

Математическая статистика

smvfe

Данный конспект не является официальным учебным материалом и не претендует на полноту и истинность изложенного. Использование данного материала подразумевает понимание контекста и использование критического мышления.

Содержание

1 Предмет математической статистики. Задачи	9
1.1 Введение и определение	9
1.2 Формальная постановка	9
1.3 Основные задачи математической статистики	9
1.4 Требования к оценкам	10
2 Модель простейшей выборки	10
2.1 Определение выборки	10
2.2 Эмпирическая функция распределения	10
2.3 Свойства эмпирической функции распределения	11
2.4 Способы визуализации выборки	12
2.4.1 Гистограмма	12
2.4.2 Ядерная оценка плотности	13
2.4.3 Box-plot (ящик с усами)	13
2.4.4 Q-Q plot (квантиль-квантильный график)	13
3 Начальные выборочные моменты	13
3.1 Определения	13
3.2 Свойства выборочных начальных моментов	14
3.3 Свойства выборочного среднего \bar{X}_n	14
4 Выборочные центральные моменты. Дельта-метод	15
4.1 Определения	15
4.2 Свойства выборочной дисперсии	16
4.3 Формула для вычисления	17
4.4 Дельта-метод	17
5 Выборочные квантили и порядковые статистики	18
5.1 Порядковые статистики	18
5.2 Распределение k -й порядковой статистики	18
5.3 Совместное распределение порядковых статистик	19
5.4 Выборочные квантили	20
5.5 Выборочная медиана	20
5.6 Асимптотическое распределение выборочных квантилей	21
5.7 Совместная асимптотика порядковых статистик	21

6 Асимптотики среднего и крайних членов вариационного ряда	22
6.1 Асимптотика среднего члена вариационного ряда	22
6.2 Асимптотика крайних членов вариационного ряда	23
6.3 Связь типов с хвостами распределения	24
7 Точечное оценивание параметров	25
7.1 Постановка задачи	25
7.2 Свойства оценок	25
7.2.1 Несмешённость	25
7.2.2 Состоятельность	26
7.2.3 Эффективность	26
7.2.4 Среднеквадратичная ошибка	27
7.2.5 Асимптотическая нормальность	27
8 Метод моментов	27
8.1 Идея метода	27
8.2 Формальное описание	28
8.3 Свойства оценок метода моментов	28
8.4 Примеры	28
8.5 Достиоинства и недостатки	29
9 Метод максимального правдоподобия	30
9.1 Функция правдоподобия	30
9.2 Оценка максимального правдоподобия	30
9.3 Инвариантность ОМП	31
9.4 Примеры	31
10 ОМП для нормальной и полиномиальной моделей	32
10.1 Нормальная модель	32
10.1.1 Распределения оценок в нормальной модели	33
10.2 Полиномиальная (мультиномиальная) модель	33
10.3 Свойства ОМП в полиномиальной модели	34
11 Информация Фишера	35
11.1 Определение и мотивация	35
11.2 Информация Фишера для выборки	36
11.3 Примеры вычисления информации Фишера	37
11.4 Многомерный случай	38
12 Неравенство Рао—Крамера	38
12.1 Формулировка	38
12.2 Эффективные оценки	39
12.3 Обобщения неравенства Рао—Крамера	40
13 Свойства оценок максимального правдоподобия	41
13.1 Основные результаты	41
13.2 Дополнительные свойства ОМП	42
13.3 Асимптотическое смещение ОМП	43
13.4 Сравнение ОМП и метода моментов	43

14 Байесовские оценки	43
14.1 Байесовский подход к статистике	43
14.2 Функция потерь и байесовский риск	44
14.3 Байесовские оценки для различных функций потерь	45
14.4 Примеры байесовских оценок	45
14.5 Свойства байесовских оценок	46
15 Минимаксные оценки	47
15.1 Мотивация	47
15.2 Функция риска	47
15.3 Минимаксные оценки	47
15.4 Связь с байесовскими оценками	48
15.5 Примеры минимаксных оценок	48
15.6 Допустимость	49
15.7 Сводка подходов к оцениванию	50
16 Доверительные интервалы	50
16.1 Определение и мотивация	50
16.2 Общая схема построения доверительного интервала	51
16.3 «Универсальный» рецепт	51
16.4 Связь доверительных интервалов и проверки гипотез	52
17 Теорема Фишера. Распределение хи-квадрат	52
17.1 Распределение хи-квадрат	52
17.2 Вспомогательные леммы	52
17.3 Теорема Фишера	53
18 Распределения Фишера и Стьюдента. ДИ для нормального закона	54
18.1 Распределение Стьюдента	54
18.2 Распределение Фишера (F-распределение)	55
18.3 Доверительные интервалы для параметров нормального закона	55
18.3.1 ДИ для μ при известной σ^2	55
18.3.2 ДИ для μ при неизвестной σ^2	56
18.3.3 ДИ для σ^2 при неизвестном μ	56
18.3.4 ДИ для σ^2 при известном μ	56
18.3.5 ДИ для отношения дисперсий двух выборок	56
19 Асимптотические доверительные интервалы	57
19.1 Общая конструкция	57
19.2 Асимптотический ДИ для математического ожидания	57
19.3 Асимптотический ДИ для дисперсии	57
19.4 Асимптотический ДИ для медианы	58
19.5 Асимптотический ДИ для квантиля	58
19.6 Сравнение точных и асимптотических ДИ	59
20 Проверка статистических гипотез	59
20.1 Постановка задачи	59
20.2 Выбор нулевой гипотезы	59
20.3 Общий принцип работы статистического теста	60
20.4 Ошибки I и II рода	60
20.5 p -value (достижаемый уровень значимости)	61
20.6 Примеры тестов	62
20.7 Связь между понятиями	63

21 Статистические тесты на основе доверительных интервалов	63
21.1 Общий принцип	63
21.2 z -тест для одной выборки	63
21.3 z -тест для двух независимых выборок	63
21.4 t -тест для одной выборки	64
21.5 t -тест для двух независимых выборок	64
21.5.1 t -тест Уэлча (разные дисперсии)	64
21.6 Парный t -тест	64
21.7 F -тест для сравнения дисперсий	65
21.8 Сводная таблица тестов	65
22 Критерии Колмогорова—Смирнова	65
22.1 Критерий согласия Колмогорова (одновыборочный)	65
22.2 Критерий Колмогорова—Смирнова (двухвыборочный)	66
22.3 Односторонние статистики	67
22.4 Достоинства и недостатки	67
23 Критерий согласия хи-квадрат Пирсона	68
23.1 Постановка задачи	68
23.2 Критерий для простой гипотезы	68
23.3 Критерий для сложной гипотезы (с оцениванием параметров)	68
23.4 Выбор разбиения	69
24 Критерий однородности хи-квадрат	69
24.1 Постановка задачи	69
24.2 Статистика критерия	70
24.3 Случай 2×2	70
24.4 Точный тест Фишера (для 2×2)	71
25 Критерий независимости хи-квадрат	71
25.1 Постановка задачи	71
25.2 Статистика критерия	71
25.3 Случай 2×2	72
25.4 Меры связи	72
25.5 Сравнение критериев однородности и независимости	73
26 Критерии квантилей и знаков	73
26.1 Критерий знаков (Sign Test)	73
26.1.1 Постановка задачи о медиане	73
26.1.2 Построение статистики	74
26.1.3 Критическая область	74
26.1.4 Критерий знаков для парных выборок	74
26.2 Критерий квантилей	75
26.2.1 Постановка	75
26.3 Знаково-ранговый критерий Уилкоксона	75
27 Ранговые критерии. Критерий Манна-Уитни-Уилкоксона	76
27.1 Основные понятия	76
27.2 Критерий Манна-Уитни-Уилкоксона	77
27.2.1 Постановка задачи	77
27.2.2 Построение статистики Уилкоксона	77
27.2.3 Статистика Манна-Уитни	78
27.2.4 Асимптотическое распределение	79

27.2.5 Критическая область	79
27.2.6 Поправка на связи	79
27.3 Интерпретация через вероятности	79
27.4 Сравнение с t-критерием	80
28 Коэффициенты корреляции Пирсона, Спирмена и Кендалла. Статистические тесты	80
28.1 Коэффициент корреляции Пирсона	80
28.1.1 Тест на значимость корреляции Пирсона	81
28.1.2 Преобразование Фишера	81
28.2 Коэффициент ранговой корреляции Спирмена	82
28.2.1 Свойства коэффициента Спирмена	82
28.2.2 Тест на значимость Спирмена	83
28.3 Коэффициент ранговой корреляции Кендалла	83
28.3.1 Свойства коэффициента Кендалла	83
28.3.2 Связь с коэффициентом Спирмена	84
28.3.3 Тест на значимость Кендалла	84
28.3.4 Модификации при наличии связей	84
28.4 Сравнение коэффициентов корреляции	85
29 Критерий инверсий	85
29.1 Определение инверсии	85
29.2 Связь с другими статистиками	86
29.3 Распределение числа инверсий	86
29.4 Критерий инверсий для проверки случайности	87
29.4.1 Постановка	87
29.4.2 Обнаружение трендов	87
29.4.3 Алгоритм вычисления	87
29.5 Приложения критерия инверсий	87
30 Модификация критерия хи-квадрат для проверки гипотезы о согласованности данных с моделью простейшей выборки	88
30.1 Модель простейшей выборки	88
30.2 Стандартный критерий хи-квадрат (напоминание)	88
30.3 Проблема оценивания параметров	88
30.4 Модификация Фишера	89
30.5 Модификация для параметров, оценённых по исходным данным	89
30.5.1 Проблема	89
30.5.2 Подход Черноффа-Лемана	89
30.6 Рекомендации по выбору разбиения	89
30.7 Критерий хи-квадрат с равновероятными интервалами	90
30.8 Специфика для некоторых распределений	90
30.8.1 Нормальное распределение	90
30.8.2 Экспоненциальное распределение	90
30.8.3 Пуассоновское распределение	90
30.9 Альтернативные подходы	91
30.9.1 Критерий минимума хи-квадрат	91
30.9.2 Бутстреп-калибровка	91
30.10 Проверка независимости наблюдений	91
30.11 Комбинированная процедура проверки	91
30.12 Сводная таблица степеней свободы	92

31 Модель линейной регрессии. Предположения. Оценка наименьших квадратов	92
31.1 Модель линейной регрессии	92
31.2 Минимальные предположения	92
31.3 Обычные (классические) предположения	93
31.4 Оценка наименьших квадратов (МНК/OLS)	93
31.5 Геометрическая интерпретация	94
31.6 Свойства МНК-оценки	95
31.7 Простая линейная регрессия	96
32 Теорема Гаусса-Маркова	96
32.1 Формулировка теоремы	96
32.2 Доказательство теоремы Гаусса-Маркова	96
32.3 Следствия теоремы Гаусса-Маркова	97
32.4 Эффективность при нормальности	98
33 Оценка остаточной дисперсии	98
33.1 Остаточная сумма квадратов	98
33.2 Несмешённая оценка дисперсии	98
33.3 Распределение RSS при нормальности	99
33.4 Независимость от оценки коэффициентов	100
34 Условная оценка наименьших квадратов	100
34.1 Постановка задачи	100
34.2 Метод множителей Лагранжа	101
34.3 Свойства условной оценки	101
34.4 Остаточная сумма квадратов	102
34.5 F-тест для проверки ограничений	102
35 Основная теорема о линейной регрессии. Следствия. t-тест	103
35.1 Основная теорема	103
35.2 Следствия основной теоремы	103
35.3 t-тест для коэффициентов регрессии	104
35.3.1 Тест на значимость коэффициента	104
35.3.2 Тест на заданное значение	105
35.4 Доверительный интервал для коэффициента	105
35.5 Простая линейная регрессия: частные случаи	105
35.6 F-тест для общей значимости регрессии	105
35.7 Коэффициент детерминации	106
35.8 Сводная таблица распределений	107
36 F-тест. Коэффициент детерминации	107
36.1 F-тест: общая теория	107
36.2 F-статистика для сравнения моделей	107
36.3 Частные случаи F-теста	108
36.3.1 Тест на общую значимость регрессии	108
36.3.2 Тест на значимость группы переменных	108
36.3.3 Тест на один коэффициент	108
36.4 Коэффициент детерминации R^2	108
36.4.1 Интерпретация R^2	109
36.4.2 Проблемы с R^2	109
36.5 Скорректированный R^2	109
36.6 Другие меры качества	110

37 Однофакторный дисперсионный анализ	110
37.1 Постановка задачи	110
37.2 Обозначения	111
37.3 Разложение суммы квадратов	111
37.4 Степени свободы	112
37.5 Средние квадраты и F-статистика	112
37.6 Таблица ANOVA	113
37.7 Связь с регрессией	113
37.8 Множественные сравнения	113
38 Двухфакторный дисперсионный анализ	113
38.1 Модель без взаимодействия	113
38.2 Модель с взаимодействием	114
38.3 Разложение суммы квадратов	114
38.4 Степени свободы	115
38.5 F-тесты	115
38.6 Таблица двухфакторного ANOVA	115
38.7 Интерпретация взаимодействия	115
38.8 Случай без повторений ($n = 1$)	115
39 Ковариационный анализ	116
39.1 Постановка задачи	116
39.2 Цели ANCOVA	116
39.3 Предположения ANCOVA	116
39.4 Оценивание параметров	117
39.5 Разложение суммы квадратов	117
39.6 F-тест ANCOVA	117
39.7 Проверка гомогенности наклонов	117
39.8 Таблица ANCOVA	117
39.9 Преимущества ANCOVA	118
40 Логистическая регрессия. Регрессия Пуассона	118
40.1 Обобщённые линейные модели: структура	118
40.2 Логистическая регрессия	118
40.2.1 Связь с вероятностью	118
40.2.2 Интерпретация коэффициентов	118
40.2.3 Оценивание: метод максимального правдоподобия	119
40.2.4 Асимптотические свойства МПО	119
40.2.5 Тесты в логистической регрессии	119
40.2.6 Меры качества	120
40.3 Регрессия Пуассона	120
40.3.1 Связь с интенсивностью	120
40.3.2 Интерпретация коэффициентов	120
40.3.3 Оценивание МПО	120
40.3.4 Сверхдисперсия	121
40.3.5 Смещение (Offset)	121
40.4 Сравнение GLM	121
41 Критерий отношения правдоподобий для простых гипотез. Лемма Неймана-Пирсона	121
41.1 Постановка задачи	121
41.2 Непрерывный случай	122
41.3 Лемма Неймана-Пирсона	122

41.4 Следствия леммы Неймана-Пирсона	123
41.5 Примеры применения	123
42 Критерий отношения правдоподобий для простых гипотез в дискретном случае	124
42.1 Особенности дискретного случая	124
42.2 Рандомизированный критерий	124
42.3 Алгоритм построения НМ-критерия в дискретном случае	125
42.4 Пример: биномиальное распределение	125
42.5 Пример: распределение Пуассона	125
42.6 Практические замечания	126
43 Общий критерий отношения максимальных правдоподобий для сложных гипотез	126
43.1 Сложные гипотезы	126
43.2 Обобщённый критерий отношения правдоподобий (GLRT)	126
43.3 Асимптотическое распределение	127
43.4 Примеры GLRT	127
43.4.1 Проверка значения среднего	127
43.4.2 Проверка равенства дисперсий	127
43.4.3 Проверка в таблицах сопряжённости	128
43.5 Сравнение GLRT с другими критериями	128
44 Последовательный анализ Вальда. Алгоритм. Теорема о конечном числе шагов	128
44.1 Мотивация	128
44.2 Постановка задачи	128
44.3 Последовательный критерий отношения вероятностей (SPRT)	129
44.4 Логарифмическая форма	129
44.5 Графическая интерпретация	129
44.6 Теорема о конечном числе шагов	129
45 Последовательный анализ Вальда. Оценка констант и вероятностей ошибок. Среднее число итераций	130
45.1 Вероятности ошибок	130
45.2 Теорема об оценке граничных констант	130
45.3 Уточнённые оценки ошибок	131
45.4 Среднее число итераций (ASN)	131
45.5 Сравнение с фиксированным объёмом выборки	132
45.6 Пример: нормальное распределение	132
46 Введение в байесовскую статистику. Credible intervals. Проверка гипотез	133
46.1 Основные принципы	133
46.2 Сравнение с частотным подходом	133
46.3 Априорные распределения	133
46.4 Байесовские точечные оценки	134
46.5 Credible Intervals (доверительные интервалы Байеса)	134
46.5.1 Типы credible intervals	134
46.6 Байесовская проверка гипотез	135
46.6.1 Апостериорные вероятности гипотез	135
46.6.2 Байес-фактор	135
46.6.3 Интерпретация Байес-фактора	136
46.6.4 Точечные нулевые гипотезы	136
46.7 Сравнение байесовского и частотного подходов к проверке гипотез	136

1 Предмет математической статистики. Задачи

1.1 Введение и определение

Def. (Математическая статистика)

Математическая статистика — раздел математики, посвящённый методам сбора, анализа и интерпретации статистических данных. В отличие от теории вероятностей, где известно распределение и изучаются свойства случайных величин, в математической статистике распределение *неизвестно* (полностью или частично), и задача состоит в его *восстановлении* по наблюдениям.

Ключевое отличие от теории вероятностей:

Теория вероятностей	Математическая статистика
Распределение известно $P \rightarrow$ свойства X Дедуктивный подход	Распределение неизвестно Выборка \rightarrow восстановление P Индуктивный подход

1.2 Формальная постановка

Пусть $(\Omega, \mathcal{F}, \mathbb{P}_\theta)$ — вероятностное пространство с неизвестным параметром $\theta \in \Theta$, где Θ — *параметрическое пространство*. Наблюдаем реализации случайной величины $X : \Omega \rightarrow \mathbb{R}$ с неизвестным распределением $F_\theta(x) = \mathbb{P}_\theta(X \leq x)$.

Цель: по выборке X_1, \dots, X_n сделать выводы о неизвестном θ или F_θ .

1.3 Основные задачи математической статистики

1. Точечное оценивание параметров

Задача: Найти функцию $\hat{\theta}_n = \hat{\theta}_n(X_1, \dots, X_n)$ — **статистику**, которая приближает неизвестный параметр θ .

Пример: Оценка математического ожидания μ выборочным средним:

$$\hat{\mu}_n = \bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

2. Интервальное оценивание (доверительные интервалы)

Задача: Построить интервал $[\hat{\theta}_L, \hat{\theta}_U]$, который содержит истинное значение θ с заданной вероятностью $1 - \alpha$ (уровень доверия):

$$\mathbb{P}_\theta(\hat{\theta}_L(X_1, \dots, X_n) \leq \theta \leq \hat{\theta}_U(X_1, \dots, X_n)) \geq 1 - \alpha$$

3. Проверка статистических гипотез

Задача: На основе выборки принять решение о справедливости гипотезы H_0 (нулевая) против альтернативы H_1 .

Примеры:

- $H_0 : \mu = \mu_0$ vs $H_1 : \mu \neq \mu_0$ (двусторонняя)
- H_0 : выборка из нормального распределения

4. Непараметрическое оценивание

Задача: Оценить функцию распределения $F(x)$ или плотность $f(x)$ без предположений о параметрической форме.

5. Регрессионный анализ

Задача: Установить зависимость $Y = f(X, \theta) + \varepsilon$ и оценить параметры θ .

6. Классификация и кластеризация

Задача: Разбиение объектов на группы по их статистическим характеристикам.

1.4 Требования к оценкам

Хорошая оценка $\hat{\theta}_n$ должна обладать свойствами:

- **Несмешённость:** $\mathbb{E}[\hat{\theta}_n] = \theta$ для всех $\theta \in \Theta$
- **Состоятельность:** $\hat{\theta}_n \xrightarrow{P} \theta$ при $n \rightarrow \infty$
- **Эффективность:** минимальная дисперсия среди несмешённых оценок
- **Асимптотическая нормальность:** $\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{d} \mathcal{N}(0, \sigma^2)$

2 Модель простейшей выборки

2.1 Определение выборки

Def. (Простейшая (простая случайная) выборка)

Простейшей выборкой объёма n из распределения F называется набор X_1, X_2, \dots, X_n независимых одинаково распределённых (i.i.d.) случайных величин с функцией распределения F .
Формально:

1. X_1, \dots, X_n — независимы
2. $X_i \sim F$ для всех $i = 1, \dots, n$

Обозначение: $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} F$ или $X_1, \dots, X_n \sim F$ (n i.i.d. копий).

Интерпретация:

- X_i — случайная величина (до проведения эксперимента)
- x_i — реализация X_i (конкретное наблюдённое значение)
- (x_1, \dots, x_n) — реализация выборки

2.2 Эмпирическая функция распределения

Def. (Эмпирическая функция распределения)

Пусть X_1, \dots, X_n — выборка. **Эмпирическая функция распределения (ЭФР):**

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{X_i \leq x} = \frac{\#\{i : X_i \leq x\}}{n}$$

где $\mathbf{1}_{X_i \leq x}$ — индикатор события $\{X_i \leq x\}$.

Геометрически: $F_n(x)$ — доля наблюдений, не превосходящих x .

Альтернативная запись через порядковые статистики:

Пусть $X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}$ — вариационный ряд (упорядоченная выборка). Тогда:

$$F_n(x) = \begin{cases} 0, & x < X_{(1)} \\ \frac{k}{n}, & X_{(k)} \leq x < X_{(k+1)}, \quad k = 1, \dots, n-1 \\ 1, & x \geq X_{(n)} \end{cases}$$

2.3 Свойства эмпирической функции распределения

Th. (Свойства ЭФР)

Пусть $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} F$. Тогда:

(i) **Несмешённость:** $\mathbb{E}[F_n(x)] = F(x)$ для любого $x \in \mathbb{R}$

(ii) **Дисперсия:** $\mathbb{D}[F_n(x)] = \frac{F(x)(1 - F(x))}{n}$

(iii) **Состоятельность (поточечная):** $F_n(x) \xrightarrow{\mathbb{P}} F(x)$ при $n \rightarrow \infty$ для любого x

(iv) **Асимптотическая нормальность:**

$$\sqrt{n}(F_n(x) - F(x)) \xrightarrow{d} \mathcal{N}(0, F(x)(1 - F(x)))$$

(v) **Теорема Гливенко—Кантелли (равномерная состоятельность):**

$$\sup_{x \in \mathbb{R}} |F_n(x) - F(x)| \xrightarrow{\text{П.Н.}} 0 \quad \text{при } n \rightarrow \infty$$

Proof. (Доказательства)

(i) **Несмешённость:**

$$\mathbb{E}[F_n(x)] = \mathbb{E}\left[\frac{1}{n} \sum_{i=1}^n \mathbf{1}_{X_i \leq x}\right] = \frac{1}{n} \sum_{i=1}^n \mathbb{E}[\mathbf{1}_{X_i \leq x}] = \frac{1}{n} \sum_{i=1}^n \mathbb{P}(X_i \leq x) = \frac{1}{n} \cdot n \cdot F(x) = F(x)$$

(ii) **Дисперсия:**

Заметим, что $Y_i = \mathbf{1}_{X_i \leq x} \sim \text{Bernoulli}(F(x))$, поэтому $\mathbb{D}[Y_i] = F(x)(1 - F(x))$.

По независимости:

$$\mathbb{D}[F_n(x)] = \mathbb{D}\left[\frac{1}{n} \sum_{i=1}^n Y_i\right] = \frac{1}{n^2} \sum_{i=1}^n \mathbb{D}[Y_i] = \frac{1}{n^2} \cdot n \cdot F(x)(1 - F(x)) = \frac{F(x)(1 - F(x))}{n}$$

(iii) **Состоятельность:** Следует из (i), (ii) и неравенства Чебышёва:

$$\mathbb{P}(|F_n(x) - F(x)| > \varepsilon) \leq \frac{\mathbb{D}[F_n(x)]}{\varepsilon^2} = \frac{F(x)(1 - F(x))}{n\varepsilon^2} \rightarrow 0$$

(iv) **Асимптотическая нормальность:** Применяем ЦПТ к сумме $\sum_{i=1}^n \mathbf{1}_{X_i \leq x}$.

(v) **Теорема Гливенко—Кантелли:**

Идея доказательства: Разбиваем \mathbb{R} на конечное число интервалов $(-\infty, t_1], (t_1, t_2], \dots, (t_k, +\infty)$ так, чтобы F менялась на каждом не более чем на ε . На каждом интервале поточечная сходимость даёт оценку $|F_n(t_j) - F(t_j)| < \varepsilon$ п.н. при больших n . Монотонность F_n и F позволяет контролировать отклонение между точками разбиения. ■

NB.

Теорема Гливенко—Кантелли — фундаментальный результат, обосновывающий использование ЭФР как оценки истинной функции распределения.

2.4 Способы визуализации выборки

2.4.1 Гистограмма

Def. (Гистограмма)

Пусть \mathbb{R} разбит на интервалы $\Delta_1, \dots, \Delta_k$ длины h (ширина бина). **Гистограмма:**

$$\hat{f}_n(x) = \frac{\nu_j}{n \cdot h}, \quad x \in \Delta_j$$

где $\nu_j = \#\{i : X_i \in \Delta_j\}$ — число наблюдений в j -м интервале.

Свойства:

- $\int_{-\infty}^{+\infty} \hat{f}_n(x) dx = 1$ (нормировка)
- При $n \rightarrow \infty, h \rightarrow 0, nh \rightarrow \infty$: $\hat{f}_n(x) \rightarrow f(x)$ (состоятельность)

Выбор числа интервалов:

- Правило Стёрджеса: $k = 1 + \log_2 n \approx 1 + 3.322 \lg n$
- Правило Фридмана—Диакониса: $h = 2 \cdot \text{IQR}/n^{1/3}$

2.4.2 Ядерная оценка плотности

Def. (Ядерная оценка плотности)

$$\hat{f}_n(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - X_i}{h}\right)$$

где K — ядро (симметричная плотность, например, гауссовское), $h > 0$ — ширина окна (bandwidth).

2.4.3 Box-plot (ящик с усами)

Отображает:

- Медиану (центральная линия)
- Первый и третий квартили Q_1, Q_3 (границы ящика)
- Усы: до $Q_1 - 1.5 \cdot \text{IQR}$ и $Q_3 + 1.5 \cdot \text{IQR}$
- Выбросы — точки за пределами усов

где $\text{IQR} = Q_3 - Q_1$ — межквартильный размах.

2.4.4 Q-Q plot (квантиль-квантильный график)

Сравнение эмпирических квантилей $X_{(k)}$ с теоретическими $F^{-1}((k - 0.5)/n)$.

Если точки ложатся на прямую $y = x$, то распределение выборки соответствует F .

3 Начальные выборочные моменты

3.1 Определения

Def. (Начальный момент порядка k)

Пусть $X \sim F$ — случайная величина. **Начальный (теоретический) момент порядка k :**

$$\alpha_k = \mathbb{E}[X^k] = \int_{-\infty}^{+\infty} x^k dF(x)$$

(если интеграл абсолютно сходится).

Def. (Выборочный начальный момент)

Пусть X_1, \dots, X_n — выборка. **Выборочный начальный момент порядка k :**

$$A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$$

Частный случай: $A_1 = \bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ — **выборочное среднее.**

3.2 Свойства выборочных начальных моментов

Th. (Свойства A_k)

Пусть $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} F, \mathbb{E}[|X|^k] < \infty$. Тогда:

(i) **Несмешённость:** $\mathbb{E}[A_k] = \alpha_k$

(ii) **Дисперсия:** $\mathbb{D}[A_k] = \frac{\alpha_{2k} - \alpha_k^2}{n} = \frac{\mathbb{D}[X^k]}{n}$

(iii) **Состоятельность:** $A_k \xrightarrow{\mathbb{P}} \alpha_k$ при $n \rightarrow \infty$ (ЗБЧ)

(iv) **Асимптотическая нормальность** (при $\mathbb{E}[X^{2k}] < \infty$):

$$\sqrt{n}(A_k - \alpha_k) \xrightarrow{d} \mathcal{N}(0, \alpha_{2k} - \alpha_k^2)$$

Proof.

(i) **Несмешённость:**

$$\mathbb{E}[A_k] = \mathbb{E}\left[\frac{1}{n} \sum_{i=1}^n X_i^k\right] = \frac{1}{n} \sum_{i=1}^n \mathbb{E}[X_i^k] = \frac{1}{n} \cdot n \cdot \alpha_k = \alpha_k$$

(ii) **Дисперсия:** Пусть $Y_i = X_i^k$. Тогда $\mathbb{D}[Y_i] = \mathbb{E}[Y_i^2] - (\mathbb{E}[Y_i])^2 = \alpha_{2k} - \alpha_k^2$.

$$\mathbb{D}[A_k] = \mathbb{D}\left[\frac{1}{n} \sum_{i=1}^n Y_i\right] = \frac{1}{n^2} \cdot n \cdot \mathbb{D}[Y_i] = \frac{\alpha_{2k} - \alpha_k^2}{n}$$

(iii) Следует из ЗБЧ (закона больших чисел) для X_i^k .

(iv) Следует из ЦПТ для X_i^k . ■

3.3 Свойства выборочного среднего \bar{X}_n

Th. (Свойства выборочного среднего)

Пусть $\mathbb{E}[X] = \mu, \mathbb{D}[X] = \sigma^2 < \infty$. Тогда:

(i) $\mathbb{E}[\bar{X}_n] = \mu$ (несмешённость)

(ii) $\mathbb{D}[\bar{X}_n] = \frac{\sigma^2}{n}$

(iii) $\bar{X}_n \xrightarrow{\mathbb{P}} \mu$ (состоятельность)

(iv) $\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} \mathcal{N}(0, 1)$ (ЦПТ)

(v) Если $X_i \sim \mathcal{N}(\mu, \sigma^2)$, то $\bar{X}_n \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$ **точно** (не асимптотически)

NB.

Выборочное среднее — **эффективная** оценка μ в классе несмешённых оценок для нормального распределения (достигает границы Рао—Крамера).

4 Выборочные центральные моменты. Дельта-метод

4.1 Определения

Def. (Центральный момент порядка k)

Теоретический центральный момент порядка k :

$$\mu_k = \mathbb{E}[(X - \mathbb{E}[X])^k] = \mathbb{E}[(X - \mu)^k]$$

В частности: $\mu_1 = 0$, $\mu_2 = \sigma^2$ (дисперсия).

Def. (Выборочный центральный момент)

Выборочный центральный момент порядка k :

$$M_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^k$$

Def. (Выборочная дисперсия)

Есть два варианта определения:

1. Смешённая выборочная дисперсия:

$$S_n^2 = M_2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

2. Несмешённая (исправленная) выборочная дисперсия:

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2 = \frac{n}{n-1} S_n^2$$

4.2 Свойства выборочной дисперсии

Th. (Свойства S_n^2 и S^2)

Пусть $\mathbb{E}[X] = \mu$, $\mathbb{D}[X] = \sigma^2$, $\mathbb{E}[X^4] < \infty$. Тогда:

(i) **Смещение** S_n^2 :

$$\mathbb{E}[S_n^2] = \frac{n-1}{n} \sigma^2 \neq \sigma^2$$

(ii) **Несмешённость** S^2 :

$$\mathbb{E}[S^2] = \sigma^2$$

(iii) **Состоятельность**: $S_n^2 \xrightarrow{\mathbb{P}} \sigma^2$ и $S^2 \xrightarrow{\mathbb{P}} \sigma^2$

(iv) **Асимптотическая нормальность**:

$$\sqrt{n}(S_n^2 - \sigma^2) \xrightarrow{d} \mathcal{N}(0, \mu_4 - \sigma^4)$$

где $\mu_4 = \mathbb{E}[(X - \mu)^4]$ — четвёртый центральный момент.

Proof. (Доказательство несмешённости S^2)

Разложим сумму квадратов отклонений:

$$\begin{aligned} \sum_{i=1}^n (X_i - \bar{X}_n)^2 &= \sum_{i=1}^n [(X_i - \mu) - (\bar{X}_n - \mu)]^2 \\ &= \sum_{i=1}^n (X_i - \mu)^2 - 2(\bar{X}_n - \mu) \sum_{i=1}^n (X_i - \mu) + n(\bar{X}_n - \mu)^2 \end{aligned}$$

Заметим, что $\sum_{i=1}^n (X_i - \mu) = n(\bar{X}_n - \mu)$, поэтому:

$$\sum_{i=1}^n (X_i - \bar{X}_n)^2 = \sum_{i=1}^n (X_i - \mu)^2 - n(\bar{X}_n - \mu)^2$$

Берём математическое ожидание:

$$\begin{aligned} \mathbb{E} \left[\sum_{i=1}^n (X_i - \bar{X}_n)^2 \right] &= \sum_{i=1}^n \mathbb{E}[(X_i - \mu)^2] - n \mathbb{E}[(\bar{X}_n - \mu)^2] \\ &= n\sigma^2 - n \cdot \frac{\sigma^2}{n} = n\sigma^2 - \sigma^2 = (n-1)\sigma^2 \end{aligned}$$

Следовательно:

$$\mathbb{E}[S^2] = \mathbb{E} \left[\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2 \right] = \frac{(n-1)\sigma^2}{n-1} = \sigma^2$$



NB. (Интерпретация множителя $n - 1$)

Делим на $(n - 1)$, а не на n , потому что при оценке центрального момента теряется одна «степень свободы» — мы используем оценку \bar{X}_n вместо истинного μ .

4.3 Формула для вычисления

Удобная вычислительная формула:

$$S_n^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}_n^2 = A_2 - A_1^2$$

4.4 Дельта-метод**Th. (Дельта-метод)**

Пусть $\sqrt{n}(T_n - \theta) \xrightarrow{d} \mathcal{N}(0, \sigma^2)$ и функция g дифференцируема в точке θ с $g'(\theta) \neq 0$. Тогда:

$$\boxed{\sqrt{n}(g(T_n) - g(\theta)) \xrightarrow{d} \mathcal{N}(0, [g'(\theta)]^2 \sigma^2)}$$

Proof.

По теореме Тейлора:

$$g(T_n) \approx g(\theta) + g'(\theta)(T_n - \theta)$$

Следовательно:

$$\sqrt{n}(g(T_n) - g(\theta)) \approx g'(\theta) \cdot \sqrt{n}(T_n - \theta) \xrightarrow{d} g'(\theta) \cdot \mathcal{N}(0, \sigma^2) = \mathcal{N}(0, [g'(\theta)]^2 \sigma^2)$$

Строгое обоснование: теорема Слуцкого и свойства сходимости по распределению. ■

Ex. (Применение дельта-метода)

Найдём асимптотическое распределение выборочного стандартного отклонения $S_n = \sqrt{S_n^2}$.

Имеем: $\sqrt{n}(S_n^2 - \sigma^2) \xrightarrow{d} \mathcal{N}(0, \mu_4 - \sigma^4)$.

Применяем $g(x) = \sqrt{x}$, $g'(x) = \frac{1}{2\sqrt{x}}$, $g'(\sigma^2) = \frac{1}{2\sigma}$.

По дельта-методу:

$$\sqrt{n}(S_n - \sigma) \xrightarrow{d} \mathcal{N}\left(0, \frac{\mu_4 - \sigma^4}{4\sigma^2}\right)$$

Th. (Многомерный дельта-метод)

Пусть $\sqrt{n}(\mathbf{T}_n - \boldsymbol{\theta}) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \Sigma)$ в \mathbb{R}^k и $g : \mathbb{R}^k \rightarrow \mathbb{R}^m$ дифференцируема в $\boldsymbol{\theta}$. Тогда:

$$\sqrt{n}(g(\mathbf{T}_n) - g(\boldsymbol{\theta})) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \nabla g(\boldsymbol{\theta})^\top \Sigma \nabla g(\boldsymbol{\theta}))$$

где ∇g — матрица Якоби.

5 Выборочные квантили и порядковые статистики

5.1 Порядковые статистики

Def. (Порядковые статистики)

Пусть X_1, \dots, X_n — выборка. **Порядковыми статистиками** называются элементы вариационного ряда:

$$X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}$$

где $X_{(k)}$ — k -я порядковая статистика.

В частности:

- $X_{(1)} = \min\{X_1, \dots, X_n\}$ — минимум
- $X_{(n)} = \max\{X_1, \dots, X_n\}$ — максимум
- $R_n = X_{(n)} - X_{(1)}$ — размах выборки

5.2 Распределение k -й порядковой статистики

Th. (Распределение $X_{(k)}$)

Пусть $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} F$ с плотностью f . Тогда плотность $X_{(k)}$:

$$f_{(k)}(x) = \frac{n!}{(k-1)!(n-k)!} [F(x)]^{k-1} [1 - F(x)]^{n-k} f(x)$$

или, используя бета-функцию:

$$f_{(k)}(x) = \frac{1}{B(k, n-k+1)} [F(x)]^{k-1} [1 - F(x)]^{n-k} f(x)$$

Proof.

Событие $\{x < X_{(k)} \leq x + dx\}$ означает:

- Ровно $(k-1)$ наблюдений $\leq x$
- Ровно одно наблюдение в $(x, x+dx]$

- Ровно $(n - k)$ наблюдений $> x + dx$

Число способов выбрать, какие именно наблюдения попадают в каждую группу:

$$\binom{n}{k-1, 1, n-k} = \frac{n!}{(k-1)! \cdot 1! \cdot (n-k)!}$$

Вероятности:

$$\begin{aligned}\mathbb{P}(X_i \leq x) &= F(x) \\ \mathbb{P}(X_i \in (x, x+dx]) &\approx f(x) dx \\ \mathbb{P}(X_i > x+dx) &\approx 1 - F(x)\end{aligned}$$

Итого:

$$\mathbb{P}(x < X_{(k)} \leq x+dx) = \frac{n!}{(k-1)!(n-k)!} [F(x)]^{k-1} f(x) dx [1 - F(x)]^{n-k}$$

■

Частные случаи:

Минимум ($k = 1$):

$$f_{(1)}(x) = n[1 - F(x)]^{n-1} f(x), \quad F_{(1)}(x) = 1 - [1 - F(x)]^n$$

Максимум ($k = n$):

$$f_{(n)}(x) = n[F(x)]^{n-1} f(x), \quad F_{(n)}(x) = [F(x)]^n$$

5.3 Совместное распределение порядковых статистик

Th. (Совместная плотность всех порядковых статистик)

Совместная плотность вектора $(X_{(1)}, \dots, X_{(n)})$:

$$f_{(1), \dots, (n)}(x_1, \dots, x_n) = n! \prod_{i=1}^n f(x_i), \quad x_1 < x_2 < \dots < x_n$$

и 0 иначе.

Proof.

Рассмотрим преобразование $(X_1, \dots, X_n) \mapsto (X_{(1)}, \dots, X_{(n)})$.

Совместная плотность независимых X_1, \dots, X_n : $f(x_1) \cdots f(x_n)$.

Существует ровно $n!$ перестановок (x_1, \dots, x_n) , дающих одну и ту же упорядоченную последовательность. Поэтому:

$$f_{(1), \dots, (n)}(x_1, \dots, x_n) = n! \cdot f(x_1) \cdots f(x_n)$$

на области $x_1 < x_2 < \dots < x_n$.

■

Th. (Совместная плотность двух порядковых статистик)

Для $i < j$ совместная плотность $(X_{(i)}, X_{(j)})$:

$$f_{(i),(j)}(x, y) = \frac{n!}{(i-1)!(j-i-1)!(n-j)!} \times [F(x)]^{i-1} [F(y) - F(x)]^{j-i-1} [1 - F(y)]^{n-j} f(x)f(y)$$

для $x < y$.

5.4 Выборочные квантили

Def. (Теоретический квантиль)

Квантиль уровня p ($0 < p < 1$) распределения F :

$$\xi_p = F^{-1}(p) = \inf\{x : F(x) \geq p\}$$

Def. (Выборочный квантиль)

Выборочный квантиль уровня p :

$$\hat{\xi}_p = X_{(\lceil np \rceil)}$$

или с интерполяцией:

$$\hat{\xi}_p = X_{(\lfloor np \rfloor + 1)} \quad \text{или} \quad \hat{\xi}_p = (1 - \gamma)X_{(j)} + \gamma X_{(j+1)}$$

где $j = \lfloor np \rfloor$, $\gamma = np - j$.

Важные квантили:

- **Медиана:** $\hat{\xi}_{0.5}$ (или $\text{Med} = \frac{X_{(k)} + X_{(k+1)}}{2}$ при чётном $n = 2k$)
- **Первый квартиль:** $Q_1 = \hat{\xi}_{0.25}$
- **Третий квартиль:** $Q_3 = \hat{\xi}_{0.75}$

5.5 Выборочная медиана

Def. (Выборочная медиана)

$$\text{Med}_n = \begin{cases} X_{\left(\frac{n+1}{2}\right)}, & n \text{ — нечётное} \\ \frac{X_{\left(\frac{n}{2}\right)} + X_{\left(\frac{n}{2}+1\right)}}{2}, & n \text{ — чётное} \end{cases}$$

5.6 Асимптотическое распределение выборочных квантилей

Th. (Асимптотическая нормальность выборочного квантиля)

Пусть F имеет плотность f , непрерывную и положительную в точке $\xi_p = F^{-1}(p)$. Тогда:

$$\sqrt{n}(\hat{\xi}_p - \xi_p) \xrightarrow{d} \mathcal{N}\left(0, \frac{p(1-p)}{[f(\xi_p)]^2}\right)$$

Proof. (Идея доказательства)

Используем представление:

$$F_n(\hat{\xi}_p) \approx p, \quad F(\xi_p) = p$$

По теореме об асимптотической нормальности ЭФР:

$$\sqrt{n}(F_n(x) - F(x)) \xrightarrow{d} \mathcal{N}(0, F(x)(1 - F(x)))$$

Применяя дельта-метод к функции F^{-1} и учитывая $(F^{-1})'(p) = 1/f(\xi_p)$:

$$\sqrt{n}(\hat{\xi}_p - \xi_p) \xrightarrow{d} \mathcal{N}\left(0, \frac{p(1-p)}{f(\xi_p)^2}\right)$$

■

Corollary. (Асимптотика медианы)

Для медианы ($p = 1/2$):

$$\sqrt{n}(\text{Med}_n - \xi_{1/2}) \xrightarrow{d} \mathcal{N}\left(0, \frac{1}{4f(\xi_{1/2})^2}\right)$$

NB. (Сравнение медианы и среднего)

Для нормального распределения $\mathcal{N}(\mu, \sigma^2)$:

- $\mathbb{D}[\bar{X}_n] = \frac{\sigma^2}{n}$
- $\mathbb{D}[\text{Med}_n] \approx \frac{\pi\sigma^2}{2n} \approx 1.57 \cdot \frac{\sigma^2}{n}$

То есть медиана менее эффективна для нормального распределения.

Однако медиана **робастна** — устойчива к выбросам, тогда как среднее сильно зависит от экстремальных значений.

5.7 Совместная асимптотика порядковых статистик

Th. (Совместная асимптотическая нормальность квантилей)

Пусть $0 < p_1 < p_2 < 1$, $\xi_{p_i} = F^{-1}(p_i)$, $f(\xi_{p_i}) > 0$. Тогда:

$$\sqrt{n} \begin{pmatrix} \hat{\xi}_{p_1} - \xi_{p_1} \\ \hat{\xi}_{p_2} - \xi_{p_2} \end{pmatrix} \xrightarrow{d} \mathcal{N}(\mathbf{0}, \Sigma)$$

где

$$\Sigma = \begin{pmatrix} \frac{p_1(1-p_1)}{f(\xi_{p_1})^2} & \frac{p_1(1-p_2)}{f(\xi_{p_1})f(\xi_{p_2})} \\ \frac{p_1(1-p_2)}{f(\xi_{p_1})f(\xi_{p_2})} & \frac{p_2(1-p_2)}{f(\xi_{p_2})^2} \end{pmatrix}$$

Сводная таблица основных результатов

Статистика	Формула	$\mathbb{E}[\cdot]$	Асимптотика
$F_n(x)$	$\frac{1}{n} \sum \mathbf{1}_{X_i \leq x}$	$F(x)$	$\mathcal{N}\left(F(x), \frac{F(x)(1-F(x))}{n}\right)$
\bar{X}_n	$\frac{1}{n} \sum X_i$	μ	$\mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$
S_n^2	$\frac{1}{n} \sum (X_i - \bar{X})^2$	$\frac{n-1}{n} \sigma^2$	$\mathcal{N}\left(\sigma^2, \frac{\mu_4 - \sigma^4}{n}\right)$
S^2	$\frac{1}{n-1} \sum (X_i - \bar{X})^2$	σ^2	—
$\hat{\xi}_p$	$X_{(\lceil np \rceil)}$	$\approx \xi_p$	$\mathcal{N}\left(\xi_p, \frac{p(1-p)}{nf(\xi_p)^2}\right)$

6 Асимптотики среднего и крайних членов вариационного ряда**6.1 Асимптотика среднего члена вариационного ряда**

Средний член вариационного ряда связан с выборочной медианой. Рассмотрим более общий результат для центральных порядковых статистик.

Th. (Асимптотика центральной порядковой статистики)

Пусть $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} F$ с плотностью f , непрерывной и положительной в точке $\xi_p = F^{-1}(p)$. Пусть $k = k(n)$ такое, что $k/n \rightarrow p$ при $n \rightarrow \infty$. Тогда:

$$\sqrt{n}(X_{(k)} - \xi_p) \xrightarrow{d} \mathcal{N}\left(0, \frac{p(1-p)}{f(\xi_p)^2}\right)$$

Proof. (Идея доказательства)

Шаг 1. Рассмотрим величину $U_i = F(X_i)$. Тогда $U_i \sim \text{Uniform}(0, 1)$ (интегральное преобразование).

Шаг 2. Порядковые статистики $U_{(k)} = F(X_{(k)})$. Известно, что:

$$U_{(k)} \sim \text{Beta}(k, n - k + 1)$$

$$\text{с } \mathbb{E}[U_{(k)}] = \frac{k}{n+1} \approx p \text{ и } \mathbb{D}[U_{(k)}] = \frac{k(n-k+1)}{(n+1)^2(n+2)} \approx \frac{p(1-p)}{n}.$$

Шаг 3. По ЦПТ для бета-распределения:

$$\sqrt{n}(U_{(k)} - p) \xrightarrow{d} \mathcal{N}(0, p(1-p))$$

Шаг 4. Применяем дельта-метод к $X_{(k)} = F^{-1}(U_{(k)})$:

$$\sqrt{n}(X_{(k)} - \xi_p) = \sqrt{n}(F^{-1}(U_{(k)}) - F^{-1}(p)) \approx (F^{-1})'(p) \cdot \sqrt{n}(U_{(k)} - p)$$

Так как $(F^{-1})'(p) = 1/f(\xi_p)$, получаем:

$$\sqrt{n}(X_{(k)} - \xi_p) \xrightarrow{d} \mathcal{N}\left(0, \frac{p(1-p)}{f(\xi_p)^2}\right)$$

■

6.2 Асимптотика крайних членов вариационного ряда

Для экстремальных порядковых статистик $X_{(1)}$ и $X_{(n)}$ асимптотика существенно отличается и зависит от поведения хвостов распределения.

Th. (Типы предельных распределений экстремумов — теорема Фишера—Типпетта—Гнеденко)

Пусть $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} F$. Если существуют нормирующие последовательности $a_n > 0$, $b_n \in \mathbb{R}$ такие, что:

$$\frac{X_{(n)} - b_n}{a_n} \xrightarrow{d} G$$

для некоторой невырожденной функции распределения G , то G принадлежит одному из трёх типов:

Тип I (Гумбель):

$$G(x) = \exp(-e^{-x}), \quad x \in \mathbb{R}$$

Тип II (Фреше):

$$G(x) = \begin{cases} 0, & x \leq 0 \\ \exp(-x^{-\alpha}), & x > 0 \end{cases}, \quad \alpha > 0$$

Тип III (Вейбулл):

$$G(x) = \begin{cases} \exp(-(-x)^\alpha), & x \leq 0 \\ 1, & x > 0 \end{cases}, \quad \alpha > 0$$

Ex. (Асимптотика максимума для экспоненциального распределения)

Пусть $X_i \sim \text{Exp}(\lambda)$, $F(x) = 1 - e^{-\lambda x}$ для $x \geq 0$.

Тогда:

$$F_{(n)}(x) = [F(x)]^n = (1 - e^{-\lambda x})^n$$

Выберем $b_n = \frac{\ln n}{\lambda}$, $a_n = \frac{1}{\lambda}$. Тогда:

$$\mathbb{P}\left(\frac{X_{(n)} - b_n}{a_n} \leq x\right) = \left(1 - \frac{e^{-x}}{n}\right)^n \rightarrow e^{-e^{-x}}$$

Это распределение Гумбеля (тип I).

Ex. (Асимптотика максимума для равномерного распределения)

Пусть $X_i \sim \text{Uniform}(0, 1)$. Тогда $F(x) = x$ для $x \in [0, 1]$.

$$\mathbb{P}(n(1 - X_{(n)}) \leq x) = \mathbb{P}\left(X_{(n)} \geq 1 - \frac{x}{n}\right) = 1 - \left(1 - \frac{x}{n}\right)^n \rightarrow 1 - e^{-x}$$

Следовательно, $n(1 - X_{(n)}) \xrightarrow{d} \text{Exp}(1)$, что соответствует типу III (Вейбулл).

Th. (Асимптотика минимума)

Для минимума $X_{(1)}$ аналогичные результаты получаются заменой $X \rightarrow -X$. Если:

$$\frac{X_{(1)} - b'_n}{a'_n} \xrightarrow{d} G'$$

то G' также принадлежит одному из трёх типов.

Proof. (Идея доказательства теоремы Фишера—Типпетта—Гнеденко)

Ключевая идея: Предельное распределение G должно быть *так-устойчивым*, т.е. удовлетворять функциональному уравнению:

$$G^n(a_n x + b_n) = G(x)$$

для некоторых $a_n > 0$, b_n .

Это означает, что максимум n независимых копий из G после линейной нормировки снова имеет распределение G .

Решение этого функционального уравнения приводит ровно к трём типам распределений, перечисленным в теореме. ■

6.3 Связь типов с хвостами распределения

- **Тип I (Гумбель):** Экспоненциально убывающие хвосты (нормальное, экспоненциальное, логнормальное)
- **Тип II (Фреше):** Тяжёлые хвосты, степенное убывание (Парето, Коши, t -распределение)

- **Тип III (Вейбулл):** Ограниченный носитель (равномерное, бета)

7 Точечное оценивание параметров

7.1 Постановка задачи

Def. (Статистическая модель)

Параметрическая статистическая модель — семейство распределений:

$$\mathcal{P} = \{P_\theta : \theta \in \Theta\}$$

где $\Theta \subseteq \mathbb{R}^d$ — *параметрическое пространство*.

Наблюдаем выборку $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} P_\theta$ с неизвестным θ .

Def. (Точечная оценка)

Точечная оценка (статистика) параметра θ — любая измеримая функция выборки:

$$\hat{\theta}_n = \hat{\theta}_n(X_1, \dots, X_n) : \mathbb{R}^n \rightarrow \Theta$$

не зависящая от θ .

Задача: Построить «хорошую» оценку $\hat{\theta}_n$ по выборке.

7.2 Свойства оценок

7.2.1 Несмешённость

Def. (Несмешённость)

Оценка $\hat{\theta}_n$ называется **несмешённой**, если:

$$\mathbb{E}_\theta[\hat{\theta}_n] = \theta \quad \text{для всех } \theta \in \Theta$$

Смещение оценки:

$$\text{bias}(\hat{\theta}_n) = \mathbb{E}_\theta[\hat{\theta}_n] - \theta$$

Def. (Асимптотическая несмешённость)

Оценка $\hat{\theta}_n$ **асимптотически несмешена**, если:

$$\lim_{n \rightarrow \infty} \mathbb{E}_\theta[\hat{\theta}_n] = \theta$$

7.2.2 Состоятельность

Def. (Состоятельность)

Оценка $\hat{\theta}_n$ **состоятельна**, если:

$$\hat{\theta}_n \xrightarrow{\mathbb{P}_{\theta}} \theta \quad \text{при } n \rightarrow \infty$$

для всех $\theta \in \Theta$.

Эквивалентно: $\forall \varepsilon > 0: \mathbb{P}_{\theta}(|\hat{\theta}_n - \theta| > \varepsilon) \rightarrow 0$.

Def. (Сильная состоятельность)

Оценка $\hat{\theta}_n$ **сильно состоятельна**, если:

$$\hat{\theta}_n \xrightarrow{\text{П.Н.}} \theta$$

Th. (Достаточное условие состоятельности)

Если $\hat{\theta}_n$ несмешена и $\mathbb{D}_{\theta}[\hat{\theta}_n] \rightarrow 0$ при $n \rightarrow \infty$, то $\hat{\theta}_n$ состоятельна.

Proof.

По неравенству Чебышёва:

$$\mathbb{P}_{\theta}(|\hat{\theta}_n - \theta| > \varepsilon) = \mathbb{P}_{\theta}(|\hat{\theta}_n - \mathbb{E}[\hat{\theta}_n]| > \varepsilon) \leq \frac{\mathbb{D}[\hat{\theta}_n]}{\varepsilon^2} \rightarrow 0$$

■

7.2.3 Эффективность

Def. (Эффективность)

Несмешённая оценка $\hat{\theta}_n^*$ называется **эффективной** в классе несмешённых оценок, если для любой другой несмешённой оценки $\hat{\theta}_n$:

$$\mathbb{D}_{\theta}[\hat{\theta}_n^*] \leq \mathbb{D}_{\theta}[\hat{\theta}_n] \quad \text{для всех } \theta \in \Theta$$

Def. (Асимптотическая эффективность)

Состоятельная оценка $\hat{\theta}_n$ **асимптотически эффективна**, если:

$$\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{d} \mathcal{N}(0, I(\theta)^{-1})$$

где $I(\theta)$ — информация Фишера (см. далее).

7.2.4 Среднеквадратичная ошибка

Def. (MSE — Mean Squared Error)

Среднеквадратичная ошибка:

$$\text{MSE}_\theta(\hat{\theta}_n) = \mathbb{E}_\theta[(\hat{\theta}_n - \theta)^2]$$

Разложение:

$$\text{MSE} = \mathbb{D}[\hat{\theta}_n] + (\text{bias})^2$$

Proof.

$$\begin{aligned}\text{MSE} &= \mathbb{E}[(\hat{\theta}_n - \theta)^2] = \mathbb{E}[(\hat{\theta}_n - \mathbb{E}[\hat{\theta}_n] + \mathbb{E}[\hat{\theta}_n] - \theta)^2] \\ &= \mathbb{E}[(\hat{\theta}_n - \mathbb{E}[\hat{\theta}_n])^2] + 2(\mathbb{E}[\hat{\theta}_n] - \theta) \mathbb{E}[\hat{\theta}_n - \mathbb{E}[\hat{\theta}_n]] + (\mathbb{E}[\hat{\theta}_n] - \theta)^2 \\ &= \mathbb{D}[\hat{\theta}_n] + 0 + (\text{bias})^2\end{aligned}$$

■

NB. (Компромисс смещение—дисперсия)

Иногда выгоднее использовать смещённую оценку с меньшей дисперсией, если общий MSE меньше. Пример: S_n^2 vs S^2 .

7.2.5 Асимптотическая нормальность

Def. (Асимптотическая нормальность)

Оценка $\hat{\theta}_n$ **асимптотически нормальна**, если существует $\sigma^2(\theta) > 0$:

$$\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{d} \mathcal{N}(0, \sigma^2(\theta))$$

$\sigma^2(\theta)$ называется **асимптотической дисперсией**.

8 Метод моментов

8.1 Идея метода

Метод моментов — один из старейших и простейших способов построения оценок.

Идея: Приравнять теоретические моменты к выборочным и решить получившуюся систему уравнений относительно параметров.

8.2 Формальное описание

Пусть $\theta = (\theta_1, \dots, \theta_d) \in \Theta \subseteq \mathbb{R}^d$ — вектор параметров.

Шаг 1. Выразить первые d моментов через параметры:

$$\alpha_k(\theta) = \mathbb{E}_\theta[X^k], \quad k = 1, \dots, d$$

Шаг 2. Вычислить выборочные моменты:

$$A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$$

Шаг 3. Решить систему уравнений:

$$\begin{cases} \alpha_1(\theta) = A_1 \\ \alpha_2(\theta) = A_2 \\ \vdots \\ \alpha_d(\theta) = A_d \end{cases}$$

Решение $\hat{\theta}_n^{MM}$ — оценка метода моментов.

NB.

Можно использовать центральные моменты вместо начальных, или их комбинацию.

8.3 Свойства оценок метода моментов

Th. (Свойства ММ-оценок)

При регулярных условиях оценки метода моментов:

(i) **Состоятельны:** $\hat{\theta}_n^{MM} \xrightarrow{\mathbb{P}} \theta$

(ii) **Асимптотически нормальны:**

$$\sqrt{n}(\hat{\theta}_n^{MM} - \theta) \xrightarrow{d} \mathcal{N}(0, \Sigma)$$

где Σ определяется дельта-методом.

Proof. (Иdea доказательства)

Состоятельность следует из ЗБЧ для $A_k \xrightarrow{\mathbb{P}} \alpha_k$ и непрерывности обратного отображения $(\alpha_1, \dots, \alpha_d) \mapsto \theta$.

Асимптотическая нормальность — из ЦПТ для (A_1, \dots, A_d) и многомерного дельта-метода. ■

8.4 Примеры

Ex. (Нормальное распределение $\mathcal{N}(\mu, \sigma^2)$)

Параметры: $\theta = (\mu, \sigma^2)$.

Моменты:

$$\alpha_1 = \mu, \quad \alpha_2 = \mu^2 + \sigma^2$$

Система уравнений:

$$\begin{cases} \mu = A_1 = \bar{X}_n \\ \mu^2 + \sigma^2 = A_2 \end{cases}$$

Решение:

$$\hat{\mu}^{MM} = \bar{X}_n, \quad \hat{\sigma}^{2,MM} = A_2 - \bar{X}_n^2 = S_n^2$$

Ex. (Гамма-распределение $\Gamma(\alpha, \beta)$)

Плотность: $f(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}, x > 0.$

Моменты:

$$\mathbb{E}[X] = \frac{\alpha}{\beta}, \quad \mathbb{E}[X^2] = \frac{\alpha(\alpha+1)}{\beta^2}$$

Дисперсия: $\mathbb{D}[X] = \frac{\alpha}{\beta^2}.$

Из системы $\mathbb{E}[X] = A_1, \mathbb{D}[X] = S_n^2$:

$$\hat{\alpha}^{MM} = \frac{\bar{X}_n^2}{S_n^2}, \quad \hat{\beta}^{MM} = \frac{\bar{X}_n}{S_n^2}$$

Ex. (Равномерное распределение Uniform($0, \theta$))

$\mathbb{E}[X] = \theta/2$, поэтому:

$$\hat{\theta}^{MM} = 2\bar{X}_n$$

Заметим: это *не* оптимальная оценка (ср. с ОМП $\hat{\theta}^{MLE} = X_{(n)}$).

8.5 Достоинства и недостатки

Достоинства:

- Простота вычисления
- Не требует знания точной формы распределения
- Всегда состоятельны

Недостатки:

- Могут быть неэффективны (большая дисперсия)
- Оценки могут выходить за пределы Θ
- Не единственны (зависят от выбора моментов)

9 Метод максимального правдоподобия

9.1 Функция правдоподобия

Def. (Функция правдоподобия)

Пусть X_1, \dots, X_n — выборка из распределения с плотностью (или функцией вероятности) $f(x; \theta)$.

Функция правдоподобия:

$$L(\theta) = L(\theta; X_1, \dots, X_n) = \prod_{i=1}^n f(X_i; \theta)$$

Логарифмическая функция правдоподобия:

$$\ell(\theta) = \ln L(\theta) = \sum_{i=1}^n \ln f(X_i; \theta)$$

Интерпретация: $L(\theta)$ — «правдоподобие» параметра θ при данных наблюдениях. Чем больше $L(\theta)$, тем лучше θ объясняет данные.

NB.

$L(\theta)$ — функция от θ при фиксированных X_1, \dots, X_n . Это **не** плотность по θ !

9.2 Оценка максимального правдоподобия

Def. (ОМП — Оценка максимального правдоподобия)

Оценка максимального правдоподобия (ОМП, MLE):

$$\hat{\theta}_n^{MLE} = \arg \max_{\theta \in \Theta} L(\theta) = \arg \max_{\theta \in \Theta} \ell(\theta)$$

Алгоритм нахождения ОМП:

Шаг 1. Записать $\ell(\theta) = \sum_{i=1}^n \ln f(X_i; \theta)$.

Шаг 2. Найти критические точки из уравнения правдоподобия:

$$\frac{\partial \ell}{\partial \theta} = 0 \quad (\text{или } \nabla_{\theta} \ell = 0 \text{ для вектора } \theta)$$

Шаг 3. Проверить, что найденная точка — максимум (вторая производная < 0).

Шаг 4. Проверить граничные точки Θ , если множество ограничено.

Def. (Score-функция)

Score-функция (функция счёта):

$$S(\theta) = \frac{\partial \ell(\theta)}{\partial \theta} = \sum_{i=1}^n \frac{\partial}{\partial \theta} \ln f(X_i; \theta)$$

9.3 Инвариантность ОМП

Th. (Инвариантность ОМП)

Если $\hat{\theta}^{MLE}$ — ОМП для θ , то для любой функции g :

$$\widehat{g(\theta)}^{MLE} = g(\hat{\theta}^{MLE})$$

Proof.

Если $\eta = g(\theta)$ и g — взаимно однозначная, то:

$$L(\eta) = L(g^{-1}(\eta))$$

максимизируется при $\eta = g(\hat{\theta}^{MLE})$. ■

9.4 Примеры

Ex. (Бернулли Bernoulli(p))

$$f(x; p) = p^x (1-p)^{1-x}, x \in \{0, 1\}.$$

$$\ell(p) = \sum_{i=1}^n [X_i \ln p + (1 - X_i) \ln(1 - p)] = n\bar{X}_n \ln p + n(1 - \bar{X}_n) \ln(1 - p)$$

$$\frac{d\ell}{dp} = \frac{n\bar{X}_n}{p} - \frac{n(1 - \bar{X}_n)}{1 - p} = 0 \implies \hat{p}^{MLE} = \bar{X}_n$$

Ex. (Пуассон Poisson(λ))

$$f(k; \lambda) = \frac{\lambda^k e^{-\lambda}}{k!}.$$

$$\ell(\lambda) = \sum_{i=1}^n [X_i \ln \lambda - \lambda - \ln(X_i!)] = n\bar{X}_n \ln \lambda - n\lambda - \sum \ln(X_i!)$$

$$\frac{d\ell}{d\lambda} = \frac{n\bar{X}_n}{\lambda} - n = 0 \implies \hat{\lambda}^{MLE} = \bar{X}_n$$

Ex. (Экспоненциальное $\text{Exp}(\lambda)$)

$$f(x; \lambda) = \lambda e^{-\lambda x}, x > 0.$$

$$\ell(\lambda) = n \ln \lambda - \lambda \sum_{i=1}^n X_i = n \ln \lambda - n \lambda \bar{X}_n$$

$$\frac{d\ell}{d\lambda} = \frac{n}{\lambda} - n \bar{X}_n = 0 \implies \hat{\lambda}^{MLE} = \frac{1}{\bar{X}_n}$$

Ex. (Равномерное $\text{Uniform}(0, \theta)$)

$$f(x; \theta) = \frac{1}{\theta} \cdot \mathbf{1}_{0 \leq x \leq \theta}.$$

$$L(\theta) = \frac{1}{\theta^n} \cdot \mathbf{1}_{\theta \geq X_{(n)}}$$

$L(\theta)$ убывает по θ при $\theta \geq X_{(n)}$, поэтому:

$$\hat{\theta}^{MLE} = X_{(n)} = \max\{X_1, \dots, X_n\}$$

Внимание: ОМП смещена вниз! $\mathbb{E}[X_{(n)}] = \frac{n}{n+1}\theta < \theta$.

10 ОМП для нормальной и полиномиальной моделей

10.1 Нормальная модель

Th. (ОМП для $\mathcal{N}(\mu, \sigma^2)$)

Пусть $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(\mu, \sigma^2)$. Тогда:

$$\hat{\mu}^{MLE} = \bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

$$\hat{\sigma}^{2,MLE} = S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

Proof.

Плотность:

$$f(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

Логарифм правдоподобия:

$$\ell(\mu, \sigma^2) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (X_i - \mu)^2$$

По μ :

$$\frac{\partial \ell}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \mu) = 0 \implies \hat{\mu} = \bar{X}_n$$

По σ^2 :

$$\frac{\partial \ell}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{i=1}^n (X_i - \mu)^2 = 0$$

Подставляя $\hat{\mu} = \bar{X}_n$:

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2 = S_n^2$$

■

NB.

$\hat{\sigma}^{2,MLE} = S_n^2$ — смещённая оценка. Несмешённая оценка: $S^2 = \frac{n}{n-1} S_n^2$.

10.1.1 Распределения оценок в нормальной модели

Th. (Точные распределения)

Для $X_i \sim \mathcal{N}(\mu, \sigma^2)$:

(i) $\bar{X}_n \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$

(ii) $\frac{(n-1)S^2}{\sigma^2} = \frac{nS_n^2}{\sigma^2} \sim \chi_{n-1}^2$

(iii) \bar{X}_n и S^2 независимы (теорема Фишера)

(iv) $\frac{\bar{X}_n - \mu}{S/\sqrt{n}} \sim t_{n-1}$ (распределение Стьюдента)

10.2 Полиномиальная (мультиномиальная) модель

Def. (Полиномиальное распределение)

Пусть имеется k категорий с вероятностями p_1, \dots, p_k , $\sum_{j=1}^k p_j = 1$.

При n независимых испытаниях вектор частот (N_1, \dots, N_k) имеет **полиномиальное распределение**:

$$\mathbb{P}(N_1 = n_1, \dots, N_k = n_k) = \frac{n!}{n_1! \cdots n_k!} p_1^{n_1} \cdots p_k^{n_k}$$

где $\sum_{j=1}^k n_j = n$.

Th. (ОМП для полиномиальной модели)

$$\hat{p}_j^{MLE} = \frac{N_j}{n} = \frac{\text{число наблюдений категории } j}{n}$$

Proof.

Логарифм правдоподобия (без константы):

$$\ell(p_1, \dots, p_k) = \sum_{j=1}^k n_j \ln p_j$$

при ограничении $\sum_{j=1}^k p_j = 1$.

Используем метод множителей Лагранжа:

$$\mathcal{L} = \sum_{j=1}^k n_j \ln p_j + \lambda \left(1 - \sum_{j=1}^k p_j \right)$$

$$\frac{\partial \mathcal{L}}{\partial p_j} = \frac{n_j}{p_j} - \lambda = 0 \implies p_j = \frac{n_j}{\lambda}$$

Из ограничения: $\sum p_j = 1 \implies \lambda = n$.

Следовательно: $\hat{p}_j = \frac{n_j}{n}$. ■

10.3 Свойства ОМП в полиномиальной модели**Th. (Асимптотика частот)**

$$\sqrt{n}(\hat{p}_j - p_j) \xrightarrow{d} \mathcal{N}(0, p_j(1 - p_j))$$

Совместно:

$$\sqrt{n}(\hat{\mathbf{p}} - \mathbf{p}) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \Sigma)$$

где $\Sigma_{jj} = p_j(1 - p_j)$, $\Sigma_{jl} = -p_j p_l$ при $j \neq l$.

Th. (Статистика хи-квадрат Пирсона)

$$\chi^2 = \sum_{j=1}^k \frac{(N_j - np_j)^2}{np_j} = n \sum_{j=1}^k \frac{(\hat{p}_j - p_j)^2}{p_j} \xrightarrow{d} \chi^2_{k-1}$$

при $n \rightarrow \infty$ (если все $p_j > 0$).

11 Информация Фишера

11.1 Определение и мотивация

Информация Фишера — фундаментальное понятие, измеряющее количество информации о параметре θ , содержащееся в наблюдениях.

Def. (Условия регулярности)

Статистическая модель $\{f(x; \theta) : \theta \in \Theta\}$ называется **регулярной**, если:

(R1) $\Theta \subseteq \mathbb{R}$ — открытое множество

(R2) Носитель $\{x : f(x; \theta) > 0\}$ не зависит от θ

(R3) $f(x; \theta)$ дважды дифференцируема по θ

(R4) Можно менять порядок дифференцирования и интегрирования:

$$\frac{\partial}{\partial \theta} \int f(x; \theta) dx = \int \frac{\partial f(x; \theta)}{\partial \theta} dx$$

$$(R5) \mathbb{E}_{\theta} \left[\left(\frac{\partial \ln f(X; \theta)}{\partial \theta} \right)^2 \right] < \infty$$

Def. (Score-функция для одного наблюдения)

Score-функция (функция счёта) для одного наблюдения:

$$s(X; \theta) = \frac{\partial}{\partial \theta} \ln f(X; \theta) = \frac{\partial_{\theta} f(X; \theta)}{f(X; \theta)}$$

Lm. (Свойство score-функции)

При условиях регулярности:

$$\mathbb{E}_\theta[s(X; \theta)] = 0$$

Proof.

$$\mathbb{E}_\theta[s(X; \theta)] = \int \frac{\partial_\theta f(x; \theta)}{f(x; \theta)} f(x; \theta) dx = \int \partial_\theta f(x; \theta) dx = \frac{\partial}{\partial \theta} \int f(x; \theta) dx = \frac{\partial}{\partial \theta} 1 = 0$$

■

Def. (Информация Фишера)

Информация Фишера для одного наблюдения:

$$I(\theta) = \mathbb{E}_\theta \left[\left(\frac{\partial \ln f(X; \theta)}{\partial \theta} \right)^2 \right] = \mathbb{E}_\theta[s(X; \theta)^2] = \mathbb{D}_\theta[s(X; \theta)]$$

Th. (Альтернативная формула для информации Фишера)

При условиях регулярности:

$$I(\theta) = -\mathbb{E}_\theta \left[\frac{\partial^2 \ln f(X; \theta)}{\partial \theta^2} \right]$$

Proof.

Дифференцируем тождество $\mathbb{E}_\theta[s(X; \theta)] = 0$ по θ :

$$0 = \frac{\partial}{\partial \theta} \int s(x; \theta) f(x; \theta) dx = \int \left[\frac{\partial s}{\partial \theta} f + s \cdot \frac{\partial f}{\partial \theta} \right] dx$$

Заметим, что $\frac{\partial f}{\partial \theta} = s \cdot f$, поэтому:

$$0 = \int \frac{\partial s}{\partial \theta} f dx + \int s^2 f dx = \mathbb{E} \left[\frac{\partial s}{\partial \theta} \right] + \mathbb{E}[s^2]$$

Следовательно:

$$I(\theta) = \mathbb{E}[s^2] = -\mathbb{E} \left[\frac{\partial s}{\partial \theta} \right] = -\mathbb{E} \left[\frac{\partial^2 \ln f}{\partial \theta^2} \right]$$

■

11.2 Информация Фишера для выборки

Th. (Аддитивность информации)

Для i.i.d. выборки X_1, \dots, X_n :

$$I_n(\theta) = n \cdot I(\theta)$$

Proof.

$$I_n(\theta) = \mathbb{E} \left[\left(\sum_{i=1}^n s(X_i; \theta) \right)^2 \right] = \sum_{i=1}^n \mathbb{E}[s(X_i; \theta)^2] + \sum_{i \neq j} \mathbb{E}[s(X_i; \theta)] \mathbb{E}[s(X_j; \theta)]$$

Так как $\mathbb{E}[s(X_i; \theta)] = 0$, получаем $I_n(\theta) = n \cdot I(\theta)$. ■

11.3 Примеры вычисления информации Фишера**Ex. (Нормальное распределение $\mathcal{N}(\mu, \sigma^2)$, σ^2 известна)**

$$\begin{aligned} \ln f(x; \mu) &= -\frac{1}{2} \ln(2\pi\sigma^2) - \frac{(x - \mu)^2}{2\sigma^2} \\ s(x; \mu) &= \frac{\partial}{\partial \mu} \ln f = \frac{x - \mu}{\sigma^2} \\ I(\mu) &= \mathbb{E} \left[\frac{(X - \mu)^2}{\sigma^4} \right] = \frac{\sigma^2}{\sigma^4} = \boxed{\frac{1}{\sigma^2}} \end{aligned}$$

Ex. (Нормальное распределение $\mathcal{N}(\mu, \sigma^2)$, μ известно)

$$\begin{aligned} \ln f(x; \sigma^2) &= -\frac{1}{2} \ln(2\pi) - \frac{1}{2} \ln \sigma^2 - \frac{(x - \mu)^2}{2\sigma^2} \\ \frac{\partial \ln f}{\partial \sigma^2} &= -\frac{1}{2\sigma^2} + \frac{(x - \mu)^2}{2\sigma^4} \\ \frac{\partial^2 \ln f}{\partial (\sigma^2)^2} &= \frac{1}{2\sigma^4} - \frac{(x - \mu)^2}{\sigma^6} \\ I(\sigma^2) &= -\mathbb{E} \left[\frac{1}{2\sigma^4} - \frac{(X - \mu)^2}{\sigma^6} \right] = -\frac{1}{2\sigma^4} + \frac{\sigma^2}{\sigma^6} = \boxed{\frac{1}{2\sigma^4}} \end{aligned}$$

Ex. (Бернулли $Bernoulli(p)$)

$$\begin{aligned} \ln f(x; p) &= x \ln p + (1 - x) \ln(1 - p) \\ s(x; p) &= \frac{x}{p} - \frac{1 - x}{1 - p} = \frac{x - p}{p(1 - p)} \\ I(p) &= \mathbb{E} \left[\frac{(X - p)^2}{p^2(1 - p)^2} \right] = \frac{p(1 - p)}{p^2(1 - p)^2} = \boxed{\frac{1}{p(1 - p)}} \end{aligned}$$

Ex. (Пуассон $\text{Poisson}(\lambda)$)

$$\ln f(k; \lambda) = k \ln \lambda - \lambda - \ln(k!)$$

$$\frac{\partial^2 \ln f}{\partial \lambda^2} = -\frac{k}{\lambda^2}$$

$$I(\lambda) = -\mathbb{E}\left[-\frac{X}{\lambda^2}\right] = \frac{\mathbb{E}[X]}{\lambda^2} = \boxed{\frac{1}{\lambda}}$$

11.4 Многомерный случай**Def. (Матрица информации Фишера)**

Для $\theta = (\theta_1, \dots, \theta_d) \in \Theta \subseteq \mathbb{R}^d$ **матрица информации Фишера**:

$$I(\theta)_{jk} = \mathbb{E}_\theta \left[\frac{\partial \ln f}{\partial \theta_j} \cdot \frac{\partial \ln f}{\partial \theta_k} \right] = -\mathbb{E}_\theta \left[\frac{\partial^2 \ln f}{\partial \theta_j \partial \theta_k} \right]$$

В матричной форме:

$$I(\theta) = \mathbb{E}[\nabla_\theta \ln f \cdot (\nabla_\theta \ln f)^\top] = -\mathbb{E}[\nabla_\theta^2 \ln f]$$

12 Неравенство Рао—Крамера**12.1 Формулировка**

Неравенство Рао—Крамера (также: неравенство Крамера—Рао, информационное неравенство) устанавливает нижнюю границу для дисперсии несмешённых оценок.

Th. (Неравенство Рао—Крамера)

Пусть выполнены условия регулярности, $\hat{\theta}_n$ — несмешённая оценка θ . Тогда:

$$\mathbb{D}_\theta[\hat{\theta}_n] \geq \frac{1}{I_n(\theta)} = \frac{1}{n \cdot I(\theta)}$$

Величина $\frac{1}{n I(\theta)}$ называется **границей Рао—Крамера**.

Proof.

Рассмотрим выборку X_1, \dots, X_n с совместной плотностью:

$$f_n(\mathbf{x}; \theta) = \prod_{i=1}^n f(x_i; \theta)$$

Обозначим:

$$S_n(\theta) = \frac{\partial}{\partial \theta} \ln f_n(\mathbf{X}; \theta) = \sum_{i=1}^n s(X_i; \theta)$$

Шаг 1. Заметим, что $\mathbb{E}[S_n(\theta)] = 0$ и $\mathbb{D}[S_n(\theta)] = I_n(\theta) = nI(\theta)$.

Шаг 2. Из несмешённости $\hat{\theta}_n$:

$$\mathbb{E}_{\theta}[\hat{\theta}_n] = \int \hat{\theta}_n(\mathbf{x}) f_n(\mathbf{x}; \theta) d\mathbf{x} = \theta$$

Дифференцируем по θ (используя условия регулярности):

$$1 = \int \hat{\theta}_n(\mathbf{x}) \frac{\partial f_n}{\partial \theta} d\mathbf{x} = \int \hat{\theta}_n(\mathbf{x}) \cdot S_n(\theta) \cdot f_n(\mathbf{x}; \theta) d\mathbf{x} = \mathbb{E}[\hat{\theta}_n \cdot S_n(\theta)]$$

Шаг 3. Так как $\mathbb{E}[S_n] = 0$:

$$\text{Cov}(\hat{\theta}_n, S_n) = \mathbb{E}[\hat{\theta}_n \cdot S_n] - \mathbb{E}[\hat{\theta}_n] \cdot \mathbb{E}[S_n] = 1 - \theta \cdot 0 = 1$$

Шаг 4. По неравенству Коши—Буняковского:

$$\begin{aligned} |\text{Cov}(\hat{\theta}_n, S_n)|^2 &\leq \mathbb{D}[\hat{\theta}_n] \cdot \mathbb{D}[S_n] \\ 1 &\leq \mathbb{D}[\hat{\theta}_n] \cdot I_n(\theta) \end{aligned}$$

Следовательно:

$$\mathbb{D}[\hat{\theta}_n] \geq \frac{1}{I_n(\theta)} = \frac{1}{nI(\theta)}$$

■

12.2 Эффективные оценки

Def. (Эффективная оценка)

Несмешённая оценка $\hat{\theta}_n^*$ называется **эффективной**, если она достигает границы Рао—Крамера:

$$\mathbb{D}_{\theta}[\hat{\theta}_n^*] = \frac{1}{nI(\theta)}$$

Th. (Критерий эффективности)

Несмешённая оценка $\hat{\theta}_n$ эффективна тогда и только тогда, когда:

$$\hat{\theta}_n = \theta + \frac{S_n(\theta)}{I_n(\theta)}$$

или эквивалентно: $\hat{\theta}_n$ линейно зависит от score-функции $S_n(\theta)$.

Proof.

Равенство в неравенстве Коши—Буняковского достигается тогда и только тогда, когда $\hat{\theta}_n$ и S_n линейно зависимы:

$$\hat{\theta}_n - \mathbb{E}[\hat{\theta}_n] = c \cdot (S_n - \mathbb{E}[S_n]) = c \cdot S_n$$

для некоторой константы c .

Из условия $\text{Cov}(\hat{\theta}_n, S_n) = 1$:

$$c \cdot \mathbb{D}[S_n] = c \cdot I_n(\theta) = 1 \implies c = \frac{1}{I_n(\theta)}$$

Следовательно: $\hat{\theta}_n = \theta + \frac{S_n(\theta)}{I_n(\theta)}$. ■

Th. (Существование эффективных оценок)

Эффективная оценка существует тогда и только тогда, когда score-функция имеет вид:

$$S_n(\theta) = I_n(\theta) \cdot (T(\mathbf{X}) - \theta)$$

для некоторой статистики $T(\mathbf{X})$.

В этом случае $\hat{\theta}_n^* = T(\mathbf{X})$ — эффективная оценка.

Ex. (Эффективность выборочного среднего для нормального распределения)

Для $X_i \sim \mathcal{N}(\mu, \sigma^2)$:

$$S_n(\mu) = \sum_{i=1}^n \frac{X_i - \mu}{\sigma^2} = \frac{n(\bar{X}_n - \mu)}{\sigma^2} = I_n(\mu) \cdot (\bar{X}_n - \mu)$$

Следовательно, \bar{X}_n — эффективная оценка μ .

Проверка: $\mathbb{D}[\bar{X}_n] = \frac{\sigma^2}{n} = \frac{1}{n \cdot \frac{1}{\sigma^2}} = \frac{1}{n I(\mu)}$ ✓

12.3 Обобщения неравенства Рао—Крамера**Th. (Неравенство для смещённых оценок)**

Если $\mathbb{E}_{\theta}[\hat{\theta}_n] = g(\theta)$ (оценка со смещением), то:

$$\mathbb{D}_{\theta}[\hat{\theta}_n] \geq \frac{[g'(\theta)]^2}{I_n(\theta)}$$

Th. (Неравенство для функций параметра)

Пусть $\tau = \tau(\theta)$ — функция параметра, $\hat{\tau}_n$ — несмешённая оценка τ . Тогда:

$$\mathbb{D}_{\theta}[\hat{\tau}_n] \geq \frac{[\tau'(\theta)]^2}{I_n(\theta)}$$

Th. (Многомерное неравенство Рао—Крамера)

Для $\theta \in \mathbb{R}^d$ и несмешённой оценки $\hat{\theta}_n$:

$$\text{Cov}(\hat{\theta}_n) \geq I_n(\theta)^{-1}$$

в смысле неотрицательной определённости разности матриц.

13 Свойства оценок максимального правдоподобия

13.1 Основные результаты

ОМП обладают рядом замечательных асимптотических свойств, делающих их универсальным инструментом статистического оценивания.

Th. (Состоятельность ОМП)

При условиях регулярности ОМП состоятельна:

$$\hat{\theta}_n^{MLE} \xrightarrow{\mathbb{P}} \theta_0$$

где θ_0 — истинное значение параметра.

Proof. (Идея доказательства)

Рассмотрим нормированный логарифм правдоподобия:

$$\frac{1}{n} \ell(\theta) = \frac{1}{n} \sum_{i=1}^n \ln f(X_i; \theta)$$

По ЗБЧ:

$$\frac{1}{n} \ell(\theta) \xrightarrow{\mathbb{P}} \mathbb{E}_{\theta_0} [\ln f(X; \theta)] =: M(\theta)$$

Ключевой факт: $M(\theta)$ достигает максимума в точке $\theta = \theta_0$ (это следует из неравенства Йенсена и свойств KL-дивергенции).

По теореме о сходимости точек максимума:

$$\hat{\theta}_n^{MLE} = \arg \max \frac{1}{n} \ell(\theta) \xrightarrow{\mathbb{P}} \arg \max M(\theta) = \theta_0$$



Th. (Асимптотическая нормальность ОМП)

При условиях регулярности:

$$\sqrt{n}(\hat{\theta}_n^{MLE} - \theta_0) \xrightarrow{d} \mathcal{N}(0, I(\theta_0)^{-1})$$

Proof. (Идея доказательства)

Разложим score-функцию в ряд Тейлора около θ_0 :

$$S_n(\hat{\theta}_n) = S_n(\theta_0) + S'_n(\theta^*)(\hat{\theta}_n - \theta_0)$$

для некоторого θ^* между θ_0 и $\hat{\theta}_n$.

Так как $\hat{\theta}_n$ — точка максимума, $S_n(\hat{\theta}_n) = 0$:

$$0 = S_n(\theta_0) + S'_n(\theta^*)(\hat{\theta}_n - \theta_0)$$

Следовательно:

$$\sqrt{n}(\hat{\theta}_n - \theta_0) = -\frac{\frac{1}{\sqrt{n}}S_n(\theta_0)}{\frac{1}{n}S'_n(\theta^*)}$$

Числитель: По ЦПТ:

$$\frac{1}{\sqrt{n}}S_n(\theta_0) = \frac{1}{\sqrt{n}} \sum_{i=1}^n s(X_i; \theta_0) \xrightarrow{d} \mathcal{N}(0, I(\theta_0))$$

Знаменатель: По ЗБЧ:

$$\frac{1}{n}S'_n(\theta^*) = \frac{1}{n} \sum_{i=1}^n \frac{\partial^2 \ln f(X_i; \theta^*)}{\partial \theta^2} \xrightarrow{\mathbb{P}} -I(\theta_0)$$

По теореме Слуцкого:

$$\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{d} \frac{\mathcal{N}(0, I(\theta_0))}{I(\theta_0)} = \mathcal{N}(0, I(\theta_0)^{-1})$$

■

Th. (Асимптотическая эффективность ОМП)

ОМП асимптотически эффективна: её асимптотическая дисперсия $I(\theta)^{-1}$ совпадает с границей Рао—Крамера.

13.2 Дополнительные свойства ОМП

Th. (Инвариантность ОМП)

Если $\hat{\theta}^{MLE}$ — ОМП для θ , то для любой функции g :

$$\widehat{g(\theta)}^{MLE} = g(\hat{\theta}^{MLE})$$

Th. (Асимптотическая нормальность для функций параметра)

Пусть $\tau = g(\theta)$, g дифференцируема, $g'(\theta) \neq 0$. Тогда:

$$\sqrt{n}(g(\hat{\theta}_n^{MLE}) - g(\theta_0)) \xrightarrow{d} \mathcal{N}\left(0, \frac{[g'(\theta_0)]^2}{I(\theta_0)}\right)$$

Th. (Многомерный случай)

Для $\theta \in \mathbb{R}^d$:

$$\sqrt{n}(\hat{\theta}_n^{MLE} - \theta_0) \xrightarrow{d} \mathcal{N}(\mathbf{0}, I(\theta_0)^{-1})$$

где $I(\theta)$ — матрица информации Фишера.

13.3 Асимптотическое смещение ОМП

NB.

ОМП в общем случае **смещена** в конечных выборках. Однако смещение имеет порядок $O(1/n)$:

$$\mathbb{E}[\hat{\theta}_n^{MLE}] = \theta + \frac{b(\theta)}{n} + O(n^{-2})$$

для некоторой функции $b(\theta)$.

Можно построить **исправленную** ОМП:

$$\tilde{\theta}_n = \hat{\theta}_n^{MLE} - \frac{b(\hat{\theta}_n^{MLE})}{n}$$

которая будет асимптотически несмешённой с точностью $O(n^{-2})$.

13.4 Сравнение ОМП и метода моментов

Свойство	ОМП	Метод моментов
Состоятельность	Да	Да
Асимптотическая нормальность	Да	Да
Асимптотическая эффективность	Да	Не всегда
Инвариантность	Да	Нет
Простота вычисления	Может быть сложно	Обычно просто
Существование в замкнутой форме	Не всегда	Обычно да

14 Байесовские оценки

14.1 Байесовский подход к статистике

В байесовском подходе параметр θ рассматривается как **случайная величина** с некоторым **априорным распределением**.

Def. (Байесовская модель)

Байесовская статистическая модель задаётся:

1. **Априорное распределение** $\pi(\theta)$ — плотность распределения θ до наблюдения данных
2. **Условное распределение данных** $f(\mathbf{x}|\theta)$ — функция правдоподобия

Th. (Формула Байеса)

Апостериорное распределение θ при данных $\mathbf{X} = \mathbf{x}$:

$$\pi(\theta|\mathbf{x}) = \frac{f(\mathbf{x}|\theta) \cdot \pi(\theta)}{\int f(\mathbf{x}|\theta') \pi(\theta') d\theta'} \propto f(\mathbf{x}|\theta) \cdot \pi(\theta)$$

Словами: Апостериорное \propto Правдоподобие \times Априорное.

14.2 Функция потерь и байесовский риск

Def. (Функция потерь)

Функция потерь $L(\theta, a)$ измеряет «штраф» за принятие решения a , когда истинный параметр равен θ .

Популярные функции потерь:

- **Квадратичная:** $L(\theta, a) = (\theta - a)^2$
- **Абсолютная:** $L(\theta, a) = |\theta - a|$
- **0-1 потери:** $L(\theta, a) = \mathbf{1}_{\theta \neq a}$

Def. (Байесовский риск)

Апостериорный риск оценки $\hat{\theta}$:

$$\rho(\hat{\theta}|\mathbf{x}) = \mathbb{E}[L(\theta, \hat{\theta})|\mathbf{X} = \mathbf{x}] = \int L(\theta, \hat{\theta}) \pi(\theta|\mathbf{x}) d\theta$$

Байесовский риск (усреднённый по данным):

$$r(\pi, \hat{\theta}) = \mathbb{E}_{\mathbf{X}}[\rho(\hat{\theta}|\mathbf{X})] = \mathbb{E}_{\theta, \mathbf{X}}[L(\theta, \hat{\theta})]$$

Def. (Байесовская оценка)

Байесовская оценка — оценка, минимизирующая апостериорный риск:

$$\hat{\theta}^{Bayes} = \arg \min_a \mathbb{E}[L(\theta, a) | \mathbf{X}]$$

14.3 Байесовские оценки для различных функций потерь

Th. (Байесовские оценки)

(i) Квадратичные потери $L(\theta, a) = (\theta - a)^2$:

$$\hat{\theta}^{Bayes} = \mathbb{E}[\theta | \mathbf{X}] = \int \theta \cdot \pi(\theta | \mathbf{x}) d\theta$$

— апостериорное среднее

(ii) Абсолютные потери $L(\theta, a) = |\theta - a|$:

$$\hat{\theta}^{Bayes} = \text{Med}[\theta | \mathbf{X}]$$

— апостериорная медиана

(iii) 0-1 потери:

$$\hat{\theta}^{Bayes} = \text{Mode}[\theta | \mathbf{X}] = \arg \max_{\theta} \pi(\theta | \mathbf{x})$$

— апостериорная мода (MAP-оценка)

Proof. (Доказательство для квадратичных потерь)

Минимизируем:

$$\rho(a | \mathbf{x}) = \mathbb{E}[(\theta - a)^2 | \mathbf{X} = \mathbf{x}]$$

Дифференцируем по a :

$$\frac{\partial \rho}{\partial a} = -2 \mathbb{E}[\theta - a | \mathbf{X}] = -2(\mathbb{E}[\theta | \mathbf{X}] - a) = 0$$

Следовательно: $a = \mathbb{E}[\theta | \mathbf{X}]$. ■

14.4 Примеры байесовских оценок

Ex. (Нормальная модель с нормальным априорным)

Пусть $X_1, \dots, X_n | \mu \sim \mathcal{N}(\mu, \sigma^2)$ (дисперсия σ^2 известна).

Априорное распределение: $\mu \sim \mathcal{N}(\mu_0, \tau^2)$.

Апостериорное распределение:

$$\mu|X_1, \dots, X_n \sim \mathcal{N} \left(\frac{\frac{\mu_0}{\tau^2} + \frac{n\bar{X}_n}{\sigma^2}}{\frac{1}{\tau^2} + \frac{n}{\sigma^2}}, \frac{1}{\frac{1}{\tau^2} + \frac{n}{\sigma^2}} \right)$$

Байесовская оценка (апостериорное среднее):

$$\hat{\mu}^{Bayes} = \frac{\frac{1}{\tau^2}}{\frac{1}{\tau^2} + \frac{n}{\sigma^2}} \cdot \mu_0 + \frac{\frac{n}{\sigma^2}}{\frac{1}{\tau^2} + \frac{n}{\sigma^2}} \cdot \bar{X}_n = w \cdot \mu_0 + (1 - w) \cdot \bar{X}_n$$

Это **взвешенное среднее** априорного среднего μ_0 и выборочного среднего \bar{X}_n .

При $n \rightarrow \infty$: $\hat{\mu}^{Bayes} \rightarrow \bar{X}_n$ (влияние априорного распределения исчезает).

Ex. (Бернулли с бета-априорным)

Пусть $X_1, \dots, X_n | p \sim \text{Bernoulli}(p)$.

Априорное: $p \sim \text{Beta}(\alpha, \beta)$.

Апостериорное: $p|X_1, \dots, X_n \sim \text{Beta}(\alpha + S_n, \beta + n - S_n)$, где $S_n = \sum X_i$.

Байесовская оценка:

$$\hat{p}^{Bayes} = \frac{\alpha + S_n}{\alpha + \beta + n}$$

Это сглаживание Лапласа: добавляем α «успехов» и β «неудач» к данным.

14.5 Свойства байесовских оценок

Th. (Асимптотическое поведение)

При $n \rightarrow \infty$ и регулярных условиях:

(i) Апостериорное распределение сосредотачивается около истинного θ_0

(ii) Байесовская оценка состоятельна: $\hat{\theta}^{Bayes} \xrightarrow{\mathbb{P}} \theta_0$

(iii) Апостериорное распределение асимптотически нормально:

$$\theta|\mathbf{X} \approx \mathcal{N} \left(\hat{\theta}^{MLE}, \frac{1}{nI(\theta_0)} \right)$$

(iv) $\hat{\theta}^{Bayes} - \hat{\theta}^{MLE} = O_p(n^{-1})$

NB. (Преимущества байесовского подхода)

- Естественное включение априорной информации
- Полное апостериорное распределение (не только точечная оценка)

- Автоматическая регуляризация через априорное распределение
- Когерентный подход к принятию решений

15 Минимаксные оценки

15.1 Мотивация

Минимаксный подход — «пессимистическая» стратегия: минимизируем максимальный возможный риск по всем значениям параметра.

15.2 Функция риска

Def. (Функция риска)

Функция риска оценки $\hat{\theta}$ при параметре θ :

$$R(\theta, \hat{\theta}) = \mathbb{E}_\theta[L(\theta, \hat{\theta})]$$

Для квадратичных потерь: $R(\theta, \hat{\theta}) = \text{MSE}_\theta(\hat{\theta}) = \mathbb{D}_\theta[\hat{\theta}] + (\text{bias})^2$.

NB.

Нельзя минимизировать $R(\theta, \hat{\theta})$ одновременно для всех θ — разные оценки оптимальны при разных θ .

15.3 Минимаксные оценки

Def. (Минимаксная оценка)

Оценка $\hat{\theta}^{minimax}$ называется **минимаксной**, если:

$$\sup_{\theta \in \Theta} R(\theta, \hat{\theta}^{minimax}) = \inf_{\hat{\theta}} \sup_{\theta \in \Theta} R(\theta, \hat{\theta})$$

Словами: минимизируем максимальный риск.

Def. (Минимаксный риск)

Минимаксный риск:

$$R^* = \inf_{\hat{\theta}} \sup_{\theta \in \Theta} R(\theta, \hat{\theta})$$

15.4 Связь с байесовскими оценками

Th. (Характеризация минимаксных оценок)

Пусть $\hat{\theta}^\pi$ — байесовская оценка относительно априорного распределения π . Если функция риска $R(\theta, \hat{\theta}^\pi)$ постоянна по θ :

$$R(\theta, \hat{\theta}^\pi) = c \quad \text{для всех } \theta \in \Theta$$

то $\hat{\theta}^\pi$ — минимаксная оценка, а π — **наименее благоприятное априорное распределение**.

Proof.

Для любой другой оценки $\tilde{\theta}$:

$$\sup_{\theta} R(\theta, \tilde{\theta}) \geq \int R(\theta, \tilde{\theta}) \pi(\theta) d\theta \geq \int R(\theta, \hat{\theta}^\pi) \pi(\theta) d\theta = c = \sup_{\theta} R(\theta, \hat{\theta}^\pi)$$

Первое неравенство — $\sup \geq$ среднее. Второе — $\hat{\theta}^\pi$ минимизирует байесовский риск. ■

Th. (Теорема о седловой точке)

Если существует априорное распределение π^* такое, что:

$$\sup_{\theta} R(\theta, \hat{\theta}^{\pi^*}) = \inf_{\hat{\theta}} \sup_{\theta} R(\theta, \hat{\theta}) = \sup_{\pi} \inf_{\hat{\theta}} r(\pi, \hat{\theta})$$

то $(\hat{\theta}^{\pi^*}, \pi^*)$ образуют **седловую точку** и $\hat{\theta}^{\pi^*}$ — минимаксная оценка.

15.5 Примеры минимаксных оценок

Ex. (Оценивание вероятности успеха)

Пусть $X \sim \text{Binomial}(n, p)$, $p \in [0, 1]$.

Для квадратичных потерь $L(p, a) = (p - a)^2$ минимаксная оценка:

$$\hat{p}^{\text{minimax}} = \frac{X + \frac{\sqrt{n}}{2}}{n + \sqrt{n}}$$

Это байесовская оценка относительно $\text{Beta}(\sqrt{n}/2, \sqrt{n}/2)$.

Сравнение:

- ОМП: $\hat{p}^{\text{MLE}} = X/n$
- Минимаксная: сдвигает оценку к 1/2

Ex. (Оценивание среднего нормального распределения)

Пусть $X_1, \dots, X_n \sim \mathcal{N}(\mu, \sigma^2)$, $\mu \in \mathbb{R}$, σ^2 известна.

Для квадратичных потерь минимаксная оценка:

$$\hat{\mu}^{minimax} = \bar{X}_n$$

Выборочное среднее минимаксно (и одновременно является ОМП и байесовской оценкой для неинформативного априорного).

Ex. (Оценка Стейна (James—Stein))

Пусть $X \sim \mathcal{N}_d(\theta, I_d)$, $d \geq 3$.

Оценка Стейна:

$$\hat{\theta}^{JS} = \left(1 - \frac{d-2}{\|X\|^2}\right) X$$

Эта оценка **доминирует** обычную оценку X (т.е. имеет меньший риск для всех θ).

Это означает, что X — **недопустимая** оценка при $d \geq 3$ (парадокс Стейна).

15.6 Допустимость

Def. (Допустимость)

Оценка $\hat{\theta}$ **допустима**, если не существует другой оценки $\tilde{\theta}$, доминирующей её:

$$\nexists \tilde{\theta} : R(\theta, \tilde{\theta}) \leq R(\theta, \hat{\theta}) \quad \forall \theta, \quad R(\theta_0, \tilde{\theta}) < R(\theta_0, \hat{\theta}) \text{ для некоторого } \theta_0$$

Th. (Допустимость байесовских оценок)

Единственная байесовская оценка (при строго положительном априорном) допустима.

Th. (Связь минимакса и допустимости)

Единственная минимаксная оценка с постоянным риском допустима.

15.7 Сводка подходов к оцениванию

Подход	Критерий оптимальности
ОМП	Максимизация правдоподобия $L(\theta)$
Метод моментов	Приравнивание теоретических и выборочных моментов
Несмешённая эффективная	Минимальная дисперсия среди несмешённых (граница Р-К)
Байесовская	Минимизация апостериорного риска $\mathbb{E}[L(\theta, a) \mathbf{X}]$
Минимаксная	Минимизация максимального риска $\sup_{\theta} R(\theta, \hat{\theta})$

16 Доверительные интервалы

16.1 Определение и мотивация

Точечная оценка $\hat{\theta}_n$ даёт одно значение, но не показывает точность оценки. Доверительный интервал даёт диапазон «правдоподобных» значений параметра.

Def. (Доверительный интервал)

Доверительным интервалом уровня доверия $1 - \alpha$ (или уровня значимости α) для параметра θ называется случайный интервал $[\hat{\theta}_L, \hat{\theta}_U]$, где $\hat{\theta}_L = \hat{\theta}_L(X_1, \dots, X_n)$ и $\hat{\theta}_U = \hat{\theta}_U(X_1, \dots, X_n)$ — статистики, такие что:

$$\mathbb{P}_{\theta}(\hat{\theta}_L \leq \theta \leq \hat{\theta}_U) \geq 1 - \alpha \quad \text{для всех } \theta \in \Theta$$

Типичные значения: $1 - \alpha = 0.95$ (95%) или $1 - \alpha = 0.99$ (99%).

NB. (Интерпретация)

Важно: После вычисления конкретного интервала $[l, u]$ **нельзя** говорить « θ лежит в $[l, u]$ с вероятностью $1 - \alpha$ ». Параметр θ — фиксированная константа!

Правильная интерпретация: если повторить эксперимент много раз, то примерно $(1 - \alpha) \cdot 100\%$ построенных интервалов будут содержать истинное θ .

Def. (Виды доверительных интервалов)

- **Двусторонний:** $[\hat{\theta}_L, \hat{\theta}_U]$
- **Односторонний снизу:** $[\hat{\theta}_L, +\infty)$, $\mathbb{P}(\theta \geq \hat{\theta}_L) \geq 1 - \alpha$
- **Односторонний сверху:** $(-\infty, \hat{\theta}_U]$, $\mathbb{P}(\theta \leq \hat{\theta}_U) \geq 1 - \alpha$

16.2 Общая схема построения доверительного интервала

Основная идея: Найти центральную статистику (pivot) — функцию $G(X_1, \dots, X_n; \theta)$, распределение которой известно и не зависит от θ .

Def. (Центральная статистика (pivot))

Статистика $G(\mathbf{X}; \theta)$ называется центральной (или опорной, pivot), если её распределение не зависит от неизвестных параметров.

Алгоритм построения ДИ:

Шаг 1. Найти центральную статистику $G(\mathbf{X}; \theta)$ с известным распределением.

Шаг 2. Найти квантили $g_{\alpha/2}$ и $g_{1-\alpha/2}$ такие, что:

$$\mathbb{P}(g_{\alpha/2} \leq G(\mathbf{X}; \theta) \leq g_{1-\alpha/2}) = 1 - \alpha$$

Шаг 3. Разрешить неравенство относительно θ :

$$g_{\alpha/2} \leq G(\mathbf{X}; \theta) \leq g_{1-\alpha/2} \iff \hat{\theta}_L \leq \theta \leq \hat{\theta}_U$$

Ex. (Центральная статистика для среднего нормального)

Пусть $X_i \sim \mathcal{N}(\mu, \sigma^2)$, σ^2 известна.

Центральная статистика:

$$G = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1)$$

Распределение G не зависит от μ — это pivot.

16.3 «Универсальный» рецепт

Для асимптотически нормальных оценок существует универсальный подход.

Th. (Универсальный рецепт для асимптотического ДИ)

Пусть $\hat{\theta}_n$ — состоятельная и асимптотически нормальная оценка:

$$\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{d} \mathcal{N}(0, \sigma^2(\theta))$$

Если $\hat{\sigma}_n^2$ — состоятельная оценка $\sigma^2(\theta)$, то асимптотический $(1 - \alpha)$ -доверительный интервал:

$$\left[\hat{\theta}_n - z_{1-\alpha/2} \cdot \frac{\hat{\sigma}_n}{\sqrt{n}}, \quad \hat{\theta}_n + z_{1-\alpha/2} \cdot \frac{\hat{\sigma}_n}{\sqrt{n}} \right]$$

где $z_{1-\alpha/2}$ — квантиль уровня $1 - \alpha/2$ стандартного нормального распределения.

Частные случаи $z_{1-\alpha/2}$:

$1 - \alpha$	90%	95%	99%
$z_{1-\alpha/2}$	1.645	1.96	2.576

16.4 Связь доверительных интервалов и проверки гипотез

Th. (Дуальность ДИ и тестов)

Пусть $C_\alpha(\mathbf{X})$ — $(1 - \alpha)$ -доверительный интервал для θ . Тогда тест:

$$\text{Отвергнуть } H_0 : \theta = \theta_0 \iff \theta_0 \notin C_\alpha(\mathbf{X})$$

имеет уровень значимости α .

Обратно: если тест уровня α не отвергает $H_0 : \theta = \theta_0$, то $\theta_0 \in C_\alpha(\mathbf{X})$.

17 Теорема Фишера. Распределение хи-квадрат

17.1 Распределение хи-квадрат

Def. (Распределение хи-квадрат)

Пусть $Z_1, \dots, Z_k \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, 1)$. Тогда:

$$\chi_k^2 = Z_1^2 + Z_2^2 + \dots + Z_k^2 \sim \chi^2(k)$$

имеет **распределение хи-квадрат с k степенями свободы**.

Свойства $\chi^2(k)$:

- Плотность: $f(x) = \frac{1}{2^{k/2}\Gamma(k/2)}x^{k/2-1}e^{-x/2}$, $x > 0$
- $\mathbb{E}[\chi_k^2] = k$
- $\mathbb{D}[\chi_k^2] = 2k$
- $\chi_{k_1}^2 + \chi_{k_2}^2 \sim \chi^2(k_1 + k_2)$ (при независимости)
- При $k \rightarrow \infty$: $\frac{\chi_k^2 - k}{\sqrt{2k}} \xrightarrow{d} \mathcal{N}(0, 1)$

Lm. (Связь с гамма-распределением)

$$\chi^2(k) = \Gamma\left(\frac{k}{2}, \frac{1}{2}\right)$$

17.2 Вспомогательные леммы

Lm. (О квадратичной форме)

Пусть $\mathbf{Z} \sim \mathcal{N}(\mathbf{0}, I_n)$ и A — симметричная идемпотентная матрица ($A^2 = A$) ранга r . Тогда:

$$\mathbf{Z}^\top A \mathbf{Z} \sim \chi^2(r)$$

Proof. (Идея доказательства)

Так как A симметрична и идемпотентна, её собственные значения — только 0 и 1. Ранг r означает, что ровно r собственных значений равны 1.

Существует ортогональная матрица P такая, что $A = P \text{diag}(1, \dots, 1, 0, \dots, 0) P^\top$.

Пусть $\mathbf{Y} = P^\top \mathbf{Z}$. Тогда $\mathbf{Y} \sim \mathcal{N}(\mathbf{0}, I_n)$ и:

$$\mathbf{Z}^\top A \mathbf{Z} = \mathbf{Y}^\top \text{diag}(1, \dots, 1, 0, \dots, 0) \mathbf{Y} = Y_1^2 + \dots + Y_r^2 \sim \chi^2(r)$$

■

Lm. (Теорема Кохрана)

Пусть $\mathbf{Z} \sim \mathcal{N}(\mathbf{0}, I_n)$ и $\|\mathbf{Z}\|^2 = Q_1 + Q_2 + \dots + Q_k$, где $Q_i = \mathbf{Z}^\top A_i \mathbf{Z}$ — квадратичные формы с рангами r_i и $\sum r_i = n$.

Тогда Q_1, \dots, Q_k независимы и $Q_i \sim \chi^2(r_i)$.

17.3 Теорема Фишера**Th. (Теорема Фишера)**

Пусть $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(\mu, \sigma^2)$. Тогда:

(i) $\bar{X}_n \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$

(ii) $\frac{(n-1)S^2}{\sigma^2} = \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X}_n)^2 \sim \chi^2(n-1)$

(iii) \bar{X}_n и S^2 независимы

Proof.

Введём стандартизованные величины $Z_i = \frac{X_i - \mu}{\sigma} \sim \mathcal{N}(0, 1)$, i.i.d.

Запишем:

$$\sum_{i=1}^n Z_i^2 = \sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma} \right)^2 = \sum_{i=1}^n \left(\frac{X_i - \bar{X}_n}{\sigma} + \frac{\bar{X}_n - \mu}{\sigma} \right)^2$$

Раскрывая:

$$\sum_{i=1}^n Z_i^2 = \sum_{i=1}^n \frac{(X_i - \bar{X}_n)^2}{\sigma^2} + n \cdot \frac{(\bar{X}_n - \mu)^2}{\sigma^2}$$

(перекрёстный член равен нулю, так как $\sum(X_i - \bar{X}_n) = 0$).

Обозначим:

$$Q_1 = \frac{(n-1)S^2}{\sigma^2}, \quad Q_2 = \frac{n(\bar{X}_n - \mu)^2}{\sigma^2} = \left(\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \right)^2$$

Имеем:

$$\underbrace{\sum_{i=1}^n Z_i^2}_{\chi^2(n)} = Q_1 + Q_2$$

$Q_2 \sim \chi^2(1)$ (квадрат стандартной нормальной).

По теореме Кохрана (или прямой проверке): Q_1 и Q_2 независимы и $Q_1 \sim \chi^2(n-1)$.

Независимость Q_1 и Q_2 влечёт независимость S^2 и \bar{X}_n . ■

NB.

Почему $n-1$ степеней свободы? Потому что $\sum(X_i - \bar{X}_n) = 0$ — одно линейное ограничение, и только $n-1$ отклонений независимы.

18 Распределения Фишера и Стьюдента. ДИ для нормального закона

18.1 Распределение Стьюдента

Def. (Распределение Стьюдента)

Пусть $Z \sim \mathcal{N}(0, 1)$ и $V \sim \chi^2(k)$ независимы. Тогда:

$$T = \frac{Z}{\sqrt{V/k}} \sim t(k)$$

имеет **распределение Стьюдента** с k степенями свободы.

Свойства $t(k)$:

- Симметрично относительно нуля
- $\mathbb{E}[T] = 0$ при $k > 1$
- $\mathbb{D}[T] = \frac{k}{k-2}$ при $k > 2$
- Более тяжёлые хвосты, чем у $\mathcal{N}(0, 1)$
- При $k \rightarrow \infty$: $t(k) \rightarrow \mathcal{N}(0, 1)$
- $t(1) = \text{Cauchy}(0, 1)$ (распределение Коши)

Th. (Стьюдентизация)

Пусть $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(\mu, \sigma^2)$. Тогда:

$$T = \frac{\bar{X}_n - \mu}{S/\sqrt{n}} \sim t(n-1)$$

Proof.

$$T = \frac{\bar{X}_n - \mu}{S/\sqrt{n}} = \frac{(\bar{X}_n - \mu)/(\sigma/\sqrt{n})}{S/\sigma} = \frac{Z}{\sqrt{V/(n-1)}}$$

где $Z = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1)$ и $V = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$.

По теореме Фишера Z и V независимы, поэтому $T \sim t(n-1)$. ■

18.2 Распределение Фишера (F-распределение)

Def. (Распределение Фишера)

Пусть $U \sim \chi^2(m)$ и $V \sim \chi^2(n)$ независимы. Тогда:

$$F = \frac{U/m}{V/n} \sim F(m, n)$$

имеет **распределение Фишера с (m, n) степенями свободы**.

Свойства $F(m, n)$:

- $F > 0$
- $\mathbb{E}[F] = \frac{n}{n-2}$ при $n > 2$
- Если $F \sim F(m, n)$, то $1/F \sim F(n, m)$
- Если $T \sim t(n)$, то $T^2 \sim F(1, n)$
- При $m, n \rightarrow \infty$: $F(m, n) \rightarrow 1$

18.3 Доверительные интервалы для параметров нормального закона

Пусть $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(\mu, \sigma^2)$.

18.3.1 ДИ для μ при известной σ^2

Центральная статистика: $Z = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1)$.

$$\mathbb{P} \left(-z_{1-\alpha/2} \leq \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \leq z_{1-\alpha/2} \right) = 1 - \alpha$$

Доверительный интервал:

$$\mu \in \left[\bar{X}_n - z_{1-\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}, \quad \bar{X}_n + z_{1-\alpha/2} \cdot \frac{\sigma}{\sqrt{n}} \right]$$

18.3.2 ДИ для μ при неизвестной σ^2

Центральная статистика: $T = \frac{\bar{X}_n - \mu}{S/\sqrt{n}} \sim t(n-1)$.

Доверительный интервал:

$$\mu \in \left[\bar{X}_n - t_{n-1,1-\alpha/2} \cdot \frac{S}{\sqrt{n}}, \quad \bar{X}_n + t_{n-1,1-\alpha/2} \cdot \frac{S}{\sqrt{n}} \right]$$

где $t_{n-1,1-\alpha/2}$ — квантиль уровня $1 - \alpha/2$ распределения $t(n-1)$.

18.3.3 ДИ для σ^2 при неизвестном μ

Центральная статистика: $\chi^2 = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$.

$$\mathbb{P} \left(\chi^2_{n-1,\alpha/2} \leq \frac{(n-1)S^2}{\sigma^2} \leq \chi^2_{n-1,1-\alpha/2} \right) = 1 - \alpha$$

Доверительный интервал:

$$\sigma^2 \in \left[\frac{(n-1)S^2}{\chi^2_{n-1,1-\alpha/2}}, \quad \frac{(n-1)S^2}{\chi^2_{n-1,\alpha/2}} \right]$$

18.3.4 ДИ для σ^2 при известном μ

Центральная статистика: $\chi^2 = \frac{\sum(X_i - \mu)^2}{\sigma^2} \sim \chi^2(n)$.

Доверительный интервал:

$$\sigma^2 \in \left[\frac{\sum(X_i - \mu)^2}{\chi^2_{n,1-\alpha/2}}, \quad \frac{\sum(X_i - \mu)^2}{\chi^2_{n,\alpha/2}} \right]$$

18.3.5 ДИ для отношения дисперсий двух выборок

Пусть $X_1, \dots, X_m \sim \mathcal{N}(\mu_1, \sigma_1^2)$ и $Y_1, \dots, Y_n \sim \mathcal{N}(\mu_2, \sigma_2^2)$ независимы.

Центральная статистика:

$$F = \frac{S_X^2 / \sigma_1^2}{S_Y^2 / \sigma_2^2} = \frac{S_X^2}{S_Y^2} \cdot \frac{\sigma_2^2}{\sigma_1^2} \sim F(m-1, n-1)$$

Доверительный интервал для σ_1^2 / σ_2^2 :

$$\frac{\sigma_1^2}{\sigma_2^2} \in \left[\frac{S_X^2}{S_Y^2} \cdot \frac{1}{F_{m-1,n-1,1-\alpha/2}}, \quad \frac{S_X^2}{S_Y^2} \cdot \frac{1}{F_{m-1,n-1,\alpha/2}} \right]$$

19 Асимптотические доверительные интервалы

19.1 Общая конструкция

Асимптотические ДИ используются, когда:

- Точное распределение статистики неизвестно
- Выборка достаточно велика для применения ЦПТ

Th. (Асимптотический ДИ через ЦПТ)

Пусть $\hat{\theta}_n$ — асимптотически нормальная оценка:

$$\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{d} \mathcal{N}(0, \sigma^2(\theta))$$

Если $\hat{\sigma}_n^2 \xrightarrow{P} \sigma^2(\theta)$, то асимптотический $(1 - \alpha)$ -ДИ:

$$\left[\hat{\theta}_n - z_{1-\alpha/2} \cdot \frac{\hat{\sigma}_n}{\sqrt{n}}, \quad \hat{\theta}_n + z_{1-\alpha/2} \cdot \frac{\hat{\sigma}_n}{\sqrt{n}} \right]$$

19.2 Асимптотический ДИ для математического ожидания

Пусть X_1, \dots, X_n — i.i.d. с $\mathbb{E}[X] = \mu$, $\mathbb{D}[X] = \sigma^2 < \infty$.

По ЦПТ: $\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} \mathcal{N}(0, \sigma^2)$.

Оценка дисперсии: $\hat{\sigma}^2 = S^2$.

Асимптотический ДИ:

$$\mu \in \left[\bar{X}_n - z_{1-\alpha/2} \cdot \frac{S}{\sqrt{n}}, \quad \bar{X}_n + z_{1-\alpha/2} \cdot \frac{S}{\sqrt{n}} \right]$$

NB.

Для нормальной выборки точный ДИ использует t -распределение. Асимптотический ДИ использует z -квантили и даёт хорошее приближение при $n \gtrsim 30$.

19.3 Асимптотический ДИ для дисперсии

Пусть $\mathbb{E}[X^4] < \infty$. По ЦПТ для S_n^2 :

$$\sqrt{n}(S_n^2 - \sigma^2) \xrightarrow{d} \mathcal{N}(0, \mu_4 - \sigma^4)$$

где $\mu_4 = \mathbb{E}[(X - \mu)^4]$.

Оценка асимптотической дисперсии:

$$\widehat{\mu_4 - \sigma^4} = M_4 - S_n^4$$

где $M_4 = \frac{1}{n} \sum (X_i - \bar{X}_n)^4$.

Асимптотический ДИ:

$$\sigma^2 \in \left[S_n^2 - z_{1-\alpha/2} \cdot \frac{\sqrt{M_4 - S_n^4}}{\sqrt{n}}, \quad S_n^2 + z_{1-\alpha/2} \cdot \frac{\sqrt{M_4 - S_n^4}}{\sqrt{n}} \right]$$

NB. (Для нормального распределения)

При $X \sim \mathcal{N}(\mu, \sigma^2)$: $\mu_4 = 3\sigma^4$, поэтому $\mu_4 - \sigma^4 = 2\sigma^4$.

Асимптотический ДИ:

$$\sigma^2 \in \left[S^2 - z_{1-\alpha/2} \cdot \frac{S^2 \sqrt{2}}{\sqrt{n}}, \quad S^2 + z_{1-\alpha/2} \cdot \frac{S^2 \sqrt{2}}{\sqrt{n}} \right]$$

19.4 Асимптотический ДИ для медианы

Пусть F имеет плотность f , непрерывную в точке медианы $m = F^{-1}(1/2)$.

Выборочная медиана \hat{m}_n асимптотически нормальна:

$$\sqrt{n}(\hat{m}_n - m) \xrightarrow{d} \mathcal{N}\left(0, \frac{1}{4f(m)^2}\right)$$

Проблема: Асимптотическая дисперсия зависит от $f(m)$ — плотности в точке медианы.

Решения:

1. Ядерная оценка плотности:

$$\hat{f}(\hat{m}_n) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{\hat{m}_n - X_i}{h}\right)$$

Асимптотический ДИ:

$$m \in \left[\hat{m}_n - \frac{z_{1-\alpha/2}}{2\hat{f}(\hat{m}_n)\sqrt{n}}, \quad \hat{m}_n + \frac{z_{1-\alpha/2}}{2\hat{f}(\hat{m}_n)\sqrt{n}} \right]$$

2. ДИ на основе порядковых статистик (точный):

Используем тот факт, что $\mathbb{P}(X_{(j)} \leq m \leq X_{(k)})$ можно вычислить точно через биномиальное распределение.

Для уровня $1 - \alpha$ находим j и k такие, что:

$$\sum_{i=j}^{k-1} \binom{n}{i} \left(\frac{1}{2}\right)^n \geq 1 - \alpha$$

Тогда $[X_{(j)}, X_{(k)}]$ — точный ДИ для медианы.

19.5 Асимптотический ДИ для квантиля

Для $\xi_p = F^{-1}(p)$ и выборочного квантиля $\hat{\xi}_p$:

$$\sqrt{n}(\hat{\xi}_p - \xi_p) \xrightarrow{d} \mathcal{N}\left(0, \frac{p(1-p)}{f(\xi_p)^2}\right)$$

Асимптотический ДИ:

$$\xi_p \in \left[\hat{\xi}_p - z_{1-\alpha/2} \cdot \frac{\sqrt{p(1-p)}}{\hat{f}(\hat{\xi}_p)\sqrt{n}}, \quad \hat{\xi}_p + z_{1-\alpha/2} \cdot \frac{\sqrt{p(1-p)}}{\hat{f}(\hat{\xi}_p)\sqrt{n}} \right]$$

19.6 Сравнение точных и асимптотических ДИ

	Точный ДИ	Асимптотический ДИ
Покрытие	Ровно $1 - \alpha$	Примерно $1 - \alpha$
Требования	Знание распределения	Только ЦПТ
Размер выборки	Любой	Достаточно большой
Универсальность	Низкая	Высокая

20 Проверка статистических гипотез

20.1 Постановка задачи

Def. (Статистическая гипотеза)

Статистическая гипотеза — утверждение о распределении наблюдений.

Параметрическая гипотеза: $H : \theta \in \Theta_0 \subset \Theta$

Непараметрическая гипотеза: $H : F \in \mathcal{F}_0$ (например, « F — нормальное»)

Def. (Нулевая и альтернативная гипотезы)

- H_0 — **нулевая гипотеза** (null hypothesis) — гипотеза, которую проверяем
- H_1 — **альтернативная гипотеза** (alternative hypothesis) — то, что принимаем при отклонении H_0

Примеры:

- $H_0 : \mu = \mu_0$ vs $H_1 : \mu \neq \mu_0$ — двусторонняя альтернатива
- $H_0 : \mu = \mu_0$ vs $H_1 : \mu > \mu_0$ — односторонняя альтернатива
- $H_0 : \mu_1 = \mu_2$ vs $H_1 : \mu_1 \neq \mu_2$ — сравнение двух групп

Def. (Простая и сложная гипотезы)

- **Простая гипотеза:** $H_0 : \theta = \theta_0$ (одна точка)
- **Сложная гипотеза:** $H_0 : \theta \in \Theta_0$ (множество точек)

20.2 Выбор нулевой гипотезы

Принципы выбора H_0 :

1. H_0 — гипотеза «статус-кво» (ничего не происходит, нет эффекта)
2. H_0 — та гипотеза, для которой ошибочное отклонение более опасно
3. H_0 — гипотеза, которую хотим опровергнуть (чтобы доказать H_1)

Примеры:

- Клинические испытания: H_0 : лекарство не эффективно
- Контроль качества: H_0 : изделие соответствует стандарту
- Судебное дело: H_0 : подсудимый невиновен

20.3 Общий принцип работы статистического теста

Def. (Статистический критерий (тест))

Статистический критерий — правило, по которому на основе выборки принимается решение: отвергнуть H_0 или не отвергать.

Формально: отображение $\phi : \mathcal{X}^n \rightarrow \{0, 1\}$

- $\phi(\mathbf{X}) = 1$ — отвергаем H_0
- $\phi(\mathbf{X}) = 0$ — не отвергаем H_0

Def. (Тестовая статистика и критическая область)

Тестовая статистика — функция $T = T(X_1, \dots, X_n)$, на основе которой принимается решение.
Критическая область W — множество значений T , при которых H_0 отвергается:

$$\phi(\mathbf{X}) = 1 \iff T(\mathbf{X}) \in W$$

Алгоритм проверки гипотез:

Шаг 1. Сформулировать H_0 и H_1 .

Шаг 2. Выбрать уровень значимости α (обычно 0.05 или 0.01).

Шаг 3. Выбрать тестовую статистику T с известным распределением при H_0 .

Шаг 4. Определить критическую область W так, чтобы $P_{H_0}(T \in W) = \alpha$.

Шаг 5. Вычислить T по выборке и принять решение:

- $T \in W$ — отвергнуть H_0
- $T \notin W$ — не отвергать H_0

20.4 Ошибки I и II рода

Def. (Ошибки при проверке гипотез)

	H_0 верна	H_0 неверна
Не отвергаем H_0	Верное решение	Ошибка II рода (β) False Negative
Отвергаем H_0	Ошибка I рода (α) False Positive	Верное решение

- **Ошибка I рода** (Type I error, False Positive): отвергнуть верную H_0

$$\alpha = \mathbb{P}(\text{отвергнуть } H_0 | H_0 \text{ верна}) = \mathbb{P}_{H_0}(T \in W)$$

- **Ошибка II рода** (Type II error, False Negative): не отвергнуть неверную H_0

$$\beta = \mathbb{P}(\text{не отвергнуть } H_0 | H_1 \text{ верна}) = \mathbb{P}_{H_1}(T \notin W)$$

Def. (Уровень значимости)

Уровень значимости теста — максимальная вероятность ошибки I рода:

$$\alpha = \sup_{\theta \in \Theta_0} \mathbb{P}_\theta(\text{отвергнуть } H_0)$$

Def. (Мощность теста)

Мощность (power) теста — вероятность правильно отвергнуть неверную H_0 :

$$\text{Мощность} = 1 - \beta = \mathbb{P}_{H_1}(T \in W)$$

Функция мощности:

$$\pi(\theta) = \mathbb{P}_\theta(\text{отвергнуть } H_0)$$

NB. (Компромисс между α и β)

При фиксированном n нельзя уменьшить обе ошибки одновременно:

- Уменьшение α (более строгий критерий) \Rightarrow увеличение β
- Единственный способ уменьшить обе ошибки — увеличить n

20.5 p -value (достигаемый уровень значимости)

Def. (p -value)

p -value (р-значение) — вероятность получить значение тестовой статистики, столь же или более экстремальное, чем наблюдаемое, при условии что H_0 верна:

$$p\text{-value} = \mathbb{P}_{H_0}(T \geq T_{\text{obs}})$$

(для правосторонней альтернативы; для двусторонней — удваиваем хвост).

Интерпретация:

- p -value — «сила доказательства» против H_0
- Малое p -value — данные маловероятны при H_0

- **Правило:** Отвергаем H_0 при $p\text{-value} < \alpha$

Типичные пороги:

$p\text{-value}$	Интерпретация
> 0.10	Нет доказательств против H_0
$0.05 - 0.10$	Слабые доказательства
$0.01 - 0.05$	Умеренные доказательства
$0.001 - 0.01$	Сильные доказательства
< 0.001	Очень сильные доказательства

Th. (Свойство $p\text{-value}$)

Если H_0 верна, то $p\text{-value} \sim \text{Uniform}(0, 1)$.

Следовательно: $\mathbb{P}_{H_0}(p\text{-value} < \alpha) = \alpha$.

NB. (Распространённые заблуждения о $p\text{-value}$)

$p\text{-value}$ НЕ является:

- Вероятностью того, что H_0 верна
- Вероятностью того, что результат получен случайно
- Мерой размера эффекта

$p\text{-value}$ — это вероятность данных (или более экстремальных) при условии H_0 , а не вероятность H_0 при данных.

20.6 Примеры тестов

Ex. (z-тест для среднего)

$H_0 : \mu = \mu_0$ vs $H_1 : \mu \neq \mu_0$, σ^2 известна.

Тестовая статистика: $Z = \frac{\bar{X}_n - \mu_0}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1)$ при H_0 .

Критическая область: $W = \{|Z| > z_{1-\alpha/2}\}$.

$p\text{-value}: 2(1 - \Phi(|Z_{\text{obs}}|))$.

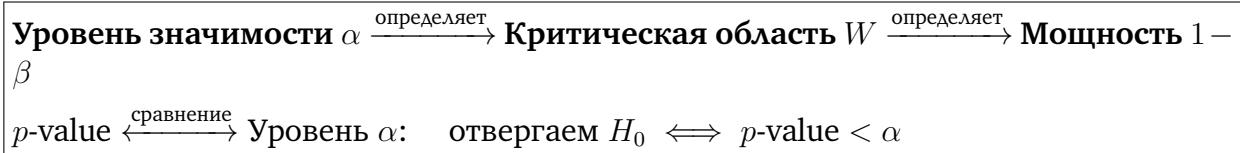
Ex. (t-тест для среднего)

$H_0 : \mu = \mu_0$ vs $H_1 : \mu \neq \mu_0$, σ^2 неизвестна.

Тестовая статистика: $T = \frac{\bar{X}_n - \mu_0}{S/\sqrt{n}} \sim t(n-1)$ при H_0 .

Критическая область: $W = \{|T| > t_{n-1, 1-\alpha/2}\}$.

20.7 Связь между понятиями



21 Статистические тесты на основе доверительных интервалов

21.1 Общий принцип

Th. (Дуальность ДИ и тестов)

Пусть $C_{1-\alpha}(\mathbf{X})$ — $(1 - \alpha)$ -доверительный интервал для θ . Тогда тест:

$$\text{Отвергнуть } H_0 : \theta = \theta_0 \iff \theta_0 \notin C_{1-\alpha}(\mathbf{X})$$

имеет уровень значимости ровно α .

21.2 z -тест для одной выборки

Условия: $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(\mu, \sigma^2)$, дисперсия σ^2 известна.

Гипотезы:

- $H_0 : \mu = \mu_0$
- $H_1 : \mu \neq \mu_0$ (двусторонняя), $\mu > \mu_0$ или $\mu < \mu_0$ (односторонние)

Тестовая статистика:

$$Z = \frac{\bar{X}_n - \mu_0}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1) \text{ при } H_0$$

Критические области:

H_1	Критическая область	$p\text{-value}$
$\mu \neq \mu_0$	$ Z > z_{1-\alpha/2}$	$2(1 - \Phi(Z))$
$\mu > \mu_0$	$Z > z_{1-\alpha}$	$1 - \Phi(Z)$
$\mu < \mu_0$	$Z < -z_{1-\alpha}$	$\Phi(Z)$

Мощность теста (для двусторонней альтернативы при истинном $\mu = \mu_1$):

$$\pi(\mu_1) = \Phi\left(-z_{1-\alpha/2} + \frac{\mu_1 - \mu_0}{\sigma/\sqrt{n}}\right) + \Phi\left(-z_{1-\alpha/2} - \frac{\mu_1 - \mu_0}{\sigma/\sqrt{n}}\right)$$

21.3 z -тест для двух независимых выборок

Условия: $X_1, \dots, X_m \sim \mathcal{N}(\mu_1, \sigma_1^2)$ и $Y_1, \dots, Y_n \sim \mathcal{N}(\mu_2, \sigma_2^2)$ независимы, дисперсии известны.

Гипотезы: $H_0 : \mu_1 = \mu_2$ (или $H_0 : \mu_1 - \mu_2 = \delta_0$).

Тестовая статистика:

$$Z = \frac{(\bar{X} - \bar{Y}) - \delta_0}{\sqrt{\frac{\sigma_1^2}{m} + \frac{\sigma_2^2}{n}}} \sim \mathcal{N}(0, 1) \text{ при } H_0$$

21.4 t -тест для одной выборки

Условия: $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(\mu, \sigma^2)$, дисперсия σ^2 неизвестна.

Гипотезы: $H_0 : \mu = \mu_0$ vs $H_1 : \mu \neq \mu_0$.

Тестовая статистика:

$$T = \frac{\bar{X}_n - \mu_0}{S/\sqrt{n}} \sim t(n-1) \text{ при } H_0$$

Критическая область: $|T| > t_{n-1, 1-\alpha/2}$.

p-value: $2 \cdot \mathbb{P}(t_{n-1} > |T_{\text{obs}}|)$.

NB.

При больших n ($n \gtrsim 30$) распределение $t(n-1)$ близко к $\mathcal{N}(0, 1)$, и t -тест практически совпадает с z -тестом.

21.5 t -тест для двух независимых выборок

Условия: $X_1, \dots, X_m \sim \mathcal{N}(\mu_1, \sigma^2)$ и $Y_1, \dots, Y_n \sim \mathcal{N}(\mu_2, \sigma^2)$, одинаковые неизвестные дисперсии.

Гипотезы: $H_0 : \mu_1 = \mu_2$.

Объединённая оценка дисперсии:

$$S_p^2 = \frac{(m-1)S_X^2 + (n-1)S_Y^2}{m+n-2}$$

Тестовая статистика:

$$T = \frac{\bar{X} - \bar{Y}}{S_p \sqrt{\frac{1}{m} + \frac{1}{n}}} \sim t(m+n-2) \text{ при } H_0$$

21.5.1 t -тест Уэлча (разные дисперсии)

Если дисперсии $\sigma_1^2 \neq \sigma_2^2$, используется **тест Уэлча**:

$$T = \frac{\bar{X} - \bar{Y}}{\sqrt{\frac{S_X^2}{m} + \frac{S_Y^2}{n}}}$$

Распределение аппроксимируется $t(\nu)$, где степени свободы по формуле Уэлча—Саттертуэйта:

$$\nu = \frac{\left(\frac{S_X^2}{m} + \frac{S_Y^2}{n} \right)^2}{\frac{(S_X^2/m)^2}{m-1} + \frac{(S_Y^2/n)^2}{n-1}}$$

21.6 Парный t -тест

Условия: Парные наблюдения $(X_1, Y_1), \dots, (X_n, Y_n)$, $D_i = X_i - Y_i$.

Гипотезы: $H_0 : \mathbb{E}[D] = 0$ (нет разницы).

Тестовая статистика:

$$T = \frac{\bar{D}}{S_D/\sqrt{n}} \sim t(n-1) \text{ при } H_0$$

21.7 F-тест для сравнения дисперсий

Условия: $X_1, \dots, X_m \sim \mathcal{N}(\mu_1, \sigma_1^2)$ и $Y_1, \dots, Y_n \sim \mathcal{N}(\mu_2, \sigma_2^2)$ независимы.

Гипотезы: $H_0: \sigma_1^2 = \sigma_2^2$ vs $H_1: \sigma_1^2 \neq \sigma_2^2$.

Тестовая статистика:

$$F = \frac{S_X^2}{S_Y^2} \sim F(m-1, n-1) \text{ при } H_0$$

Критическая область (двусторонняя):

$$F < F_{m-1, n-1, \alpha/2} \quad \text{или} \quad F > F_{m-1, n-1, 1-\alpha/2}$$

NB.

F-тест очень чувствителен к отклонению от нормальности. При ненормальных данных лучше использовать тест Левена или Бартлетта.

21.8 Сводная таблица тестов

Тест	H_0	Статистика	Распределение
<i>z</i> -тест (1 выб.)	$\mu = \mu_0$	$\frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$	$\mathcal{N}(0, 1)$
<i>t</i> -тест (1 выб.)	$\mu = \mu_0$	$\frac{\bar{X} - \mu_0}{S/\sqrt{n}}$	$t(n-1)$
<i>z</i> -тест (2 выб.)	$\mu_1 = \mu_2$	$\frac{\bar{X} - \bar{Y}}{\sqrt{\sigma_1^2/m + \sigma_2^2/n}}$	$\mathcal{N}(0, 1)$
<i>t</i> -тест (2 выб.)	$\mu_1 = \mu_2$	$\frac{\bar{X} - \bar{Y}}{S_p \sqrt{1/m + 1/n}}$	$t(m+n-2)$
<i>F</i> -тест	$\sigma_1^2 = \sigma_2^2$	S_X^2/S_Y^2	$F(m-1, n-1)$

22 Критерии Колмогорова—Смирнова

22.1 Критерий согласия Колмогорова (одновыборочный)

Задача: Проверить, имеет ли выборка заданное распределение F_0 .

Гипотезы:

- $H_0: F = F_0$ (выборка из F_0)
- $H_1: F \neq F_0$

Def. (Статистика Колмогорова)

Статистика Колмогорова:

$$D_n = \sup_{x \in \mathbb{R}} |F_n(x) - F_0(x)|$$

где $F_n(x)$ — эмпирическая функция распределения.

Эквивалентная формула через порядковые статистики:

$$D_n = \max \left(\max_{1 \leq i \leq n} \left(\frac{i}{n} - F_0(X_{(i)}) \right), \max_{1 \leq i \leq n} \left(F_0(X_{(i)}) - \frac{i-1}{n} \right) \right)$$

Th. (Распределение статистики Колмогорова)

При H_0 распределение D_n не зависит от F_0 (если F_0 непрерывна).

Асимптотически:

$$\sqrt{n}D_n \xrightarrow{d} K$$

где K — распределение Колмогорова с функцией распределения:

$$\mathbb{P}(K \leq x) = 1 - 2 \sum_{k=1}^{\infty} (-1)^{k-1} e^{-2k^2 x^2}, \quad x > 0$$

Proof. (Иdea доказательства)

Преобразуем $U_i = F_0(X_i)$. При H_0 : $U_i \sim \text{Uniform}(0, 1)$ (интегральное преобразование).

Тогда:

$$D_n = \sup_x |F_n(x) - F_0(x)| = \sup_{u \in [0,1]} |G_n(u) - u|$$

где G_n — ЭФР для $U_1, \dots, U_n \sim \text{Uniform}(0, 1)$.

Это распределение не зависит от F_0 !

Асимптотика следует из теории эмпирических процессов (процесс $\sqrt{n}(G_n(u) - u)$ сходится к броуновскому мосту). ■

Критерий: Отвергаем H_0 при $D_n > d_{n,\alpha}$, где $d_{n,\alpha}$ — критическое значение.

Приближённое критическое значение:

$$d_{n,\alpha} \approx \sqrt{\frac{-\ln(\alpha/2)}{2n}} \cdot c$$

α	0.10	0.05	0.01
$\sqrt{n} \cdot d_{n,\alpha}$	1.22	1.36	1.63

22.2 Критерий Колмогорова—Смирнова (двуихвыборочный)

Задача: Проверить, имеют ли две выборки одинаковое распределение.

Гипотезы:

- $H_0: F_X = F_Y$
- $H_1: F_X \neq F_Y$

Данные: $X_1, \dots, X_m \sim F_X$ и $Y_1, \dots, Y_n \sim F_Y$ — независимые выборки.

Def. (Двухвыборочная статистика К-С)

$$D_{m,n} = \sup_{x \in \mathbb{R}} |F_m(x) - G_n(x)|$$

где F_m, G_n — ЭФР для выборок X и Y .

Th. (Асимптотика двухвыборочной статистики)

При H_0 и $m, n \rightarrow \infty$, $m/(m+n) \rightarrow \lambda \in (0, 1)$:

$$\sqrt{\frac{mn}{m+n}} D_{m,n} \xrightarrow{d} K$$

где K — то же распределение Колмогорова.

Критерий: Отвергаем H_0 при $D_{m,n} > d_{m,n,\alpha}$.

22.3 Односторонние статистики**Def. (Односторонние статистики)**

$$D_n^+ = \sup_x (F_n(x) - F_0(x)), \quad D_n^- = \sup_x (F_0(x) - F_n(x))$$

Используются для односторонних альтернатив:

- $H_1 : F \prec F_0$ (стохастически меньше) — используем D_n^+
- $H_1 : F \succ F_0$ (стохастически больше) — используем D_n^-

22.4 Достоинства и недостатки**Достоинства:**

- Непараметрический (не требует предположений о распределении)
- Свобден от распределения при непрерывной F_0
- Чувствителен к различиям в центре распределения

Недостатки:

- Менее мощный для конкретных альтернатив, чем специализированные тесты
- Менее чувствителен к различиям в хвостах
- При оценивании параметров F_0 по данным критические значения неверны (нужна поправка Лиллиефорса)

23 Критерий согласия хи-квадрат Пирсона

23.1 Постановка задачи

Задача: Проверить, согласуются ли данные с заданным распределением.

Разбиваем область значений на k непересекающихся интервалов (ячеек) A_1, \dots, A_k .

Обозначения:

- n_j — наблюдаемое число попаданий в A_j
- $p_j = \mathbb{P}(X \in A_j)$ — теоретическая вероятность при H_0
- $e_j = n \cdot p_j$ — ожидаемое число попаданий

23.2 Критерий для простой гипотезы

Гипотезы: $H_0 : F = F_0$ (полностью задано).

Def. (Статистика хи-квадрат Пирсона)

$$\chi^2 = \sum_{j=1}^k \frac{(n_j - e_j)^2}{e_j} = \sum_{j=1}^k \frac{(n_j - np_j)^2}{np_j}$$

Th. (Теорема Пирсона)

При H_0 и $n \rightarrow \infty$:

$$\chi^2 \xrightarrow{d} \chi^2(k-1)$$

при условии, что все $e_j = np_j \rightarrow \infty$ (практически: $e_j \geq 5$).

Proof. (Идея доказательства)

Вектор частот (n_1, \dots, n_k) имеет полиномиальное распределение.

По ЦПТ для мультиномиального распределения:

$$\sqrt{n} \left(\frac{n_j}{n} - p_j \right) \xrightarrow{d} \mathcal{N}(0, p_j(1-p_j))$$

Статистика χ^2 является квадратичной формой от этих нормальных величин. С учётом ограничения $\sum n_j = n$ (одна степень свободы теряется), получаем $\chi^2(k-1)$. ■

Критерий: Отвергаем H_0 при $\chi^2 > \chi^2_{k-1, 1-\alpha}$.

23.3 Критерий для сложной гипотезы (с оцениванием параметров)

Гипотезы: $H_0 : F \in \{F_\theta : \theta \in \Theta\}$ — параметрическое семейство.

Процедура:

1. Оценить θ по данным (например, методом максимального правдоподобия): $\hat{\theta}$

2. Вычислить $\hat{p}_j = \mathbb{P}_{\hat{\theta}}(X \in A_j)$

3. Вычислить статистику:

$$\chi^2 = \sum_{j=1}^k \frac{(n_j - n\hat{p}_j)^2}{n\hat{p}_j}$$

Th. (Распределение при сложной гипотезе)

Если оценка $\hat{\theta}$ получена методом максимального правдоподобия по сгруппированным данным, то при H_0 :

$$\chi^2 \xrightarrow{d} \chi^2(k - 1 - d)$$

где $d = \dim(\theta)$ — число оцениваемых параметров.

NB.

Если параметры оценены по исходным данным (не по группированным), то распределение статистики лежит между $\chi^2(k - 1 - d)$ и $\chi^2(k - 1)$. На практике используют $k - 1 - d$ как консервативную оценку.

Ex. (Проверка нормальности)

H_0 : выборка из $\mathcal{N}(\mu, \sigma^2)$.

Разбиваем на k интервалов, оцениваем $\hat{\mu} = \bar{X}$, $\hat{\sigma}^2 = S^2$.

Степени свободы: $k - 1 - 2 = k - 3$.

23.4 Выбор разбиения

Рекомендации:

- Число ячеек: $k \approx \sqrt{n}$ или $k = 1 + \log_2 n$
- Ожидаемые частоты: $e_j \geq 5$ для всех j
- При малых e_j — объединять соседние ячейки
- Равновероятные ячейки ($p_j = 1/k$) часто оптимальны

24 Критерий однородности хи-квадрат

24.1 Постановка задачи

Задача: Проверить, имеют ли несколько выборок одинаковое распределение по категориям.

Данные: r независимых выборок (групп), каждая классифицирована по c категориям.

Таблица сопряжённости:

	Категория 1	Категория 2	...	Категория c	Всего
Группа 1	n_{11}	n_{12}	...	n_{1c}	$n_{1\cdot}$
Группа 2	n_{21}	n_{22}	...	n_{2c}	$n_{2\cdot}$
\vdots	\vdots	\vdots	\ddots	\vdots	\vdots
Группа r	n_{r1}	n_{r2}	...	n_{rc}	$n_{r\cdot}$
Всего	$n_{\cdot 1}$	$n_{\cdot 2}$...	$n_{\cdot c}$	n

Гипотезы:

- H_0 : распределения по категориям одинаковы во всех группах ($p_{1j} = p_{2j} = \dots = p_{rj}$ для всех j)
- H_1 : распределения различаются хотя бы для некоторых групп

24.2 Статистика критерия

Ожидаемые частоты при H_0 :

$$e_{ij} = \frac{n_{i\cdot} \cdot n_{\cdot j}}{n}$$

Статистика хи-квадрат:

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(n_{ij} - e_{ij})^2}{e_{ij}}$$

Th. (Распределение статистики однородности)

При H_0 и $n \rightarrow \infty$:

$$\chi^2 \xrightarrow{d} \chi^2((r-1)(c-1))$$

Proof. (Идея подсчёта степеней свободы)

В таблице $r \times c$ всего rc ячеек.

Ограничения:

- r сумм по строкам фиксированы: $-r$ ограничений (но одно следует из $\sum = n$, поэтому $-(r-1)$)
- c сумм по столбцам: $-(c-1)$
- Общая сумма n : уже учтена

Свободных параметров: $rc - (r-1) - (c-1) - 1 = (r-1)(c-1)$. ■

Критерий: Отвергаем H_0 при $\chi^2 > \chi^2_{(r-1)(c-1), 1-\alpha}$.

24.3 Случай 2×2

Для таблицы 2×2 :

	Категория 1	Категория 2	Всего
Группа 1	a	b	$a+b$
Группа 2	c	d	$c+d$
Всего	$a+c$	$b+d$	n

Упрощённая формула:

$$\chi^2 = \frac{n(ad - bc)^2}{(a+b)(c+d)(a+c)(b+d)}$$

Степени свободы: $(2-1)(2-1) = 1$.

Поправка Йейтса (для малых выборок):

$$\chi^2_{\text{Yates}} = \frac{n(|ad - bc| - n/2)^2}{(a+b)(c+d)(a+c)(b+d)}$$

NB.

При очень малых ожидаемых частотах ($e_{ij} < 5$) лучше использовать точный тест Фишера.

24.4 Точный тест Фишера (для 2×2)

При фиксированных маргинальных суммах вероятность конкретной таблицы:

$$\mathbb{P}(\text{таблица}) = \frac{(a+b)!(c+d)!(a+c)!(b+d)!}{n! \cdot a! \cdot b! \cdot c! \cdot d!}$$

p-value — сумма вероятностей всех таблиц, не менее экстремальных, чем наблюдаемая.

25 Критерий независимости хи-квадрат

25.1 Постановка задачи

Задача: Проверить независимость двух категориальных признаков.

Данные: Одна выборка объёма n , каждое наблюдение классифицировано по двум признакам:

- Признак A с r уровнями
- Признак B с c уровнями

Таблица сопряжённости: та же структура $r \times c$, но с другой интерпретацией.

Гипотезы:

- H_0 : признаки A и B независимы ($p_{ij} = p_{i \cdot} \cdot p_{\cdot j}$)
- H_1 : признаки зависимы

25.2 Статистика критерия

При независимости $\mathbb{P}(A = i, B = j) = \mathbb{P}(A = i) \cdot \mathbb{P}(B = j)$.

Оценки маргинальных вероятностей:

$$\hat{p}_{i \cdot} = \frac{n_{i \cdot}}{n}, \quad \hat{p}_{\cdot j} = \frac{n_{\cdot j}}{n}$$

Ожидаемые частоты при H_0 :

$$e_{ij} = n \cdot \hat{p}_{i \cdot} \cdot \hat{p}_{\cdot j} = \frac{n_{i \cdot} \cdot n_{\cdot j}}{n}$$

Статистика:

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(n_{ij} - e_{ij})^2}{e_{ij}}$$

Th. (Распределение статистики независимости)

При H_0 и $n \rightarrow \infty$:

$$\chi^2 \xrightarrow{d} \chi^2((r-1)(c-1))$$

NB.

Формулы для статистик однородности и независимости идентичны! Различие — в постановке задачи и интерпретации.

25.3 Случай 2×2

Для таблицы 2×2 (два бинарных признака):

$$\chi^2 = \frac{n(ad - bc)^2}{(a+b)(c+d)(a+c)(b+d)}$$

Степени свободы: 1.

Ex. (Связь курения и заболевания)

	Болен	Здоров	Всего
Курит	60	40	100
Не курит	30	70	100
Всего	90	110	200

Ожидаемые частоты при независимости:

$$e_{11} = \frac{100 \cdot 90}{200} = 45, \quad e_{12} = \frac{100 \cdot 110}{200} = 55$$

Статистика:

$$\chi^2 = \frac{200 \cdot (60 \cdot 70 - 40 \cdot 30)^2}{100 \cdot 100 \cdot 90 \cdot 110} = \frac{200 \cdot 3000^2}{99000000} \approx 18.18$$

При $\alpha = 0.05$: $\chi^2_{1,0.95} = 3.84$.

$18.18 > 3.84$ — отвергаем H_0 , признаки зависимы.

25.4 Меры связи

При отвержении H_0 полезно оценить силу связи.

Def. (Коэффициент Крамера)

$$V = \sqrt{\frac{\chi^2}{n \cdot \min(r-1, c-1)}}$$

$V \in [0, 1]$, где $V = 0$ — независимость, $V = 1$ — полная связь.

Def. (Коэффициент ϕ (для 2×2))

$$\phi = \sqrt{\frac{\chi^2}{n}} = \frac{ad - bc}{\sqrt{(a+b)(c+d)(a+c)(b+d)}}$$

$\phi \in [-1, 1]$ — аналог корреляции для категориальных данных.

Def. (Отношение шансов (Odds Ratio))

Для таблицы 2×2 :

$$OR = \frac{a \cdot d}{b \cdot c}$$

- $OR = 1$ — независимость
- $OR > 1$ — положительная ассоциация
- $OR < 1$ — отрицательная ассоциация

25.5 Сравнение критериев однородности и независимости

	Однородность	Независимость
Число выборок	r независимых	Одна
Что фиксировано	Объёмы групп n_i .	Только n
Гипотеза H_0	$p_{1j} = \dots = p_{rj}$	$p_{ij} = p_i \cdot p_j$
Статистика	Однаковая	Однаковая
Распределение	$\chi^2((r-1)(c-1))$	$\chi^2((r-1)(c-1))$

26 Критерии квантилей и знаков

Критерии квантилей и знаков — это непараметрические критерии, не требующие знания вида распределения и основанные на порядковых свойствах данных.

26.1 Критерий знаков (Sign Test)

Def. (Критерий знаков)

Критерий знаков предназначен для проверки гипотезы о медиане распределения или для сравнения парных выборок.

26.1.1 Постановка задачи о медиане

Пусть X_1, \dots, X_n — выборка из непрерывного распределения с медианой Me .

Гипотезы:

- $H_0: Me = m_0$ (медиана равна заданному значению)
- $H_1: Me \neq m_0$ (или односторонняя альтернатива)

26.1.2 Построение статистики

Для каждого наблюдения определим знак:

$$S_i = \text{sign}(X_i - m_0) = \begin{cases} +1, & X_i > m_0 \\ -1, & X_i < m_0 \\ 0, & X_i = m_0 \end{cases}$$

Статистика критерия:

$$S^+ = \sum_{i=1}^n \mathbf{1}(X_i > m_0) = \#\{i : X_i > m_0\}$$

— число положительных знаков.

Th. (Распределение статистики знаков)

При справедливости H_0 и отбрасывании нулей (пусть их n_0 , тогда $n' = n - n_0$):

$$S^+ \sim \text{Bin}(n', 1/2)$$

Proof.

При $H_0: \text{Ме} = m_0$, то есть $P(X_i > m_0) = P(X_i < m_0) = 1/2$ по определению медианы (для непрерывного распределения). Каждое $\mathbf{1}(X_i > m_0)$ — независимый бернуlliевский эксперимент с $p = 1/2$. Сумма независимых бернуlliевских величин имеет биномиальное распределение. ■

26.1.3 Критическая область

Двусторонний критерий (уровень α):

Отвергаем H_0 , если S^+ слишком мало или слишком велико:

$$S^+ \leq c_1 \quad \text{или} \quad S^+ \geq c_2$$

где c_1, c_2 — квантили $\text{Bin}(n', 1/2)$:

$$P(S^+ \leq c_1) = \alpha/2, \quad P(S^+ \geq c_2) = \alpha/2$$

Асимптотическая версия:

При $n' \rightarrow \infty$:

$$Z = \frac{S^+ - n'/2}{\sqrt{n'/4}} = \frac{2S^+ - n'}{\sqrt{n'}} \xrightarrow{d} \mathcal{N}(0, 1)$$

26.1.4 Критерий знаков для парных выборок

Пусть $(X_1, Y_1), \dots, (X_n, Y_n)$ — парные наблюдения.

Гипотезы:

- H_0 : распределения X и Y одинаковы (медиана разности равна 0)
- H_1 : распределения различаются

Процедура:

1. Вычислить разности $D_i = X_i - Y_i$
2. Подсчитать $S^+ = \#\{i : D_i > 0\}$
3. Применить критерий знаков к разностям с $m_0 = 0$

26.2 Критерий квантилей

Def. (Критерий квантилей)

Критерий квантилей проверяет гипотезу о том, что заданное значение является квантилем определённого порядка.

26.2.1 Постановка

Гипотезы:

- $H_0: x_p = q_0$ (p -квантиль равна q_0)
- $H_1: x_p \neq q_0$

Статистика:

$$K = \#\{i : X_i \leq q_0\}$$

Th. (Распределение статистики квантилей)

При H_0 :

$$K \sim \text{Bin}(n, p)$$

Proof.

По определению p -квантили: $P(X \leq x_p) = p$. При $H_0: x_p = q_0$, поэтому $P(X_i \leq q_0) = p$. Каждый индикатор $\mathbf{1}(X_i \leq q_0)$ имеет распределение $\text{Ber}(p)$, и они независимы. ■

Асимптотика:

$$Z = \frac{K - np}{\sqrt{np(1-p)}} \xrightarrow{d} \mathcal{N}(0, 1)$$

Ex.

Проверка гипотезы о медиане ($p = 0.5$) — частный случай критерия квантилей, совпадающий с критерием знаков.

26.3 Знаково-ранговый критерий Уилкоксона

Def. (Критерий Уилкоксона для одной выборки)

Усиление критерия знаков, учитывающее не только знаки, но и величины отклонений.

Процедура:

1. Вычислить $D_i = X_i - m_0$
2. Упорядочить $|D_i|$ по возрастанию и присвоить ранги R_i
3. Вычислить статистику:

$$W^+ = \sum_{i:D_i>0} R_i$$

— сумма рангов положительных разностей

При H_0 : $\text{Ме} = m_0$:

$$\mathbb{E}[W^+] = \frac{n(n+1)}{4}, \quad \text{Var}(W^+) = \frac{n(n+1)(2n+1)}{24}$$

Асимптотика:

$$Z = \frac{W^+ - \frac{n(n+1)}{4}}{\sqrt{\frac{n(n+1)(2n+1)}{24}}} \xrightarrow{d} \mathcal{N}(0, 1)$$

NB.

Критерий Уилкоксона мощнее критерия знаков, так как использует больше информации (величины отклонений), но требует симметричности распределения относительно медианы.

27 Ранговые критерии. Критерий Манна-Уитни-Уилкоксона

Ранговые критерии — непараметрические критерии, основанные на рангах наблюдений. Они устойчивы к выбросам и не требуют предположений о виде распределения.

27.1 Основные понятия

Def. (Ранг)

Ранг наблюдения X_i в выборке — это его порядковый номер после упорядочения выборки по возрастанию:

$$R_i = \#\{j : X_j \leq X_i\}$$

Def. (Связи (Ties))

Если несколько наблюдений имеют одинаковые значения, им присваивают **средний ранг** — среднее арифметическое рангов, которые они бы заняли.

Ex.

Выборка: 3, 7, 7, 9, 12. Ранги: 1, 2.5, 2.5, 4, 5 (значениям 7 присвоен средний ранг $(2 + 3)/2 = 2.5$).

27.2 Критерий Манна-Уитни-Уилкоксона

Def. (Критерий Манна-Уитни-Уилкоксона)

Непараметрический критерий для сравнения двух независимых выборок. Также известен как:

- Критерий суммы рангов Уилкоксона (Wilcoxon rank-sum test)
- U-критерий Манна-Уитни (Mann-Whitney U test)

27.2.1 Постановка задачи

Даны две независимые выборки:

- X_1, \dots, X_m из распределения F
- Y_1, \dots, Y_n из распределения G

Гипотезы:

- $H_0: F = G$ (распределения одинаковы)
- $H_1: F \neq G$ (или односторонняя: F стохастически больше/меньше G)

Альтернативная формулировка (модель сдвига): $G(x) = F(x - \Delta)$.

- $H_0: \Delta = 0$
- $H_1: \Delta \neq 0$

27.2.2 Построение статистики Уилкоксона

Процедура:

1. Объединить выборки: Z_1, \dots, Z_{m+n}
2. Упорядочить объединённую выборку и присвоить ранги R_1, \dots, R_{m+n}
3. Вычислить сумму рангов первой выборки:

$$W = \sum_{i=1}^m R_{X_i}$$

Th. (Свойства статистики W при H_0)

Если H_0 верна (распределения одинаковы):

$$\mathbb{E}[W] = \frac{m(m + n + 1)}{2}$$

$$\text{Var}(W) = \frac{mn(m+n+1)}{12}$$

Proof.

При H_0 все ранги от 1 до $m + n$ равновероятно распределены между двумя выборками.

Математическое ожидание: Средний ранг в объединённой выборке:

$$\bar{R} = \frac{1 + 2 + \dots + (m+n)}{m+n} = \frac{m+n+1}{2}$$

Поэтому:

$$\mathbb{E}[W] = m \cdot \bar{R} = \frac{m(m+n+1)}{2}$$

Дисперсия: Дисперсия одного ранга:

$$\text{Var}(R) = \frac{(m+n)^2 - 1}{12}$$

С учётом ковариаций (ранги без повторений):

$$\text{Var}(W) = \frac{mn(m+n+1)}{12}$$

■

27.2.3 Статистика Манна-Уитни

Def. (U-статистика Манна-Уитни)

$$U = \sum_{i=1}^m \sum_{j=1}^n \mathbf{1}(X_i > Y_j)$$

— число пар (X_i, Y_j) , в которых $X_i > Y_j$.

Th. (Связь между W и U)

$$U = W - \frac{m(m+1)}{2}$$

или эквивалентно:

$$W = U + \frac{m(m+1)}{2}$$

Proof.

Сумма рангов первой выборки W складывается из:

- Числа элементов первой выборки, меньших каждого X_i : вклад $\frac{m(m+1)}{2}$ (от самих X)
- Числа элементов второй выборки, меньших каждого X_i : это и есть U

■

Th. (Свойства U при H_0)

$$\mathbb{E}[U] = \frac{mn}{2}, \quad \text{Var}(U) = \frac{mn(m+n+1)}{12}$$

27.2.4 Асимптотическое распределение**Th. (Асимптотическая нормальность)**

При $m, n \rightarrow \infty$:

$$Z = \frac{W - \frac{m(m+n+1)}{2}}{\sqrt{\frac{mn(m+n+1)}{12}}} \xrightarrow{d} \mathcal{N}(0, 1)$$

Эквивалентно для U :

$$Z = \frac{U - \frac{mn}{2}}{\sqrt{\frac{mn(m+n+1)}{12}}} \xrightarrow{d} \mathcal{N}(0, 1)$$

27.2.5 Критическая область

Двусторонний критерий: Отвергаем H_0 , если $|Z| > z_{1-\alpha/2}$.

Односторонние критерии:

- $H_1: X$ стохастически больше $Y \Rightarrow$ отвергаем при $Z > z_{1-\alpha}$
- $H_1: X$ стохастически меньше $Y \Rightarrow$ отвергаем при $Z < -z_{1-\alpha}$

27.2.6 Поправка на связи

При наличии связей (одинаковых значений) дисперсия корректируется:

$$\text{Var}(W) = \frac{mn}{12} \left(m + n + 1 - \frac{\sum_k t_k(t_k^2 - 1)}{(m+n)(m+n-1)} \right)$$

где t_k — размер k -й группы связей.

27.3 Интерпретация через вероятности

Th. (Вероятностная интерпретация)

Статистика $U/(mn)$ является оценкой вероятности $P(X > Y)$:

$$\frac{U}{mn} \approx P(X > Y)$$

При $H_0: P(X > Y) = 1/2$.

NB.

Критерий Манна-Уитни проверяет, являются ли два распределения стохастически упорядоченными. Он особенно эффективен для альтернатив сдвига.

27.4 Сравнение с t-критерием

	t-критерий	Манна-Уитни
Предположения	Нормальность	Нет
Устойчивость к выбросам	Низкая	Высокая
Мощность (норм. распр.)	Оптимальная	$\approx 95.5\%$ от t
Мощность (тяж. хвосты)	Низкая	Выше

28 Коэффициенты корреляции Пирсона, Спирмена и Кендалла. Статистические тесты

Коэффициенты корреляции измеряют степень связи между двумя переменными. Разные коэффициенты улавливают разные типы зависимости.

28.1 Коэффициент корреляции Пирсона**Def. (Теоретический коэффициент Пирсона)**

Коэффициент корреляции Пирсона для случайных величин X и Y :

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X) \cdot \text{Var}(Y)}} = \frac{\mathbb{E}[(X - \mu_X)(Y - \mu_Y)]}{\sigma_X \sigma_Y}$$

Th. (Свойства коэффициента Пирсона)

1. $\rho \in [-1, 1]$
2. $|\rho| = 1 \Leftrightarrow Y = aX + b$ (линейная зависимость)
3. $\rho = 0$ — отсутствие линейной связи (но возможна нелинейная!)
4. Инвариантен к линейным преобразованиям: $\rho(aX + b, cY + d) = \text{sign}(ac) \cdot \rho(X, Y)$

Def. (Выборочный коэффициент Пирсона)

$$r = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2 \cdot \sum_{i=1}^n (Y_i - \bar{Y})^2}}$$

или эквивалентно:

$$r = \frac{n \sum X_i Y_i - \sum X_i \sum Y_i}{\sqrt{[n \sum X_i^2 - (\sum X_i)^2][n \sum Y_i^2 - (\sum Y_i)^2]}}$$

28.1.1 Тест на значимость корреляции Пирсона**Гипотезы:**

- $H_0: \rho = 0$ (нет линейной связи)
- $H_1: \rho \neq 0$ (есть линейная связь)

Th. (t-статистика для корреляции)При $(X, Y) \sim \mathcal{N}_2$ и $H_0: \rho = 0$:

$$t = r \sqrt{\frac{n-2}{1-r^2}} \sim t(n-2)$$

Proof.При нормальном распределении и $\rho = 0$:

$$r \sqrt{\frac{n-2}{1-r^2}} = \frac{r/\sqrt{1-r^2}}{\sqrt{1/(n-2)}}$$

Числитель асимптотически нормален, знаменатель связан с χ^2 -распределением остатков регрессии. ■**Критерий:** отвергаем H_0 , если $|t| > t_{1-\alpha/2}(n-2)$.**28.1.2 Преобразование Фишера**Для проверки $H_0: \rho = \rho_0 \neq 0$ используется z-преобразование Фишера:

$$z = \frac{1}{2} \ln \frac{1+r}{1-r} = \operatorname{arctanh}(r)$$

Th. (Распределение z-преобразования)При больших n :

$$z \approx \mathcal{N} \left(\frac{1}{2} \ln \frac{1+\rho}{1-\rho}, \frac{1}{n-3} \right)$$

28.2 Коэффициент ранговой корреляции Спирмена

Def. (Коэффициент Спирмена)

Коэффициент Спирмена — это коэффициент Пирсона, вычисленный для рангов:

$$r_S = \frac{\sum_{i=1}^n (R_i - \bar{R})(S_i - \bar{S})}{\sqrt{\sum_{i=1}^n (R_i - \bar{R})^2 \cdot \sum_{i=1}^n (S_i - \bar{S})^2}}$$

где R_i — ранг X_i , S_i — ранг Y_i .

Th. (Упрощённая формула Спирмена)

При отсутствии связей:

$$r_S = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)}$$

где $d_i = R_i - S_i$ — разность рангов.

Proof.

Поскольку $\bar{R} = \bar{S} = (n + 1)/2$ и $\sum(R_i - \bar{R})^2 = \sum(S_i - \bar{S})^2 = \frac{n(n^2 - 1)}{12}$:

$$\begin{aligned} r_S &= \frac{\sum_{i=1}^n (R_i - \bar{R})(S_i - \bar{S})}{\frac{n(n^2 - 1)}{12}} \\ &= \frac{\sum_{i=1}^n R_i S_i - n \bar{R} \bar{S}}{\frac{n(n^2 - 1)}{12}} \end{aligned}$$

Используя $\sum d_i^2 = \sum R_i^2 + \sum S_i^2 - 2 \sum R_i S_i$ и $\sum R_i^2 = \sum S_i^2 = \frac{n(n + 1)(2n + 1)}{6}$:

$$\sum R_i S_i = \frac{n(n + 1)(2n + 1)}{6} - \frac{\sum d_i^2}{2}$$

Подстановка даёт исковую формулу. ■

28.2.1 Свойства коэффициента Спирмена

- $r_S \in [-1, 1]$
- $|r_S| = 1 \Leftrightarrow$ строгая монотонная зависимость
- Инвариантен к монотонным преобразованиям
- Устойчив к выбросам
- Измеряет монотонную (не обязательно линейную) связь

28.2.2 Тест на значимость Спирмена

Гипотезы:

- $H_0: \rho_S = 0$ (нет монотонной связи)
- $H_1: \rho_S \neq 0$

Th. (Асимптотическое распределение)

При $n \rightarrow \infty$ и H_0 :

$$\sqrt{n-1} \cdot r_S \xrightarrow{d} \mathcal{N}(0, 1)$$

или эквивалентно:

$$t = r_S \sqrt{\frac{n-2}{1-r_S^2}} \approx t(n-2)$$

Для малых n используются точные таблицы критических значений.

28.3 Коэффициент ранговой корреляции Кендалла

Def. (Согласованные и несогласованные пары)

Пара наблюдений (X_i, Y_i) и (X_j, Y_j) называется:

- **Согласованной**, если $(X_i - X_j)(Y_i - Y_j) > 0$
- **Несогласованной**, если $(X_i - X_j)(Y_i - Y_j) < 0$
- **Связанной**, если $X_i = X_j$ или $Y_i = Y_j$

Def. (Коэффициент Кендалла τ)

$$\boxed{\tau = \frac{C - D}{\binom{n}{2}} = \frac{C - D}{\frac{n(n-1)}{2}}}$$

где C — число согласованных пар, D — число несогласованных пар.

Альтернативные формы:

$$\tau = \frac{2(C - D)}{n(n - 1)}$$

$$\tau = \frac{\sum_{i < j} \text{sign}(X_j - X_i) \cdot \text{sign}(Y_j - Y_i)}{\binom{n}{2}}$$

28.3.1 Свойства коэффициента Кендалла

Th. (Свойства τ)

1. $\tau \in [-1, 1]$
2. $\tau = 1 \Leftrightarrow$ строго возрастающая монотонная зависимость ($D = 0$)
3. $\tau = -1 \Leftrightarrow$ строго убывающая монотонная зависимость ($C = 0$)
4. $\tau = 0$ — нет монотонной связи

Th. (Вероятностная интерпретация)

$$\tau = P(\text{согласованная пара}) - P(\text{несогласованная пара})$$

28.3.2 Связь с коэффициентом Спирмена**Th. (Соотношение между τ и r_S)**

Для любой выборки:

$$-1 \leq \frac{3\tau - r_S}{2} \leq \tau \leq r_S \leq 1 \quad (\text{при } r_S \geq 0)$$

Асимптотически:

$$r_S \approx \frac{3}{2}\tau \quad (\text{грубое приближение})$$

28.3.3 Тест на значимость Кендалла**Th. (Распределение τ при H_0)**

При H_0 : независимость X и Y :

$$\mathbb{E}[\tau] = 0, \quad \text{Var}(\tau) = \frac{2(2n+5)}{9n(n-1)}$$

Th. (Асимптотическая нормальность)

При $n \rightarrow \infty$:

$$Z = \frac{\tau}{\sqrt{\frac{2(2n+5)}{9n(n-1)}}} = \tau \cdot \frac{3\sqrt{n(n-1)}}{\sqrt{2(2n+5)}} \xrightarrow{d} \mathcal{N}(0, 1)$$

28.3.4 Модификации при наличии связей

Def. (τ_b Кендалла)

При наличии связей:

$$\tau_b = \frac{C - D}{\sqrt{(C + D + T_X)(C + D + T_Y)}}$$

где T_X — число пар, связанных по X , T_Y — по Y .

28.4 Сравнение коэффициентов корреляции

	Пирсон	Спирмен	Кендалл
Тип связи	Линейная	Монотонная	Монотонная
Использует	Значения	Ранги	Пары
Чувствительность	К выбросам	Устойчив	Устойчив
Предположения	Нормальность	Нет	Нет
Интерпретация	Доля дисперсии	Ранговая связь	Вероятности пар

29 Критерий инверсий

Критерий инверсий — непараметрический критерий для проверки гипотезы о случайности последовательности наблюдений. Особенно полезен для обнаружения трендов.

29.1 Определение инверсии

Def. (Инверсия)

Инверсией в последовательности X_1, X_2, \dots, X_n называется пара индексов (i, j) такая, что $i < j$, но $X_i > X_j$.

Def. (Число инверсий)

$$I_n = \sum_{i < j} \mathbf{1}(X_i > X_j) = \#\{(i, j) : i < j, X_i > X_j\}$$

Ex.

Последовательность: 3, 1, 4, 2.

- (3, 1): $3 > 1$ — инверсия
- (3, 2): $3 > 2$ — инверсия
- (4, 2): $4 > 2$ — инверсия

Итого: $I_4 = 3$.

29.2 Связь с другими статистиками

Th. (Связь с коэффициентом Кендалла)

Число инверсий связано с числом несогласованных пар:

$$I_n = D \quad (\text{число несогласованных пар})$$

Коэффициент Кендалла:

$$\tau = \frac{\binom{n}{2} - 2I_n}{\binom{n}{2}} = 1 - \frac{4I_n}{n(n-1)}$$

Th. (Связь со статистикой Манна-Уитни)

Для последовательности рангов статистика U Манна-Уитни может быть выражена через инверсии.

29.3 Распределение числа инверсий

Th. (Распределение I_n при случайному порядке)

Пусть X_1, \dots, X_n — случайная перестановка чисел $1, \dots, n$ (все перестановки равновероятны). Тогда:

$$\mathbb{E}[I_n] = \frac{n(n-1)}{4}$$

$$\text{Var}(I_n) = \frac{n(n-1)(2n+5)}{72}$$

Proof.

Математическое ожидание:

Для каждой пары (i, j) , $i < j$, определим индикатор $A_{ij} = \mathbf{1}(X_i > X_j)$. При случайному порядке: $P(X_i > X_j) = 1/2$.

$$\mathbb{E}[I_n] = \mathbb{E} \left[\sum_{i < j} A_{ij} \right] = \sum_{i < j} P(X_i > X_j) = \binom{n}{2} \cdot \frac{1}{2} = \frac{n(n-1)}{4}$$

Дисперсия:

$$\text{Var}(I_n) = \sum_{i < j} \text{Var}(A_{ij}) + 2 \sum_{(i,j) \neq (k,l)} \text{Cov}(A_{ij}, A_{kl})$$

$$\text{Var}(A_{ij}) = 1/4.$$

Ковариации ненулевые только для пар с общим индексом. После вычислений получаем указанную формулу. ■

Th. (Асимптотическая нормальность)

При $n \rightarrow \infty$:

$$Z = \frac{I_n - \frac{n(n-1)}{4}}{\sqrt{\frac{n(n-1)(2n+5)}{72}}} \xrightarrow{d} \mathcal{N}(0, 1)$$

29.4 Критерий инверсий для проверки случайности

29.4.1 Постановка

Гипотезы:

- H_0 : наблюдения независимы и одинаково распределены (случайный порядок)
- H_1 : есть тренд или зависимость между последовательными наблюдениями

29.4.2 Обнаружение трендов

- **Возрастающий тренд**: малое число инверсий (I_n мало)
- **Убывающий тренд**: большое число инверсий (I_n велико)

Критическая область:

Двусторонний критерий (любой тренд):

$$|Z| > z_{1-\alpha/2}$$

Односторонний критерий (возрастающий тренд):

$$Z < -z_{1-\alpha}$$

Односторонний критерий (убывающий тренд):

$$Z > z_{1-\alpha}$$

29.4.3 Алгоритм вычисления

Наивный алгоритм: $O(n^2)$ — перебор всех пар.

Эффективный алгоритм: $O(n \log n)$ через модифицированную сортировку слиянием (merge sort).

29.5 Приложения критерия инверсий

1. Проверка случайности временных рядов
2. Обнаружение трендов в данных
3. Контроль качества: обнаружение дрейфа процесса
4. Проверка гипотезы об отсутствии автокорреляции

NB.

Критерий инверсий тесно связан с ранговыми критериями. Фактически, статистика инверсий эквивалентна статистике Кендалла с заменой $Y_i = i$ (порядковые номера).

30 Модификация критерия хи-квадрат для проверки гипотезы о согласованности данных с моделью простейшей выборки

Модификация критерия хи-квадрат позволяет проверить, являются ли данные простой выборкой (i.i.d. наблюдениями) из некоторого распределения, с учётом оцениваемых параметров.

30.1 Модель простейшей выборки

Def. (Простейшая (простая) выборка)

Простейшая выборка — это набор независимых одинаково распределённых (i.i.d.) случайных величин X_1, \dots, X_n из некоторого распределения F .

Проверка согласованности данных с моделью простейшей выборки включает:

1. Проверку соответствия данных заданному семейству распределений
2. Учёт того, что параметры распределения оценены по данным

30.2 Стандартный критерий хи-квадрат (напоминание)

Разбиваем область значений на k интервалов $\Delta_1, \dots, \Delta_k$.

Статистика:

$$\chi^2 = \sum_{j=1}^k \frac{(\nu_j - np_j)^2}{np_j}$$

где ν_j — наблюдаемое число попаданий в Δ_j , $p_j = P(X \in \Delta_j)$.

При известных p_j и H_0 : $\chi^2 \xrightarrow{d} \chi^2(k - 1)$.

30.3 Проблема оценивания параметров

Th. (Эффект оценивания параметров)

Если параметры распределения $\theta = (\theta_1, \dots, \theta_r)$ оценены по тем же данным, то при H_0 :

$$\chi^2 = \sum_{j=1}^k \frac{(\nu_j - np_j(\hat{\theta}))^2}{np_j(\hat{\theta})} \xrightarrow{d} \chi^2(k - 1 - r')$$

где $r' \leq r$ — эффективное число оценённых параметров.

NB.

Важно: $r' = r$ только если параметры оценены методом минимума хи-квадрат по сгруппированным данным. При оценивании методом максимального правдоподобия по исходным данным $r' < r$ в общем случае.

30.4 Модификация Фишера

Th. (Теорема Фишера о степенях свободы)

Если параметры θ оценены методом максимального правдоподобия по **сгруппированным данным** (то есть максимизируется мультиномиальное правдоподобие $\prod p_j(\theta)^{\nu_j}$), то:

$$\chi^2 \xrightarrow{d} \chi^2(k - 1 - r)$$

где r — число оценённых параметров.

30.5 Модификация для параметров, оценённых по исходным данным

30.5.1 Проблема

При оценивании параметров методом максимального правдоподобия по **исходным (не сгруппированным)** данным распределение статистики χ^2 лежит между $\chi^2(k - 1 - r)$ и $\chi^2(k - 1)$.

30.5.2 Подход Черноффа-Лемана

Th. (Черноффа-Лемана)

Пусть $\hat{\theta}$ — МПО по исходным данным. Тогда распределение χ^2 -статистики:

$$\chi^2 \xrightarrow{d} \sum_{i=1}^{k-1} \lambda_i Z_i^2$$

где Z_i — независимые $\mathcal{N}(0, 1)$, а $\lambda_i \in [0, 1]$ зависят от способа разбиения и распределения.

Практические рекомендации:

1. Использовать консервативную оценку с $k - 1$ степенями свободы (заносит в p-value)
2. Использовать $k - 1 - r$ степеней свободы (занижает p-value)
3. Использовать специальные поправки или бутстреп

30.6 Рекомендации по выбору разбиения

Th. (Оптимальное число интервалов)

Для минимизации ошибок II рода рекомендуется:

$$k \approx 2n^{2/5}$$

(правило Манна-Уолда).

Практические правила:

- $np_j \geq 5$ для всех j (классическое правило)
- $np_j \geq 1$ и не более 20% интервалов с $np_j < 5$ (ослабленное правило)
- Равновероятные интервалы: $p_j = 1/k$ — часто оптимальны

30.7 Критерий хи-квадрат с равновероятными интервалами

Процедура:

1. Оценить параметры $\hat{\theta}$ по данным
2. Выбрать k и построить интервалы Δ_j так, что $p_j(\hat{\theta}) = 1/k$
3. Подсчитать ν_j — число наблюдений в каждом интервале
4. Вычислить статистику:

$$\chi^2 = \frac{k}{n} \sum_{j=1}^k (\nu_j - n/k)^2 = \frac{k}{n} \sum_{j=1}^k \nu_j^2 - n$$

5. Сравнить с $\chi^2(k - 1 - r)$ или $\chi^2(k - 1)$

30.8 Специфика для некоторых распределений

30.8.1 Нормальное распределение

- При оценке μ и σ^2 по исходным данным (МПО)
- Рекомендуется использовать $k - 3$ степени свободы
- Альтернатива: критерии Шапиро-Уилка, Андерсона-Дарлинга (мощнее)

30.8.2 Экспоненциальное распределение

- При оценке λ по исходным данным
- Использовать $k - 2$ степени свободы

30.8.3 Пуассоновское распределение

- При оценке $\lambda = \bar{X}$
- Объединять категории с малыми ожидаемыми частотами
- Использовать $k - 2$ степени свободы (после объединения)

30.9 Альтернативные подходы

30.9.1 Критерий минимума хи-квадрат

Def. (Метод минимума хи-квадрат)

Оценить параметры, минимизируя статистику хи-квадрат:

$$\hat{\theta}_{MCS} = \arg \min_{\theta} \sum_{j=1}^k \frac{(\nu_j - np_j(\theta))^2}{np_j(\theta)}$$

При такой оценке гарантируется $\chi^2 \xrightarrow{d} \chi^2(k - 1 - r)$.

30.9.2 Бутстреп-калибровка

1. Оценить параметры $\hat{\theta}$ по данным
2. Генерировать B бутстреп-выборок из $F_{\hat{\theta}}$
3. Для каждой выборки оценить параметры и вычислить χ^2
4. Использовать эмпирическое распределение χ^2 для определения критических значений

30.10 Проверка независимости наблюдений

Для проверки того, что данные представляют простую выборку (i.i.d.), можно дополнительно использовать:

1. Критерий серий — проверка на автокорреляцию
2. Критерий инверсий — проверка на тренд
3. Критерий Дарбина-Уотсона — проверка автокорреляции первого порядка

30.11 Комбинированная процедура проверки

Полная проверка модели простейшей выборки:

1. Проверка вида распределения: критерий хи-квадрат, Колмогорова-Смирнова, Андерсона-Дарлинга
2. Проверка независимости: критерий серий, инверсий, автокорреляционный анализ
3. Проверка однородности: разбить выборку на части и проверить критерием однородности

NB.

При множественной проверке необходима поправка на множественные сравнения (Бонферрони, Холма и др.) для контроля вероятности ошибки I рода.

30.12 Сводная таблица степеней свободы

Ситуация	Степени свободы
Параметры известны	$k - 1$
Параметры оценены по сгруппированным данным (МПО)	$k - 1 - r$
Параметры оценены методом мин. хи-квадрат	$k - 1 - r$
Параметры оценены по исходным данным (МПО)	между $k - 1 - r$ и $k - 1$

31 Модель линейной регрессии. Предположения. Оценка наименьших квадратов

Линейная регрессия — фундаментальный метод статистического анализа, позволяющий моделировать зависимость отклика от предикторов.

31.1 Модель линейной регрессии

Def. (Линейная регрессионная модель)

Линейная модель связывает наблюдения Y_1, \dots, Y_n с объясняющими переменными (регрессорами):

$$Y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_p x_{ip} + \varepsilon_i, \quad i = 1, \dots, n$$

или в матричной форме:

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

где:

- $\mathbf{Y} = (Y_1, \dots, Y_n)^\top$ — вектор откликов ($n \times 1$)
- \mathbf{X} — матрица плана (дизайна) размера $n \times (p + 1)$
- $\boldsymbol{\beta} = (\beta_0, \beta_1, \dots, \beta_p)^\top$ — вектор параметров ($(p + 1) \times 1$)
- $\boldsymbol{\varepsilon} = (\varepsilon_1, \dots, \varepsilon_n)^\top$ — вектор ошибок ($n \times 1$)

Матрица плана:

$$\mathbf{X} = \begin{pmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1p} \\ 1 & x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix}$$

Первый столбец из единиц соответствует свободному члену β_0 .

31.2 Минимальные предположения

Def. (Минимальные предположения)

Минимальные (слабые) предположения о модели линейной регрессии:

1. **Линейность:** $\mathbb{E}[Y_i | \mathbf{x}_i] = \mathbf{x}_i^\top \boldsymbol{\beta}$
2. **Полный ранг:** $\text{rank}(\mathbf{X}) = p + 1$ (матрица \mathbf{X} полного столбцового ранга)
3. **Экзогенность:** $\mathbb{E}[\varepsilon_i | \mathbf{X}] = 0$ (или слабее: $\mathbb{E}[\varepsilon_i] = 0$)

NB.

При минимальных предположениях можно построить оценку наименьших квадратов и показать её несмешённость, но нельзя строить доверительные интервалы и проводить тесты.

31.3 Обычные (классические) предположения

Def. (Классические предположения Гаусса-Маркова)

Обычные предположения включают минимальные и дополнительно:

- (GM1) **Линейность:** $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \varepsilon$
- (GM2) **Полный ранг:** $\text{rank}(\mathbf{X}) = p + 1 \leq n$
- (GM3) **Строгая экзогенность:** $\mathbb{E}[\varepsilon | \mathbf{X}] = 0$
- (GM4) **Сферические ошибки:** $\text{Var}(\varepsilon | \mathbf{X}) = \sigma^2 \mathbf{I}_n$
 - Гомоскедастичность: $\text{Var}(\varepsilon_i) = \sigma^2$ (одинаковая дисперсия)
 - Некоррелированность: $\text{Cov}(\varepsilon_i, \varepsilon_j) = 0$ при $i \neq j$

Def. (Нормальные предположения)

Нормальная линейная модель дополнительно требует:

- (GM5) **Нормальность:** $\varepsilon | \mathbf{X} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_n)$
- Эквивалентно: $\varepsilon_1, \dots, \varepsilon_n$ — i.i.d. $\mathcal{N}(0, \sigma^2)$.

31.4 Оценка наименьших квадратов (МНК/OLS)

Def. (Метод наименьших квадратов)

Оценка наименьших квадратов (МНК, OLS — Ordinary Least Squares) минимизирует сумму квадратов остатков:

$$\hat{\beta} = \arg \min_{\beta} \|\mathbf{Y} - \mathbf{X}\beta\|^2 = \arg \min_{\beta} \sum_{i=1}^n (Y_i - \mathbf{x}_i^\top \beta)^2$$

Th. (Формула МНК-оценки)

При условии полного ранга \mathbf{X} :

$$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}$$

Proof.

Минимизируем $Q(\beta) = (\mathbf{Y} - \mathbf{X}\beta)^\top (\mathbf{Y} - \mathbf{X}\beta)$.

Раскрываем:

$$Q(\beta) = \mathbf{Y}^\top \mathbf{Y} - 2\beta^\top \mathbf{X}^\top \mathbf{Y} + \beta^\top \mathbf{X}^\top \mathbf{X}\beta$$

Градиент:

$$\frac{\partial Q}{\partial \beta} = -2\mathbf{X}^\top \mathbf{Y} + 2\mathbf{X}^\top \mathbf{X}\beta$$

Приравниваем к нулю:

$$\mathbf{X}^\top \mathbf{X}\beta = \mathbf{X}^\top \mathbf{Y}$$

Это **нормальные уравнения**. При $\text{rank}(\mathbf{X}) = p + 1$ матрица $\mathbf{X}^\top \mathbf{X}$ обратима:

$$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}$$

Гессиан $\frac{\partial^2 Q}{\partial \beta \partial \beta^\top} = 2\mathbf{X}^\top \mathbf{X}$ положительно определён, значит это минимум. ■

31.5 Геометрическая интерпретация

Def. (Проекционная матрица)

Матрица проектирования (hat matrix):

$$\mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$$

Проецирует \mathbf{Y} на пространство столбцов \mathbf{X} .

Th. (Свойства матрицы H)

1. \mathbf{H} — симметричная: $\mathbf{H}^\top = \mathbf{H}$

2. \mathbf{H} — идемпотентная: $\mathbf{H}^2 = \mathbf{H}$
3. $\text{rank}(\mathbf{H}) = \text{tr}(\mathbf{H}) = p + 1$
4. Собственные значения: 0 или 1

Предсказанные значения:

$$\hat{\mathbf{Y}} = \mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{HY}$$

Остатки:

$$\hat{\boldsymbol{\varepsilon}} = \mathbf{Y} - \hat{\mathbf{Y}} = (\mathbf{I} - \mathbf{H})\mathbf{Y} = \mathbf{MY}$$

где $\mathbf{M} = \mathbf{I} - \mathbf{H}$ — также проекционная матрица.

31.6 Свойства МНК-оценки

Th. (Несмешённость МНК-оценки)

При условиях GM1-GM3:

$$\mathbb{E}[\hat{\boldsymbol{\beta}}|\mathbf{X}] = \boldsymbol{\beta}$$

Proof.

$$\begin{aligned}\hat{\boldsymbol{\beta}} &= (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y} \\ &= (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top (\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}) \\ &= \boldsymbol{\beta} + (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \boldsymbol{\varepsilon}\end{aligned}$$

Следовательно:

$$\mathbb{E}[\hat{\boldsymbol{\beta}}|\mathbf{X}] = \boldsymbol{\beta} + (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbb{E}[\boldsymbol{\varepsilon}|\mathbf{X}] = \boldsymbol{\beta}$$

■

Th. (Ковариационная матрица МНК-оценки)

При условиях GM1-GM4:

$$\text{Var}(\hat{\boldsymbol{\beta}}|\mathbf{X}) = \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1}$$

Proof.

$$\begin{aligned}\text{Var}(\hat{\boldsymbol{\beta}}|\mathbf{X}) &= \text{Var}((\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \boldsymbol{\varepsilon}|\mathbf{X}) \\ &= (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \text{Var}(\boldsymbol{\varepsilon}|\mathbf{X}) \mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1} \\ &= (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top (\sigma^2 \mathbf{I}) \mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1} \\ &= \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1}\end{aligned}$$

■

31.7 Простая линейная регрессия

Для случая одного регрессора: $Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$.

Th. (Формулы для простой регрессии)

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(Y_i - \bar{Y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{S_{xy}}{S_{xx}}$$

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{x}$$

32 Теорема Гаусса-Маркова

Теорема Гаусса-Маркова — фундаментальный результат, обосновывающий оптимальность МНК-оценки в классе линейных несмешённых оценок.

32.1 Формулировка теоремы

Th. (Теорема Гаусса-Маркова)

При выполнении условий GM1-GM4 (без предположения нормальности) оценка наименьших квадратов $\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}$ является **наилучшей линейной несмешённой оценкой** (BLUE — Best Linear Unbiased Estimator).

То есть для любой линейной несмешённой оценки $\tilde{\beta} = \mathbf{CY}$:

$$\text{Var}(\mathbf{a}^\top \tilde{\beta}) \geq \text{Var}(\mathbf{a}^\top \hat{\beta}) \quad \forall \mathbf{a} \in \mathbb{R}^{p+1}$$

или эквивалентно:

$$\text{Var}(\tilde{\beta}) - \text{Var}(\hat{\beta}) \text{ — неотрицательно определённая матрица}$$

32.2 Доказательство теоремы Гаусса-Маркова

Proof.

Пусть $\tilde{\beta} = \mathbf{CY}$ — произвольная линейная оценка.

Шаг 1: Условие несмешённости.

Для несмешённости: $\mathbb{E}[\tilde{\beta}] = \beta$ для любого β .

$$\mathbb{E}[\mathbf{CY}] = \mathbf{C}\mathbb{E}[\mathbf{X}\beta + \varepsilon] = \mathbf{CX}\beta$$

Для равенства β при всех β необходимо:

$$\mathbf{CX} = \mathbf{I}_{p+1}$$

Шаг 2: Представление линейной оценки.

Запишем $\mathbf{C} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top + \mathbf{D}$ для некоторой матрицы \mathbf{D} .

Из условия несмешённости:

$$\mathbf{CX} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{X} + \mathbf{DX} = \mathbf{I} + \mathbf{DX} = \mathbf{I}$$

Следовательно: $\mathbf{DX} = \mathbf{0}$.

Шаг 3: Вычисление дисперсии.

$$\begin{aligned}\text{Var}(\tilde{\beta}) &= \text{Var}(\mathbf{CY}) = \sigma^2 \mathbf{CC}^\top \\ &= \sigma^2 [(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top + \mathbf{D}] [\mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} + \mathbf{D}^\top]\end{aligned}$$

Раскрываем:

$$\begin{aligned}\mathbf{CC}^\top &= (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1} + (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{D}^\top \\ &\quad + \mathbf{D} \mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1} + \mathbf{DD}^\top\end{aligned}$$

Так как $\mathbf{DX} = \mathbf{0}$, то $\mathbf{X}^\top \mathbf{D}^\top = (\mathbf{DX})^\top = \mathbf{0}$:

$$\mathbf{CC}^\top = (\mathbf{X}^\top \mathbf{X})^{-1} + \mathbf{DD}^\top$$

Шаг 4: Сравнение дисперсий.

$$\text{Var}(\tilde{\beta}) = \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1} + \sigma^2 \mathbf{DD}^\top = \text{Var}(\hat{\beta}) + \sigma^2 \mathbf{DD}^\top$$

Матрица \mathbf{DD}^\top неотрицательно определена, поэтому:

$$\text{Var}(\tilde{\beta}) \geq \text{Var}(\hat{\beta})$$

в смысле положительной определённости разности.

Равенство достигается только при $\mathbf{D} = \mathbf{0}$, то есть $\tilde{\beta} = \hat{\beta}$. ■

32.3 Следствия теоремы Гаусса-Маркова

Corollary. (Оптимальность для линейных комбинаций)

Для любой линейной комбинации $\mathbf{a}^\top \beta$ оценка $\mathbf{a}^\top \hat{\beta}$ имеет минимальную дисперсию среди всех линейных несмешённых оценок.

Corollary. (Оптимальность предсказаний)

Предсказание $\hat{Y}(\mathbf{x}_0) = \mathbf{x}_0^\top \hat{\beta}$ имеет минимальную дисперсию среди всех линейных несмешённых предсказаний.

NB.

Теорема Гаусса-Маркова не утверждает, что МНК-оценка:

- лучшая среди всех несмешённых (нелинейные могут быть лучше)
- имеет минимальный среднеквадратичный риск (смешённые могут быть лучше)
- асимптотически эффективна (это отдельное свойство)

32.4 Эффективность при нормальности

Th. (МНК при нормальных ошибках)

При выполнении GM1-GM5 (включая нормальность) МНК-оценка является:

1. **BLUE** (по теореме Гаусса-Маркова)
2. **BUE** — наилучшей несмешённой (не только линейной) — достигает границы Рао-Крамера
3. **МПО** (оценкой максимального правдоподобия)

33 Оценка остаточной дисперсии

Оценка остаточной дисперсии σ^2 необходима для построения доверительных интервалов и проверки гипотез.

33.1 Остаточная сумма квадратов

Def. (Остаточная сумма квадратов (RSS))

Остаточная сумма квадратов (Residual Sum of Squares):

$$\text{RSS} = \sum_{i=1}^n \hat{\varepsilon}_i^2 = \|\hat{\varepsilon}\|^2 = \|\mathbf{Y} - \hat{\mathbf{Y}}\|^2 = \mathbf{Y}^\top \mathbf{M} \mathbf{Y}$$

где $\mathbf{M} = \mathbf{I} - \mathbf{H}$.

33.2 Несмешённая оценка дисперсии

Th. (Несмешённая оценка σ^2)

При условиях GM1-GM4:

$$s^2 = \frac{\text{RSS}}{n - p - 1} = \frac{\sum_{i=1}^n \hat{\varepsilon}_i^2}{n - p - 1}$$

является несмешённой оценкой σ^2 .

Proof.

Шаг 1: Представление RSS.

$$\text{RSS} = \mathbf{Y}^\top \mathbf{M} \mathbf{Y} = (\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon})^\top \mathbf{M} (\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon})$$

Так как $\mathbf{M}\mathbf{X} = (\mathbf{I} - \mathbf{H})\mathbf{X} = \mathbf{X} - \mathbf{X} = \mathbf{0}$:

$$\text{RSS} = \boldsymbol{\varepsilon}^\top \mathbf{M} \boldsymbol{\varepsilon}$$

Шаг 2: Математическое ожидание.

Используем свойство: $\mathbb{E}[\varepsilon^\top \mathbf{A}\varepsilon] = \text{tr}(\mathbf{A}\text{Var}(\varepsilon)) = \sigma^2\text{tr}(\mathbf{A})$ при $\mathbb{E}[\varepsilon] = \mathbf{0}$.

$$\mathbb{E}[\text{RSS}] = \mathbb{E}[\varepsilon^\top \mathbf{M}\varepsilon] = \sigma^2\text{tr}(\mathbf{M})$$

Шаг 3: След матрицы M.

$$\text{tr}(\mathbf{M}) = \text{tr}(\mathbf{I}_n) - \text{tr}(\mathbf{H}) = n - (p + 1)$$

Шаг 4: Вывод.

$$\mathbb{E}[\text{RSS}] = \sigma^2(n - p - 1)$$

Следовательно:

$$\mathbb{E}[s^2] = \mathbb{E}\left[\frac{\text{RSS}}{n - p - 1}\right] = \sigma^2$$

■

33.3 Распределение RSS при нормальности

Th. (Распределение RSS)

При GM1-GM5:

$$\frac{\text{RSS}}{\sigma^2} \sim \chi^2(n - p - 1)$$

Proof.

$$\varepsilon \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}).$$

$\text{RSS} = \varepsilon^\top \mathbf{M}\varepsilon$, где \mathbf{M} — симметричная идемпотентная матрица.

По теореме о квадратичных формах: если $\mathbf{Z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ и \mathbf{A} идемпотентна с рангом r , то $\mathbf{Z}^\top \mathbf{A} \mathbf{Z} \sim \chi^2(r)$.

$$\frac{\varepsilon}{\sigma} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}), \text{rank}(\mathbf{M}) = n - p - 1.$$

$$\frac{\text{RSS}}{\sigma^2} = \frac{\varepsilon^\top}{\sigma} \mathbf{M} \frac{\varepsilon}{\sigma} \sim \chi^2(n - p - 1)$$

■

Corollary. (Свойства s^2)

При GM1-GM5:

$$1. \frac{(n - p - 1)s^2}{\sigma^2} \sim \chi^2(n - p - 1)$$

$$2. \mathbb{E}[s^2] = \sigma^2$$

$$3. \text{Var}(s^2) = \frac{2\sigma^4}{n - p - 1}$$

33.4 Независимость от оценки коэффициентов

Th. (Независимость $\hat{\beta}$ и s^2)

При GM1-GM5:

$\hat{\beta}$ и s^2 независимы

Proof.

$\hat{\beta} = \beta + (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \varepsilon$ — линейная функция от ε .

RSS = $\varepsilon^\top \mathbf{M} \varepsilon$, где $\hat{\varepsilon} = \mathbf{M} \varepsilon$.

Ковариация:

$$\text{Cov}((\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \varepsilon, \mathbf{M} \varepsilon) = \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{M} = \mathbf{0}$$

так как $\mathbf{X}^\top \mathbf{M} = \mathbf{X}^\top (\mathbf{I} - \mathbf{H}) = \mathbf{X}^\top - \mathbf{X}^\top = \mathbf{0}$.

При нормальности некоррелированность влечёт независимость. ■

34 Условная оценка наименьших квадратов

Условная оценка наименьших квадратов (Restricted Least Squares, RLS) используется при наличии ограничений на параметры.

34.1 Постановка задачи

Def. (Линейные ограничения)

Рассмотрим модель $\mathbf{Y} = \mathbf{X}\beta + \varepsilon$ с линейными ограничениями:

$$\mathbf{R}\beta = \mathbf{r}$$

где \mathbf{R} — матрица размера $q \times (p + 1)$, \mathbf{r} — вектор размера $q \times 1$.

Предполагаем: $\text{rank}(\mathbf{R}) = q \leq p + 1$.

Ex.

Примеры ограничений:

- $\beta_1 = 0$ (исключение переменной): $\mathbf{R} = (0, 1, 0, \dots, 0)$, $r = 0$
- $\beta_1 = \beta_2$ (равенство коэффициентов): $\mathbf{R} = (0, 1, -1, 0, \dots)$, $r = 0$
- $\beta_1 + \beta_2 = 1$ (нормировка): $\mathbf{R} = (0, 1, 1, 0, \dots)$, $r = 1$

34.2 Метод множителей Лагранжа

Def. (Задача условной оптимизации)

$$\min_{\beta} \|\mathbf{Y} - \mathbf{X}\beta\|^2 \quad \text{при условии} \quad \mathbf{R}\beta = \mathbf{r}$$

Лагранжиан:

$$\mathcal{L}(\beta, \lambda) = (\mathbf{Y} - \mathbf{X}\beta)^T (\mathbf{Y} - \mathbf{X}\beta) + 2\lambda^T (\mathbf{R}\beta - \mathbf{r})$$

Условия первого порядка:

$$\frac{\partial \mathcal{L}}{\partial \beta} = -2\mathbf{X}^T \mathbf{Y} + 2\mathbf{X}^T \mathbf{X}\beta + 2\mathbf{R}^T \lambda = \mathbf{0}$$

$$\frac{\partial \mathcal{L}}{\partial \lambda} = 2(\mathbf{R}\beta - \mathbf{r}) = \mathbf{0}$$

Th. (Формула условной МНК-оценки)

Условная оценка наименьших квадратов:

$$\tilde{\beta} = \hat{\beta} - (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{R}^T [\mathbf{R}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{R}^T]^{-1} (\mathbf{R}\hat{\beta} - \mathbf{r})$$

где $\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}$ — безусловная МНК-оценка.

Proof.

Из первого условия:

$$\begin{aligned} \mathbf{X}^T \mathbf{X}\beta &= \mathbf{X}^T \mathbf{Y} - \mathbf{R}^T \lambda \\ \beta &= (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y} - (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{R}^T \lambda = \hat{\beta} - (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{R}^T \lambda \end{aligned}$$

Подставляем в ограничение $\mathbf{R}\beta = \mathbf{r}$:

$$\begin{aligned} \mathbf{R}\hat{\beta} - \mathbf{R}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{R}^T \lambda &= \mathbf{r} \\ \lambda &= [\mathbf{R}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{R}^T]^{-1} (\mathbf{R}\hat{\beta} - \mathbf{r}) \end{aligned}$$

Подставляем обратно:

$$\tilde{\beta} = \hat{\beta} - (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{R}^T [\mathbf{R}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{R}^T]^{-1} (\mathbf{R}\hat{\beta} - \mathbf{r})$$

■

34.3 Свойства условной оценки

Th. (Несмешённость при истинности ограничений)

Если $\mathbf{R}\beta = \mathbf{r}$ выполнено (ограничения верны):

$$\mathbb{E}[\tilde{\beta}] = \beta$$

Proof.

$$\mathbb{E}[\mathbf{R}\hat{\beta} - \mathbf{r}] = \mathbf{R}\beta - \mathbf{r} = \mathbf{0}$$

Следовательно:

$$\mathbb{E}[\tilde{\beta}] = \mathbb{E}[\hat{\beta}] - \mathbf{0} = \beta$$

■

Th. (Ковариационная матрица условной оценки)

При истинности ограничений:

$$\text{Var}(\tilde{\beta}) = \sigma^2 [(\mathbf{X}^\top \mathbf{X})^{-1} - (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{R}^\top \mathbf{W}^{-1} \mathbf{R} (\mathbf{X}^\top \mathbf{X})^{-1}]$$

где $\mathbf{W} = \mathbf{R}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{R}^\top$.

Corollary. (Уменьшение дисперсии)

$$\text{Var}(\hat{\beta}) - \text{Var}(\tilde{\beta}) = \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{R}^\top \mathbf{W}^{-1} \mathbf{R} (\mathbf{X}^\top \mathbf{X})^{-1} \geq \mathbf{0}$$

Условная оценка имеет меньшую (или равную) дисперсию при истинных ограничениях.

34.4 Остаточная сумма квадратов**Th. (RSS при ограничениях)**

$$\text{RSS}_R = \text{RSS} + (\mathbf{R}\hat{\beta} - \mathbf{r})^\top \mathbf{W}^{-1} (\mathbf{R}\hat{\beta} - \mathbf{r})$$

где RSS — остаточная сумма квадратов без ограничений, RSS_R — с ограничениями.

Всегда: $\text{RSS}_R \geq \text{RSS}$.

34.5 F-тест для проверки ограничений**Th. (F-тест для линейных ограничений)**

Для проверки $H_0: \mathbf{R}\beta = \mathbf{r}$ против $H_1: \mathbf{R}\beta \neq \mathbf{r}$:

$$F = \frac{(\text{RSS}_R - \text{RSS})/q}{\text{RSS}/(n - p - 1)} \sim F(q, n - p - 1)$$

при H_0 и GM1-GM5.

Альтернативная форма:

$$F = \frac{(\mathbf{R}\hat{\beta} - \mathbf{r})^\top [\mathbf{R}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{R}^\top]^{-1} (\mathbf{R}\hat{\beta} - \mathbf{r}) / q}{s^2}$$

35 Основная теорема о линейной регрессии. Следствия. *t*-тест

Основная теорема объединяет результаты о распределениях в линейной регрессии и даёт основу для статистического вывода.

35.1 Основная теорема

Th. (Основная теорема о линейной регрессии)

При выполнении условий GM1-GM5 (нормальная линейная модель):

1. $\hat{\beta} \sim \mathcal{N}(\beta, \sigma^2(\mathbf{X}^\top \mathbf{X})^{-1})$
2. $\frac{\text{RSS}}{\sigma^2} = \frac{(n-p-1)s^2}{\sigma^2} \sim \chi^2(n-p-1)$
3. $\hat{\beta}$ и s^2 независимы

Proof.

Пункт 1: $\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}$ — линейная функция от \mathbf{Y} .

При $\mathbf{Y} \sim \mathcal{N}(\mathbf{X}\beta, \sigma^2 \mathbf{I})$:

$$\begin{aligned} \hat{\beta} &\sim \mathcal{N}((\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \cdot \mathbf{X}\beta, (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \sigma^2 \mathbf{I} \mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1}) \\ &= \mathcal{N}(\beta, \sigma^2(\mathbf{X}^\top \mathbf{X})^{-1}) \end{aligned}$$

Пункты 2-3: Доказаны ранее (раздел об оценке остаточной дисперсии). ■

35.2 Следствия основной теоремы

Corollary. (Распределение отдельного коэффициента)

Для каждого $j = 0, 1, \dots, p$:

$$\hat{\beta}_j \sim \mathcal{N}(\beta_j, \sigma^2[(\mathbf{X}^\top \mathbf{X})^{-1}]_{jj})$$

Corollary. (t -распределение)

$$\frac{\hat{\beta}_j - \beta_j}{s \cdot \sqrt{[(\mathbf{X}^\top \mathbf{X})^{-1}]_{jj}}} \sim t(n - p - 1)$$

Proof.

Обозначим $c_{jj} = [(\mathbf{X}^\top \mathbf{X})^{-1}]_{jj}$.

$$\begin{aligned}\frac{\hat{\beta}_j - \beta_j}{\sigma \sqrt{c_{jj}}} &\sim \mathcal{N}(0, 1) \\ \frac{(n - p - 1)s^2}{\sigma^2} &\sim \chi^2(n - p - 1)\end{aligned}$$

$\hat{\beta}_j$ и s^2 независимы. По определению t -распределения:

$$\frac{\frac{\hat{\beta}_j - \beta_j}{\sigma \sqrt{c_{jj}}}}{\sqrt{\frac{(n-p-1)s^2}{\sigma^2(n-p-1)}}} = \frac{\hat{\beta}_j - \beta_j}{s \sqrt{c_{jj}}} \sim t(n - p - 1)$$

■

Corollary. (Стандартная ошибка коэффициента)

$$\text{SE}(\hat{\beta}_j) = s \cdot \sqrt{[(\mathbf{X}^\top \mathbf{X})^{-1}]_{jj}}$$

35.3 t -тест для коэффициентов регрессии**35.3.1 Тест на значимость коэффициента**

Гипотезы:

- $H_0: \beta_j = 0$ (переменная x_j не влияет на Y)
- $H_1: \beta_j \neq 0$ (переменная x_j значима)

Статистика:

$$t_j = \frac{\hat{\beta}_j}{\text{SE}(\hat{\beta}_j)} = \frac{\hat{\beta}_j}{s \sqrt{[(\mathbf{X}^\top \mathbf{X})^{-1}]_{jj}}} \sim t(n - p - 1)$$

при H_0 .

Критическая область:

- Двусторонний тест: отвергаем H_0 , если $|t_j| > t_{1-\alpha/2}(n - p - 1)$
- Односторонний тест ($H_1: \beta_j > 0$): отвергаем, если $t_j > t_{1-\alpha}(n - p - 1)$

35.3.2 Тест на заданное значение

Гипотезы:

- $H_0: \beta_j = \beta_j^0$
- $H_1: \beta_j \neq \beta_j^0$

Статистика:

$$t = \frac{\hat{\beta}_j - \beta_j^0}{\text{SE}(\hat{\beta}_j)} \sim t(n - p - 1)$$

35.4 Доверительный интервал для коэффициента

Th. (Доверительный интервал)

($1 - \alpha$)-доверительный интервал для β_j :

$$\left[\hat{\beta}_j \pm t_{1-\alpha/2}(n - p - 1) \cdot \text{SE}(\hat{\beta}_j) \right]$$

Proof.

$$P \left(-t_{1-\alpha/2} < \frac{\hat{\beta}_j - \beta_j}{\text{SE}(\hat{\beta}_j)} < t_{1-\alpha/2} \right) = 1 - \alpha$$

Преобразуя:

$$P \left(\hat{\beta}_j - t_{1-\alpha/2} \cdot \text{SE}(\hat{\beta}_j) < \beta_j < \hat{\beta}_j + t_{1-\alpha/2} \cdot \text{SE}(\hat{\beta}_j) \right) = 1 - \alpha$$

■

35.5 Простая линейная регрессия: частные случаи

Для модели $Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$:

$$\begin{aligned} \text{SE}(\hat{\beta}_1) &= \frac{s}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2}} = \frac{s}{\sqrt{S_{xx}}} \\ \text{SE}(\hat{\beta}_0) &= s \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}} \end{aligned}$$

t-статистика для наклона:

$$t = \frac{\hat{\beta}_1}{s/\sqrt{S_{xx}}} = \frac{\hat{\beta}_1 \sqrt{S_{xx}}}{s}$$

35.6 F-тест для общей значимости регрессии

Гипотезы:

- $H_0: \beta_1 = \beta_2 = \dots = \beta_p = 0$ (все коэффициенты, кроме свободного члена, равны нулю)
- $H_1: \text{хотя бы один } \beta_j \neq 0$

Th. (F-статистика для общей значимости)

$$F = \frac{(\text{TSS} - \text{RSS})/p}{\text{RSS}/(n - p - 1)} = \frac{\text{ESS}/p}{\text{RSS}/(n - p - 1)} \sim F(p, n - p - 1)$$

где:

- $\text{TSS} = \sum(Y_i - \bar{Y})^2$ — полная сумма квадратов
- $\text{ESS} = \sum(\hat{Y}_i - \bar{Y})^2$ — объяснённая сумма квадратов
- $\text{RSS} = \sum(Y_i - \hat{Y}_i)^2$ — остаточная сумма квадратов

NB.

$\text{TSS} = \text{ESS} + \text{RSS}$ (разложение дисперсии).

35.7 Коэффициент детерминации**Def. (Коэффициент детерминации R^2)**

$$R^2 = \frac{\text{ESS}}{\text{TSS}} = 1 - \frac{\text{RSS}}{\text{TSS}}$$

— доля объяснённой вариации.

Th. (Свойства R^2)

1. $0 \leq R^2 \leq 1$
2. $R^2 = r_{Y\hat{Y}}^2$ — квадрат корреляции между Y и \hat{Y}
3. В простой регрессии: $R^2 = r_{XY}^2$

Def. (Скорректированный R^2)

$$\bar{R}^2 = 1 - \frac{\text{RSS}/(n - p - 1)}{\text{TSS}/(n - 1)} = 1 - (1 - R^2) \frac{n - 1}{n - p - 1}$$

Учитывает число параметров; может быть отрицательным.

Связь с F-статистикой:

$$F = \frac{R^2/p}{(1 - R^2)/(n - p - 1)}$$

35.8 Сводная таблица распределений

Статистика	Распределение при H_0
$\hat{\beta}$	$\mathcal{N}(\beta, \sigma^2(\mathbf{X}^\top \mathbf{X})^{-1})$
$\hat{\beta}_j - \beta_j$	$t(n - p - 1)$
$SE(\hat{\beta}_j)$	
$\frac{(n - p - 1)s^2}{\sigma^2}$	$\chi^2(n - p - 1)$
$F = \frac{ESS/p}{RSS/(n - p - 1)}$	$F(p, n - p - 1)$

36 F-тест. Коэффициент детерминации

F-тест — универсальный инструмент для сравнения вложенных моделей и проверки гипотез о группах параметров. *Коэффициент детерминации* измеряет качество подгонки модели.

36.1 F-тест: общая теория

Def. (Вложенные модели)

Модель M_0 (ограниченная) называется **вложенной** в модель M_1 (полную), если M_0 получается из M_1 наложением линейных ограничений на параметры.

Ex.

Полная модель: $Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \varepsilon$
 Ограниченнная модель ($\beta_2 = \beta_3 = 0$): $Y = \beta_0 + \beta_1 x_1 + \varepsilon$

36.2 F-статистика для сравнения моделей

Th. (F-тест для вложенных моделей)

Пусть RSS_R — остаточная сумма квадратов ограниченной модели (с q ограничениями), RSS — полной модели. При H_0 (ограничения верны):

$$F = \frac{(RSS_R - RSS)/q}{RSS/(n - p - 1)} \sim F(q, n - p - 1)$$

Proof.

При H_0 :

- $\frac{RSS}{\sigma^2} \sim \chi^2(n - p - 1)$

- $\frac{\text{RSS}_R - \text{RSS}}{\sigma^2} \sim \chi^2(q)$ (разность независимых χ^2)
- Эти величины независимы

По определению F -распределения:

$$F = \frac{(\text{RSS}_R - \text{RSS})/q}{\text{RSS}/(n-p-1)} = \frac{\chi^2(q)/q}{\chi^2(n-p-1)/(n-p-1)} \sim F(q, n-p-1)$$

■

Критерий: Отвергаем H_0 , если $F > F_{1-\alpha}(q, n-p-1)$.

36.3 Частные случаи F-теста

36.3.1 Тест на общую значимость регрессии

$$H_0: \beta_1 = \beta_2 = \dots = \beta_p = 0$$

Ограниченнная модель: $Y = \beta_0 + \varepsilon \Rightarrow \text{RSS}_R = \text{TSS}$

$$F = \frac{(\text{TSS} - \text{RSS})/p}{\text{RSS}/(n-p-1)} = \frac{\text{ESS}/p}{\text{RSS}/(n-p-1)} \sim F(p, n-p-1)$$

36.3.2 Тест на значимость группы переменных

$$H_0: \beta_{k+1} = \beta_{k+2} = \dots = \beta_p = 0$$

Ограниченнная модель включает только x_1, \dots, x_k .

$$F = \frac{(\text{RSS}_k - \text{RSS}_{full})/(p-k)}{\text{RSS}_{full}/(n-p-1)} \sim F(p-k, n-p-1)$$

36.3.3 Тест на один коэффициент

$$H_0: \beta_j = 0 \text{ (частный случай } q=1\text{)}$$

$$F = \frac{(\text{RSS}_{-j} - \text{RSS})/1}{\text{RSS}/(n-p-1)} = t_j^2$$

где t_j — t -статистика для β_j .

Th. (Связь F и t)

$F(1, \nu) = t^2(\nu)$, то есть F -тест с одним ограничением эквивалентен двустороннему t -тесту.

36.4 Коэффициент детерминации R^2

Def. (Разложение дисперсии)

$$\text{TSS} = \text{ESS} + \text{RSS}$$

где:

- $\text{TSS} = \sum_{i=1}^n (Y_i - \bar{Y})^2$ — полная сумма квадратов (Total)
- $\text{ESS} = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2$ — объяснённая сумма (Explained/Regression)
- $\text{RSS} = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$ — остаточная сумма (Residual)

Def. (Коэффициент детерминации)

$$R^2 = \frac{\text{ESS}}{\text{TSS}} = 1 - \frac{\text{RSS}}{\text{TSS}}$$

36.4.1 Интерпретация R^2

- R^2 — доля вариации Y , объяснённая моделью
- $R^2 = 0$: модель не объясняет вариацию (предсказание = \bar{Y})
- $R^2 = 1$: идеальная подгонка (все точки на линии регрессии)

Th. (Связь R^2 и F)

$$F = \frac{R^2/p}{(1 - R^2)/(n - p - 1)} = \frac{R^2(n - p - 1)}{(1 - R^2)p}$$

36.4.2 Проблемы с R^2

- Монотонность:** R^2 не убывает при добавлении переменных
- Переобучение:** высокий R^2 не гарантирует хорошие предсказания
- Несравнимость:** R^2 нельзя сравнивать для разных зависимых переменных

36.5 Скорректированный R^2

Def. (Adjusted R^2)

$$\bar{R}^2 = 1 - \frac{\text{RSS}/(n-p-1)}{\text{TSS}/(n-1)} = 1 - \frac{n-1}{n-p-1}(1-R^2)$$

Свойства:

- Штрафует за добавление незначимых переменных
- Может быть отрицательным
- $\bar{R}^2 < R^2$ всегда (при $p \geq 1$)
- \bar{R}^2 увеличивается при добавлении переменной $\Leftrightarrow |t_j| > 1$

36.6 Другие меры качества**Def. (Информационные критерии)****AIC** (Akaike): $AIC = n \ln(\text{RSS}/n) + 2(p+1)$ **BIC** (Bayesian): $BIC = n \ln(\text{RSS}/n) + (p+1) \ln n$

Меньшие значения предпочтительнее.

37 Однофакторный дисперсионный анализ

Дисперсионный анализ (ANOVA — Analysis of Variance) — метод сравнения средних нескольких групп путём анализа дисперсий.

37.1 Постановка задачи**Def. (Однофакторная модель)**

Имеется k групп (уровней фактора). В i -й группе n_i наблюдений:

$$Y_{ij} = \mu_i + \varepsilon_{ij}, \quad i = 1, \dots, k, \quad j = 1, \dots, n_i$$

или эквивалентно:

$$Y_{ij} = \mu + \alpha_i + \varepsilon_{ij}$$

где:

- μ — общее среднее
- α_i — эффект i -го уровня фактора
- $\varepsilon_{ij} \sim \mathcal{N}(0, \sigma^2)$ — независимые ошибки

Ограничение идентифицируемости: $\sum_{i=1}^k n_i \alpha_i = 0$ или $\alpha_1 = 0$ (базовая группа).

Гипотезы:

- $H_0: \mu_1 = \mu_2 = \dots = \mu_k$ (или $\alpha_1 = \dots = \alpha_k = 0$)
- $H_1:$ хотя бы два средних различаются

37.2 Обозначения

- $N = \sum_{i=1}^k n_i$ — общий объём выборки
- $\bar{Y}_{i\cdot} = \frac{1}{n_i} \sum_{j=1}^{n_i} Y_{ij}$ — среднее i -й группы
- $\bar{Y}_{..} = \frac{1}{N} \sum_{i,j} Y_{ij}$ — общее среднее

37.3 Разложение суммы квадратов

Th. (Разложение в ANOVA)

$$\underbrace{\sum_{i,j} (Y_{ij} - \bar{Y}_{..})^2}_{SST} = \underbrace{\sum_{i=1}^k n_i (\bar{Y}_{i\cdot} - \bar{Y}_{..})^2}_{SSB} + \underbrace{\sum_{i,j} (Y_{ij} - \bar{Y}_{i\cdot})^2}_{SSW}$$

где:

- SST — полная сумма квадратов (Total)
- SSB — межгрупповая сумма (Between groups)
- SSW — внутригрупповая сумма (Within groups)

Proof.

$$Y_{ij} - \bar{Y}_{..} = (Y_{ij} - \bar{Y}_{i\cdot}) + (\bar{Y}_{i\cdot} - \bar{Y}_{..})$$

Возводим в квадрат и суммируем. Перекрёстные члены обращаются в ноль:

$$\sum_j (Y_{ij} - \bar{Y}_{i\cdot})(\bar{Y}_{i\cdot} - \bar{Y}_{..}) = (\bar{Y}_{i\cdot} - \bar{Y}_{..}) \underbrace{\sum_j (Y_{ij} - \bar{Y}_{i\cdot})}_{=0} = 0$$

■

37.4 Степени свободы

Источник	Сумма квадратов	Степени свободы
Между группами	SSB	$k - 1$
Внутри групп	SSW	$N - k$
Полная	SST	$N - 1$

37.5 Средние квадраты и F-статистика

Def. (Средние квадраты)

$$\text{MSB} = \frac{\text{SSB}}{k - 1}, \quad \text{MSW} = \frac{\text{SSW}}{N - k}$$

Th. (Свойства средних квадратов)

При любой гипотезе:

$$\mathbb{E}[\text{MSW}] = \sigma^2$$

При H_0 :

$$\mathbb{E}[\text{MSB}] = \sigma^2$$

При H_1 :

$$\mathbb{E}[\text{MSB}] = \sigma^2 + \frac{\sum_i n_i \alpha_i^2}{k - 1} > \sigma^2$$

Th. (F-статистика ANOVA)

При H_0 :

$$F = \frac{\text{MSB}}{\text{MSW}} = \frac{\text{SSB}/(k - 1)}{\text{SSW}/(N - k)} \sim F(k - 1, N - k)$$

Proof.

При H_0 :

- $\frac{\text{SSB}}{\sigma^2} \sim \chi^2(k - 1)$
- $\frac{\text{SSW}}{\sigma^2} \sim \chi^2(N - k)$
- SSB и SSW независимы

По определению F-распределения получаем результат. ■

Критерий: Отвергаем H_0 , если $F > F_{1-\alpha}(k - 1, N - k)$.

37.6 Таблица ANOVA

Источник	SS	df	MS	F
Между группами	SSB	$k - 1$	MSB	$\frac{MSB}{MSW}$
Внутри групп	SSW	$N - k$	MSW	
Итого	SST	$N - 1$		

37.7 Связь с регрессией

ANOVA эквивалентна регрессии с фиктивными переменными:

$$Y_{ij} = \beta_0 + \beta_1 D_1 + \beta_2 D_2 + \dots + \beta_{k-1} D_{k-1} + \varepsilon_{ij}$$

где $D_i = 1$ для i -й группы, 0 иначе (первая группа — базовая).

F -тест ANOVA = F -тест на $H_0: \beta_1 = \dots = \beta_{k-1} = 0$.

37.8 Множественные сравнения

После отвержения H_0 необходимо определить, какие группы различаются.

Def. (Поправка Бонферрони)

При m сравнениях использовать уровень α/m для каждого.

Def. (Метод Тьюки (HSD))

Критическое значение для разности средних:

$$|\bar{Y}_{i\cdot} - \bar{Y}_{j\cdot}| > q_\alpha(k, N - k) \cdot \sqrt{\frac{MSW}{2} \left(\frac{1}{n_i} + \frac{1}{n_j} \right)}$$

где q_α — квантиль стьюодентизированного размаха.

38 Двухфакторный дисперсионный анализ

Двухфакторный дисперсионный анализ исследует влияние двух категориальных факторов и их взаимодействие.

38.1 Модель без взаимодействия

Def. (Аддитивная модель)

Фактор А имеет a уровней, фактор В — b уровней:

$$Y_{ijk} = \mu + \alpha_i + \beta_j + \varepsilon_{ijk}$$

где:

- μ — общее среднее

- α_i — эффект i -го уровня фактора А ($i = 1, \dots, a$)
- β_j — эффект j -го уровня фактора В ($j = 1, \dots, b$)
- $k = 1, \dots, n_{ij}$ — номер наблюдения в ячейке (i, j)

Ограничения: $\sum_i \alpha_i = 0, \sum_j \beta_j = 0.$

38.2 Модель с взаимодействием

Def. (Модель с взаимодействием)

$$Y_{ijk} = \mu + \alpha_i + \beta_j + (\alpha\beta)_{ij} + \varepsilon_{ijk}$$

где $(\alpha\beta)_{ij}$ — эффект взаимодействия факторов А и В.

Ограничения: $\sum_i (\alpha\beta)_{ij} = 0$ для всех $j, \sum_j (\alpha\beta)_{ij} = 0$ для всех $i.$

NB.

Взаимодействие означает, что эффект одного фактора зависит от уровня другого.

38.3 Разложение суммы квадратов

Для сбалансированного плана ($n_{ij} = n$ для всех i, j):

$$\text{SST} = \text{SS}_A + \text{SS}_B + \text{SS}_{AB} + \text{SSE}$$

где:

- $\text{SS}_A = bn \sum_i (\bar{Y}_{i..} - \bar{Y}_{...})^2$ — сумма квадратов фактора А
- $\text{SS}_B = an \sum_j (\bar{Y}_{.j.} - \bar{Y}_{...})^2$ — сумма квадратов фактора В
- $\text{SS}_{AB} = n \sum_{i,j} (\bar{Y}_{ij.} - \bar{Y}_{i..} - \bar{Y}_{.j.} + \bar{Y}_{...})^2$ — взаимодействие
- $\text{SSE} = \sum_{i,j,k} (Y_{ijk} - \bar{Y}_{ij.})^2$ — остаточная (ошибка)

38.4 Степени свободы

Источник	SS	df
Фактор А	SS_A	$a - 1$
Фактор В	SS_B	$b - 1$
Взаимодействие АВ	SS_{AB}	$(a - 1)(b - 1)$
Ошибка	SSE	$ab(n - 1)$
Итого	SST	$abn - 1$

38.5 F-тесты

Th. (F-статистики двухфакторного ANOVA)

При соответствующих H_0 :

$$F_A = \frac{SS_A/(a - 1)}{SSE/(ab(n - 1))} \sim F(a - 1, ab(n - 1))$$

$$F_B = \frac{SS_B/(b - 1)}{SSE/(ab(n - 1))} \sim F(b - 1, ab(n - 1))$$

$$F_{AB} = \frac{SS_{AB}/((a - 1)(b - 1))}{SSE/(ab(n - 1))} \sim F((a - 1)(b - 1), ab(n - 1))$$

38.6 Таблица двухфакторного ANOVA

Источник	SS	df	MS	F
Фактор А	SS_A	$a - 1$	MS_A	F_A
Фактор В	SS_B	$b - 1$	MS_B	F_B
$A \times B$	SS_{AB}	$(a - 1)(b - 1)$	MS_{AB}	F_{AB}
Ошибка	SSE	$ab(n - 1)$	MSE	
Итого	SST	$abn - 1$		

38.7 Интерпретация взаимодействия

- Если F_{AB} значим: эффект А зависит от уровня В (и наоборот)
- Графически: непараллельные линии на графике взаимодействия
- При значимом взаимодействии главные эффекты интерпретировать осторожно

38.8 Случай без повторений ($n = 1$)

При одном наблюдении на ячейку:

- Невозможно оценить взаимодействие отдельно от ошибки
- Используется аддитивная модель

- $SSE = SS_{AB}$ служит оценкой ошибки
- df ошибки = $(a - 1)(b - 1)$

39 Ковариационный анализ

Ковариационный анализ (ANCOVA — Analysis of Covariance) объединяет ANOVA и регрессию, позволяя учитывать влияние непрерывных ковариат при сравнении групп.

39.1 Постановка задачи

Def. (Модель ANCOVA)

$$Y_{ij} = \mu + \alpha_i + \beta(X_{ij} - \bar{X}_{..}) + \varepsilon_{ij}$$

где:

- μ — общее среднее
- α_i — эффект i -й группы (фактор)
- X_{ij} — ковариата (непрерывная переменная)
- β — коэффициент регрессии (общий для всех групп)
- $\varepsilon_{ij} \sim \mathcal{N}(0, \sigma^2)$

39.2 Цели ANCOVA

1. Контроль влияния мешающей переменной (ковариаты)
2. Повышение мощности за счёт уменьшения остаточной дисперсии
3. Корректировка групповых средних на различия в ковариате

Ex.

Сравнение эффективности методов обучения (группы) с учётом начального уровня знаний (ковариата).

39.3 Предположения ANCOVA

1. Линейная связь между Y и X
2. Гомогенность наклонов: β одинаков для всех групп
3. Независимость ковариаты от фактора (в идеале)
4. Нормальность и гомоскедастичность ошибок

39.4 Оценивание параметров

Модель является частным случаем линейной регрессии. МНК-оценки:

$$\hat{\beta} = \frac{\sum_{i,j} (X_{ij} - \bar{X}_{i\cdot})(Y_{ij} - \bar{Y}_{i\cdot})}{\sum_{i,j} (X_{ij} - \bar{X}_{i\cdot})^2} = \frac{SP_W}{SS_{X,W}}$$

Скорректированные групповые средние:

$$\bar{Y}_{i\cdot}^{adj} = \bar{Y}_{i\cdot} - \hat{\beta}(\bar{X}_{i\cdot} - \bar{X}_{..})$$

39.5 Разложение сумм квадратов

$$SST_{adj} = SS_{groups,adj} + SSE_{adj}$$

Скорректированная остаточная сумма:

$$SSE_{adj} = SSE_Y - \frac{(SP_W)^2}{SS_{X,W}}$$

где SSE_Y — остаточная сумма квадратов ANOVA без ковариаты.

39.6 F-тест ANCOVA

Th. (F-статистика ANCOVA)

Для проверки $H_0: \alpha_1 = \dots = \alpha_k = 0$ (нет различий между группами с учётом ковариаты):

$$F = \frac{SS_{groups,adj}/(k-1)}{SSE_{adj}/(N-k-1)} \sim F(k-1, N-k-1)$$

NB.

Обратите внимание на изменение степеней свободы: $N - k - 1$ вместо $N - k$ (потеря одной степени свободы на ковариату).

39.7 Проверка гомогенности наклонов

Расширенная модель с разными наклонами:

$$Y_{ij} = \mu + \alpha_i + \beta_i(X_{ij} - \bar{X}_{..}) + \varepsilon_{ij}$$

$H_0: \beta_1 = \beta_2 = \dots = \beta_k$ (гомогенность)

F-тест сравнивает модели с общим и разными наклонами.

39.8 Таблица ANCOVA

Источник	SS	df
Группы (скорр.)	$SS_{groups,adj}$	$k - 1$
Ковариата	SS_{cov}	1
Ошибки	SSE_{adj}	$N - k - 1$
Итого	SST	$N - 1$

39.9 Преимущества ANCOVA

1. Уменьшение MSE повышает мощность
2. Статистический контроль мешающих переменных
3. Более точные оценки групповых различий

40 Логистическая регрессия. Регрессия Пуассона

Обобщённые линейные модели (GLM) расширяют классическую регрессию на случаи, когда отклик не является нормально распределённым.

40.1 Обобщённые линейные модели: структура

Def. (Компоненты GLM)

1. Случайный компонент: $Y \sim$ распределение из экспоненциального семейства
2. Систематический компонент: $\eta = \mathbf{x}^\top \boldsymbol{\beta}$ — линейный предиктор
3. Функция связи: $g(\mu) = \eta$, где $\mu = \mathbb{E}[Y]$

40.2 Логистическая регрессия

Def. (Модель логистической регрессии)

Для бинарного отклика $Y \in \{0, 1\}$:

$$Y_i \sim \text{Bernoulli}(p_i)$$

$$\text{logit}(p_i) = \ln \frac{p_i}{1 - p_i} = \beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip} = \mathbf{x}_i^\top \boldsymbol{\beta}$$

40.2.1 Связь с вероятностью

Обратная функция связи:

$$p_i = \frac{e^{\mathbf{x}_i^\top \boldsymbol{\beta}}}{1 + e^{\mathbf{x}_i^\top \boldsymbol{\beta}}} = \frac{1}{1 + e^{-\mathbf{x}_i^\top \boldsymbol{\beta}}}$$

Это логистическая (сигмоидная) функция.

40.2.2 Интерпретация коэффициентов

Th. (Отношение шансов)

$$\frac{p_i}{1 - p_i} = e^{\mathbf{x}_i^\top \boldsymbol{\beta}}$$

При увеличении x_j на единицу (при прочих равных):

$$\text{Odds Ratio} = e^{\beta_j}$$

Шансы успеха умножаются на e^{β_j} .

Ex.

$\beta_j = 0.5 \Rightarrow \text{OR} = e^{0.5} \approx 1.65$: шансы увеличиваются на 65%.

$\beta_j = -0.3 \Rightarrow \text{OR} = e^{-0.3} \approx 0.74$: шансы уменьшаются на 26%.

40.2.3 Оценивание: метод максимального правдоподобия

Функция правдоподобия:

$$L(\boldsymbol{\beta}) = \prod_{i=1}^n p_i^{Y_i} (1 - p_i)^{1 - Y_i}$$

Логарифм правдоподобия:

$$\ell(\boldsymbol{\beta}) = \sum_{i=1}^n \left[Y_i \mathbf{x}_i^\top \boldsymbol{\beta} - \ln(1 + e^{\mathbf{x}_i^\top \boldsymbol{\beta}}) \right]$$

Максимизируется численно (метод Ньютона-Рафсона / IRLS).

40.2.4 Асимптотические свойства МПО**Th. (Асимптотика МПО в логистической регрессии)**

При $n \rightarrow \infty$:

$$\hat{\boldsymbol{\beta}} \xrightarrow{d} \mathcal{N}(\boldsymbol{\beta}, \mathbf{I}^{-1}(\boldsymbol{\beta}))$$

где $\mathbf{I}(\boldsymbol{\beta}) = \mathbf{X}^\top \mathbf{W} \mathbf{X}$ — информация Фишера, $\mathbf{W} = \text{diag}(p_i(1 - p_i))$.

40.2.5 Тесты в логистической регрессии

Тест Вальда:

$$z_j = \frac{\hat{\beta}_j}{\text{SE}(\hat{\beta}_j)} \approx \mathcal{N}(0, 1)$$

Тест отношения правдоподобия:

$$\Lambda = -2(\ell_0 - \ell_1) \xrightarrow{d} \chi^2(q)$$

где q — число ограничений.

Девианс:

$$D = -2\ell(\hat{\boldsymbol{\beta}}) + 2\ell_{\text{saturated}}$$

40.2.6 Меры качества

Def. (Псевдо- R^2 Макфаддена)

$$R_{McF}^2 = 1 - \frac{\ell(\hat{\beta})}{\ell_0}$$

где ℓ_0 — логарифм правдоподобия модели только с константой.

40.3 Регрессия Пуассона

Def. (Модель регрессии Пуассона)

Для счётного отклика $Y \in \{0, 1, 2, \dots\}$:

$$Y_i \sim \text{Poisson}(\lambda_i)$$

$$\ln(\lambda_i) = \beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip} = \mathbf{x}_i^\top \boldsymbol{\beta}$$

Функция связи — логарифм.

40.3.1 Связь с интенсивностью

$$\lambda_i = \mathbb{E}[Y_i] = e^{\mathbf{x}_i^\top \boldsymbol{\beta}}$$

40.3.2 Интерпретация коэффициентов

Th. (Мультипликативный эффект)

При увеличении x_j на единицу:

$$\frac{\lambda_{new}}{\lambda_{old}} = e^{\beta_j}$$

Ожидаемое число событий умножается на e^{β_j} .

Ex.

$\beta_j = 0.2 \Rightarrow e^{0.2} \approx 1.22$: ожидаемое число увеличивается на 22%.

40.3.3 Оценивание МПО

Функция правдоподобия:

$$L(\boldsymbol{\beta}) = \prod_{i=1}^n \frac{\lambda_i^{Y_i} e^{-\lambda_i}}{Y_i!}$$

Логарифм правдоподобия:

$$\ell(\boldsymbol{\beta}) = \sum_{i=1}^n \left[Y_i \mathbf{x}_i^\top \boldsymbol{\beta} - e^{\mathbf{x}_i^\top \boldsymbol{\beta}} - \ln(Y_i!) \right]$$

40.3.4 Сверхдисперсия

Def. (Сверхдисперсия)

В модели Пуассона: $\mathbb{E}[Y] = \text{Var}(Y) = \lambda$.

Сверхдисперсия — ситуация, когда $\text{Var}(Y) > \mathbb{E}[Y]$.

Решения:

- Квази-пуассоновская регрессия: $\text{Var}(Y) = \phi\lambda$
- Отрицательная биномиальная регрессия

40.3.5 Смещение (Offset)

Для моделирования интенсивности с учётом экспозиции t_i :

$$\ln(\lambda_i) = \ln(t_i) + \mathbf{x}_i^\top \boldsymbol{\beta}$$

где $\ln(t_i)$ — **смещение** (offset), известная величина.

40.4 Сравнение GLM

	Линейная	Логистическая	Пуассона
Отклик	Непрерывный	Бинарный	Счётный
Распределение	Нормальное	Бернулли	Пуассон
Функция связи	Тождественная	Логит	Логарифм
$\mathbb{E}[Y]$	$\mathbf{x}^\top \boldsymbol{\beta}$	$\frac{e^\eta}{1 + e^\eta}$	e^η
Интерпретация $\boldsymbol{\beta}$	Разность	$\ln(\text{OR})$	$\ln(\text{RR})$
Оценивание	МНК	МПО	МПО

41 Критерий отношения правдоподобий для простых гипотез. Лемма Неймана-Пирсона

Лемма Неймана-Пирсона — фундаментальный результат теории проверки гипотез, определяющий наиболее мощный критерий для простых гипотез.

41.1 Постановка задачи

Def. (Простые гипотезы)

Гипотеза называется **простой**, если она полностью определяет распределение:

- $H_0: X \sim f_0(x)$ (или P_0)
- $H_1: X \sim f_1(x)$ (или P_1)

Def. (Отношение правдоподобия)

Для наблюдений X_1, \dots, X_n **отношение правдоподобия**:

$$\Lambda(X_1, \dots, X_n) = \frac{L_1(X_1, \dots, X_n)}{L_0(X_1, \dots, X_n)} = \frac{\prod_{i=1}^n f_1(X_i)}{\prod_{i=1}^n f_0(X_i)}$$

41.2 Непрерывный случай

Пусть $f_0(x)$ и $f_1(x)$ — плотности при H_0 и H_1 соответственно.

Def. (Критерий отношения правдоподобия)

Критерий отношения правдоподобия (LRT — Likelihood Ratio Test):

Отвергаем H_0 , если $\Lambda(\mathbf{X}) > c$, где c выбирается из условия $P_{H_0}(\Lambda > c) = \alpha$.

41.3 Лемма Неймана-Пирсона**Th. (Лемма Неймана-Пирсона)**

Пусть $H_0: X \sim f_0$ и $H_1: X \sim f_1$ — простые гипотезы. Для заданного уровня значимости $\alpha \in (0, 1)$ рассмотрим критерий:

$$\phi(x) = \begin{cases} 1, & \text{если } \Lambda(x) > c \\ \gamma, & \text{если } \Lambda(x) = c \\ 0, & \text{если } \Lambda(x) < c \end{cases}$$

где константы $c \geq 0$ и $\gamma \in [0, 1]$ выбираются так, что:

$$\mathbb{E}_{H_0}[\phi(X)] = \alpha$$

Тогда:

1. Критерий ϕ имеет уровень α
2. Критерий ϕ является **наиболее мощным** (НМ) среди всех критериев уровня α

То есть для любого другого критерия ψ с $\mathbb{E}_{H_0}[\psi] \leq \alpha$:

$$\mathbb{E}_{H_1}[\phi] \geq \mathbb{E}_{H_1}[\psi]$$

(мощность ϕ не меньше мощности ψ).

Proof.

Обозначим мощности: $\beta_\phi = \mathbb{E}_{H_1}[\phi]$, $\beta_\psi = \mathbb{E}_{H_1}[\psi]$.

Покажем, что $\beta_\phi \geq \beta_\psi$.

Шаг 1: Из определения ϕ :

- При $\Lambda(x) > c$: $\phi(x) = 1 \geq \psi(x)$, поэтому $(\phi - \psi)(f_1 - cf_0) \geq 0$
- При $\Lambda(x) < c$: $\phi(x) = 0 \leq \psi(x)$, и $f_1 < cf_0$, поэтому $(\phi - \psi)(f_1 - cf_0) \geq 0$
- При $\Lambda(x) = c$: $f_1 = cf_0$, поэтому $(\phi - \psi)(f_1 - cf_0) = 0$

Шаг 2: Интегрируем:

$$\int (\phi(x) - \psi(x))(f_1(x) - cf_0(x)) dx \geq 0$$

Шаг 3: Раскрываем:

$$\begin{aligned} \int \phi f_1 dx - \int \psi f_1 dx - c \int \phi f_0 dx + c \int \psi f_0 dx \geq 0 \\ \beta_\phi - \beta_\psi - c\alpha + c\mathbb{E}_{H_0}[\psi] \geq 0 \end{aligned}$$

Шаг 4: Так как $\mathbb{E}_{H_0}[\psi] \leq \alpha$:

$$\beta_\phi - \beta_\psi \geq c(\alpha - \mathbb{E}_{H_0}[\psi]) \geq 0$$

Следовательно: $\beta_\phi \geq \beta_\psi$. ■

41.4 Следствия леммы Неймана-Пирсона

Corollary. (Единственность)

Если критерий ψ имеет ту же мощность, что и ϕ , то $\psi = \phi$ почти всюду относительно $P_0 + P_1$.

Corollary. (Рандомизация)

Рандомизация ($\gamma \in (0, 1)$) нужна только если $P_{H_0}(\Lambda = c) > 0$, что происходит в дискретном случае.

Corollary. (Монотонность мощности)

Мощность НМ-критерия не убывает по уровню α .

41.5 Примеры применения

Ex. (Нормальное распределение с известной дисперсией)

$H_0: \mu = \mu_0$ vs $H_1: \mu = \mu_1 > \mu_0$.

$X_1, \dots, X_n \sim \mathcal{N}(\mu, \sigma^2)$, σ^2 известна.

$$\Lambda = \frac{\prod \frac{1}{\sigma} \varphi\left(\frac{X_i - \mu_1}{\sigma}\right)}{\prod \frac{1}{\sigma} \varphi\left(\frac{X_i - \mu_0}{\sigma}\right)} = \exp \left\{ \frac{(\mu_1 - \mu_0)}{\sigma^2} \sum X_i - \frac{n(\mu_1^2 - \mu_0^2)}{2\sigma^2} \right\}$$

$\Lambda > c$ эквивалентно $\bar{X} > c'$.

НМ-критерий: отвергать H_0 , если $\bar{X} > \mu_0 + z_{1-\alpha} \frac{\sigma}{\sqrt{n}}$.

Ex. (Экспоненциальное распределение)

$H_0: \lambda = \lambda_0$ vs $H_1: \lambda = \lambda_1 < \lambda_0$.

$\Lambda > c$ эквивалентно $\sum X_i > c'$.

НМ-критерий основан на статистике $\sum X_i$.

42 Критерий отношения правдоподобий для простых гипотез в дискретном случае

В дискретном случае необходимо учитывать особенности: отношение правдоподобия может принимать одно и то же значение с положительной вероятностью, что требует рандомизации.

42.1 Особенности дискретного случая

Def. (Дискретные распределения)

Пусть X принимает значения в счётом множестве \mathcal{X} :

- $H_0: P_0(X = x) = p_0(x)$
- $H_1: P_1(X = x) = p_1(x)$

Отношение правдоподобия:

$$\Lambda(x) = \frac{p_1(x)}{p_0(x)}$$

Проблема: Функция $\alpha(c) = P_{H_0}(\Lambda > c)$ — ступенчатая, поэтому для заданного α может не существовать c такого, что $P_{H_0}(\Lambda > c) = \alpha$ точно.

42.2 Рандомизированный критерий

Def. (Рандомизированный критерий)

$$\phi(x) = \begin{cases} 1, & \text{если } \Lambda(x) > c \\ \gamma, & \text{если } \Lambda(x) = c \\ 0, & \text{если } \Lambda(x) < c \end{cases}$$

где γ выбирается так, что:

$$P_{H_0}(\Lambda > c) + \gamma \cdot P_{H_0}(\Lambda = c) = \alpha$$

Интерпретация: При $\Lambda(x) = c$ отвергаем H_0 с вероятностью γ (бросаем монету).

42.3 Алгоритм построения НМ-критерия в дискретном случае

1. Вычислить $\Lambda(x)$ для всех $x \in \mathcal{X}$
2. Упорядочить значения: $\Lambda(x_{(1)}) > \Lambda(x_{(2)}) > \dots$
3. Найти c и γ :

- c — наибольшее значение такое, что $P_{H_0}(\Lambda > c) \leq \alpha$
- $\gamma = \frac{\alpha - P_{H_0}(\Lambda > c)}{P_{H_0}(\Lambda = c)}$

42.4 Пример: биномиальное распределение

Ex.

$X \sim \text{Bin}(n, p)$.

$H_0: p = p_0$ vs $H_1: p = p_1 > p_0$.

$$\Lambda(k) = \frac{\binom{n}{k} p_1^k (1-p_1)^{n-k}}{\binom{n}{k} p_0^k (1-p_0)^{n-k}} = \left(\frac{p_1(1-p_0)}{p_0(1-p_1)} \right)^k \cdot \left(\frac{1-p_1}{1-p_0} \right)^n$$

При $p_1 > p_0$: $\Lambda(k)$ возрастает по k .

$\Lambda > c$ эквивалентно $X > c'$.

НМ-критерий: отвергать H_0 , если $X \geq k^*$, где k^* — наименьшее k такое, что $P_{H_0}(X \geq k) \leq \alpha$.

Рандомизация: при $X = k^* - 1$ отвергать с вероятностью γ .

42.5 Пример: распределение Пуассона

Ex.

$X \sim \text{Poisson}(\lambda)$.

$H_0: \lambda = \lambda_0$ vs $H_1: \lambda = \lambda_1 > \lambda_0$.

$$\Lambda(k) = \frac{e^{-\lambda_1} \lambda_1^k / k!}{e^{-\lambda_0} \lambda_0^k / k!} = e^{\lambda_0 - \lambda_1} \left(\frac{\lambda_1}{\lambda_0} \right)^k$$

При $\lambda_1 > \lambda_0$: $\Lambda(k)$ возрастает по k .

НМ-критерий: отвергать при больших значениях X .

42.6 Практические замечания

- **Рандомизация на практике:** часто избегают, используя ближайший достижимый уровень
- **p-value:** минимальный уровень, при котором H_0 отвергается
- **Консервативный критерий:** не использовать рандомизацию, уровень $\leq \alpha$

43 Общий критерий отношения максимальных правдоподобий для сложных гипотез

Для сложных гипотез (когда параметр не полностью определён) используется обобщённый критерий отношения правдоподобий (GLRT).

43.1 Сложные гипотезы

Def. (Сложные гипотезы)

- $H_0: \theta \in \Theta_0$ (подмножество параметрического пространства)
- $H_1: \theta \in \Theta_1 = \Theta \setminus \Theta_0$

Ex.

$H_0: \mu \leq \mu_0$ vs $H_1: \mu > \mu_0$ — обе гипотезы сложные.
 $H_0: \mu = \mu_0$ vs $H_1: \mu \neq \mu_0$ — H_0 простая, H_1 сложная.

43.2 Обобщённый критерий отношения правдоподобий (GLRT)

Def. (GLRT-статистика)

$$\Lambda = \frac{\sup_{\theta \in \Theta_0} L(\theta; X)}{\sup_{\theta \in \Theta} L(\theta; X)} = \frac{L(\hat{\theta}_0; X)}{L(\hat{\theta}; X)}$$

где $\hat{\theta}_0$ — МПО при H_0 , $\hat{\theta}$ — безусловный МПО.

Свойства:

- $0 \leq \Lambda \leq 1$
- Малые значения Λ свидетельствуют против H_0

Def. (GLRT-критерий)

Отвергаем H_0 , если $\Lambda \leq c$, где c выбирается из условия:

$$\sup_{\theta \in \Theta_0} P_\theta(\Lambda \leq c) = \alpha$$

43.3 Асимптотическое распределение**Th. (Теорема Уилкса)**

При регулярных условиях, если H_0 верна и Θ_0 задаётся r независимыми ограничениями:

$$-2 \ln \Lambda \xrightarrow{d} \chi^2(r)$$

при $n \rightarrow \infty$.

Proof. (Идея доказательства)

При H_0 : $\hat{\theta} - \hat{\theta}_0 = O_p(n^{-1/2})$.

Разложение в ряд Тейлора логарифма правдоподобия:

$$\ln L(\hat{\theta}) - \ln L(\hat{\theta}_0) \approx \frac{1}{2}(\hat{\theta} - \hat{\theta}_0)^\top I(\theta_0)(\hat{\theta} - \hat{\theta}_0)$$

Это квадратичная форма от асимптотически нормального вектора с r ограничениями, что даёт $\chi^2(r)$. ■

Критерий: Отвергаем H_0 , если $-2 \ln \Lambda > \chi^2_{1-\alpha}(r)$.

43.4 Примеры GLRT**43.4.1 Проверка значения среднего**

$X_1, \dots, X_n \sim \mathcal{N}(\mu, \sigma^2)$, оба параметра неизвестны.

$H_0: \mu = \mu_0$ vs $H_1: \mu \neq \mu_0$.

GLRT-статистика эквивалентна t -статистике:

$$-2 \ln \Lambda = n \ln \left(1 + \frac{t^2}{n-1} \right)$$

где $t = \frac{\bar{X} - \mu_0}{s/\sqrt{n}}$.

При $n \rightarrow \infty$: $-2 \ln \Lambda \xrightarrow{d} \chi^2(1)$.

43.4.2 Проверка равенства дисперсий

$X_1, \dots, X_m \sim \mathcal{N}(\mu_1, \sigma_1^2)$, $Y_1, \dots, Y_n \sim \mathcal{N}(\mu_2, \sigma_2^2)$.

$H_0: \sigma_1^2 = \sigma_2^2$ vs $H_1: \sigma_1^2 \neq \sigma_2^2$.

GLRT приводит к F -статистике: $F = s_1^2/s_2^2$.

43.4.3 Проверка в таблицах сопряжённости

H_0 : независимость признаков.

$$-2 \ln \Lambda = 2 \sum_{ij} O_{ij} \ln \frac{O_{ij}}{E_{ij}} — \text{статистика } G^2 \text{ (G-test).}$$

При H_0 : $G^2 \xrightarrow{d} \chi^2((r-1)(c-1))$.

43.5 Сравнение GLRT с другими критериями

Критерий	Статистика	Асимптотика
GLRT	$-2 \ln \Lambda$	$\chi^2(r)$
Вальда	$(\hat{\theta} - \theta_0)^\top \hat{I}(\hat{\theta} - \theta_0)$	$\chi^2(r)$
Множ. Лагранжа (Score)	$S(\theta_0)^\top I^{-1}(\theta_0)S(\theta_0)$	$\chi^2(r)$

Все три асимптотически эквивалентны при H_0 .

44 Последовательный анализ Вальда. Алгоритм. Теорема о конечном числе шагов

Последовательный анализ — метод, при котором решение о принятии/отвержении гипотезы принимается по мере поступления данных, а не после сбора фиксированной выборки.

44.1 Мотивация

- В классических тестах объём выборки n фиксирован заранее
- Последовательные тесты позволяют принять решение раньше
- В среднем требуется меньше наблюдений для достижения тех же ошибок

44.2 Постановка задачи

Def. (Последовательный критерий)

Для простых гипотез:

- $H_0: X \sim f_0$
- $H_1: X \sim f_1$

После каждого наблюдения X_n принимается одно из решений:

1. Принять H_0
2. Принять H_1
3. Продолжить наблюдения

44.3 Последовательный критерий отношения вероятностей (SPRT)

Def. (SPRT Вальда)

После n наблюдений вычисляется отношение правдоподобия:

$$\Lambda_n = \frac{L_1(X_1, \dots, X_n)}{L_0(X_1, \dots, X_n)} = \prod_{i=1}^n \frac{f_1(X_i)}{f_0(X_i)}$$

Правило решения:

$\begin{cases} \text{Принять } H_0, & \text{если } \Lambda_n \leq A \\ \text{Принять } H_1, & \text{если } \Lambda_n \geq B \\ \text{Продолжить,} & \text{если } A < \Lambda_n < B \end{cases}$

где $0 < A < 1 < B$ — граничные константы.

44.4 Логарифмическая форма

Удобнее работать с логарифмом:

$$S_n = \ln \Lambda_n = \sum_{i=1}^n \ln \frac{f_1(X_i)}{f_0(X_i)} = \sum_{i=1}^n Z_i$$

где $Z_i = \ln \frac{f_1(X_i)}{f_0(X_i)}$.

Правило:

$\begin{cases} \text{Принять } H_0, & \text{если } S_n \leq a = \ln A \\ \text{Принять } H_1, & \text{если } S_n \geq b = \ln B \\ \text{Продолжить,} & \text{если } a < S_n < b \end{cases}$

44.5 Графическая интерпретация

S_n — случайное блуждание. Тест останавливается при первом выходе за границы $[a, b]$:

- Выход через нижнюю границу $a \Rightarrow$ принять H_0
- Выход через верхнюю границу $b \Rightarrow$ принять H_1

44.6 Теорема о конечном числе шагов

Th. (Завершение SPRT)

При условии, что $P_0 \neq P_1$ (распределения различны), последовательный критерий отношения правдоподобностей завершается с вероятностью 1:

$$P(\text{тест завершится за конечное число шагов}) = 1$$

независимо от того, какая гипотеза верна.

Proof. (Идея доказательства)

Случай 1: $\mathbb{E}[Z_i] \neq 0$ при истинной гипотезе.

По закону больших чисел: $S_n/n \rightarrow \mathbb{E}[Z_i] \neq 0$.

Следовательно, $|S_n| \rightarrow \infty$, и блуждание выйдет за границы.

Случай 2: Если $\mathbb{E}_{H_0}[Z_i] < 0$ (всегда верно при H_0 , так как $\mathbb{E}_{H_0}[\ln \frac{f_1}{f_0}] = -D_{KL}(f_0\|f_1) < 0$), то $S_n \rightarrow -\infty$ при H_0 .

Аналогично, $\mathbb{E}_{H_1}[Z_i] = D_{KL}(f_1\|f_0) > 0$, и $S_n \rightarrow +\infty$ при H_1 .

В обоих случаях тест завершится. ■

NB.

Ключевое условие: $P_0 \neq P_1$, то есть гипотезы различимы. Если $f_0 = f_1$, то $Z_i = 0$, и тест никогда не завершится.

45 Последовательный анализ Вальда. Оценка констант и вероятностей ошибок. Среднее число итераций

45.1 Вероятности ошибок

Def. (Ошибки в последовательном teste)

- $\alpha = P_{H_0}$ (принять H_1) — ошибка I рода
- $\beta = P_{H_1}$ (принять H_0) — ошибка II рода

45.2 Теорема об оценке граничных констант

Th. (Приближённые границы Вальда)

Для заданных вероятностей ошибок α и β граничные константы приближённо равны:

$$A \approx \frac{\beta}{1 - \alpha}, \quad B \approx \frac{1 - \beta}{\alpha}$$

или в логарифмической форме:

$$a = \ln A \approx \ln \frac{\beta}{1 - \alpha}, \quad b = \ln B \approx \ln \frac{1 - \beta}{\alpha}$$

Proof.

Рассмотрим событие $\{\text{принять } H_1\} = \{\Lambda_N \geq B\}$ при остановке на шаге N .

При H_0 :

$$\alpha = P_{H_0}(\Lambda_N \geq B) = \mathbb{E}_{H_0}[\mathbf{1}(\Lambda_N \geq B)]$$

При H_1 :

$$1 - \beta = P_{H_1}(\Lambda_N \geq B) = \mathbb{E}_{H_1}[\mathbf{1}(\Lambda_N \geq B)]$$

Используя замену меры: $dP_1 = \Lambda \cdot dP_0$:

$$1 - \beta = \mathbb{E}_{H_0}[\Lambda_N \cdot \mathbf{1}(\Lambda_N \geq B)]$$

Приближённо (при выходе через верхнюю границу $\Lambda_N \approx B$):

$$1 - \beta \approx B \cdot \alpha \Rightarrow B \approx \frac{1 - \beta}{\alpha}$$

Аналогично для нижней границы (при выходе $\Lambda_N \approx A$):

$$\beta \approx (1 - \alpha) \cdot A \Rightarrow A \approx \frac{\beta}{1 - \alpha}$$

■

NB.

Приближения точны, когда блуждание выходит ровно на границу. На практике возможен “перескок” границы, и реальные ошибки могут отличаться. Формулы Вальда дают оценку сверху для α и β одновременно.

45.3 Уточнённые оценки ошибок

Th. (Неравенства для ошибок)

Для любого SPRT с границами A и B :

$$\begin{aligned} \alpha + \beta &\leq 1 \\ \alpha &\leq \frac{1}{B}, \quad \beta \leq A \end{aligned}$$

Более точно:

$$\frac{\alpha}{1 - \beta} \leq \frac{1}{B}, \quad \frac{\beta}{1 - \alpha} \leq A$$

45.4 Среднее число итераций (ASN)

Def. (ASN — Average Sample Number)

$\mathbb{E}[N] =$ среднее число наблюдений до остановки

Th. (Формула Вальда для ASN)

Пусть $\mu = \mathbb{E}[Z_i]$ при истинной гипотезе, $\mu \neq 0$. Тогда:

$$\mathbb{E}[N] \approx \frac{\mathbb{E}[S_N]}{\mu}$$

где S_N — значение логарифма отношения правдоподобия при остановке.

При H_0 ($\mu_0 = \mathbb{E}_{H_0}[Z_i] < 0$):

$$\mathbb{E}_{H_0}[S_N] \approx (1 - \alpha) \cdot a + \alpha \cdot b = (1 - \alpha) \ln \frac{\beta}{1 - \alpha} + \alpha \ln \frac{1 - \beta}{\alpha}$$

При H_1 ($\mu_1 = \mathbb{E}_{H_1}[Z_i] > 0$):

$$\mathbb{E}_{H_1}[S_N] \approx \beta \cdot a + (1 - \beta) \cdot b = \beta \ln \frac{\beta}{1 - \alpha} + (1 - \beta) \ln \frac{1 - \beta}{\alpha}$$

Th. (Приближённые формулы ASN)

$$\mathbb{E}_{H_0}[N] \approx \frac{(1 - \alpha) \ln \frac{\beta}{1 - \alpha} + \alpha \ln \frac{1 - \beta}{\alpha}}{\mathbb{E}_{H_0}[Z]}$$

$$\mathbb{E}_{H_1}[N] \approx \frac{\beta \ln \frac{\beta}{1 - \alpha} + (1 - \beta) \ln \frac{1 - \beta}{\alpha}}{\mathbb{E}_{H_1}[Z]}$$

45.5 Сравнение с фиксированным объёмом выборки**Th. (Эффективность SPRT)**

SPRT с заданными α и β требует в среднем примерно вдвое меньше наблюдений, чем наилучший фиксированный тест с теми же ошибками:

$$\mathbb{E}[N_{SPRT}] \approx \frac{1}{2} n_{fixed}$$

Точнее, экономия составляет от 30% до 70% в зависимости от параметров.

45.6 Пример: нормальное распределение

$X_i \sim \mathcal{N}(\mu, \sigma^2)$, σ^2 известна.

$H_0: \mu = \mu_0$ vs $H_1: \mu = \mu_1 > \mu_0$.

$$Z_i = \ln \frac{f_1(X_i)}{f_0(X_i)} = \frac{(\mu_1 - \mu_0)}{\sigma^2} \left(X_i - \frac{\mu_0 + \mu_1}{2} \right)$$

$$\mathbb{E}_{H_0}[Z_i] = -\frac{(\mu_1 - \mu_0)^2}{2\sigma^2}, \quad \mathbb{E}_{H_1}[Z_i] = \frac{(\mu_1 - \mu_0)^2}{2\sigma^2}$$

46 Введение в байесовскую статистику. Credible intervals. Приверка гипотез

Байесовская статистика — альтернативный подход к статистическому выводу, основанный на теореме Байеса и субъективной интерпретации вероятности.

46.1 Основные принципы

Def. (Байесовский подход)

- Параметр θ — случайная величина с **априорным распределением** $\pi(\theta)$
- Данные X имеют условное распределение $f(x|\theta)$ — **правдоподобие**
- После наблюдения данных обновляем знания до **апостериорного распределения** $\pi(\theta|x)$

Th. (Теорема Байеса)

$$\boxed{\pi(\theta|x) = \frac{f(x|\theta)\pi(\theta)}{\int f(x|\theta')\pi(\theta') d\theta'} \propto f(x|\theta)\pi(\theta)}$$

Апостериорное \propto Правдоподобие \times Априорное

46.2 Сравнение с частотным подходом

	Частотный	Байесовский
Параметр θ	Фиксированный	Случайный
Вероятность	Частотная	Субъективная
Результат	Точечная/интервальная оценка	Апостериорное распределение
Предварительное знание	Не учитывается	Априорное распределение

46.3 Априорные распределения

Def. (Типы априорных распределений)

- **Информативное:** отражает существенные предварительные знания
- **Неинформативное (диффузное):** минимальное влияние на апостериорное
- **Сопряжённое:** апостериорное принадлежит тому же семейству, что и априорное

Ex. (Сопряжённые пары)

- Бернулли + Бета → Бета
- Пуассон + Гамма → Гамма
- Нормальное (известная σ^2) + Нормальное → Нормальное
- Нормальное (известное μ) + Обратное гамма → Обратное гамма

46.4 Байесовские точечные оценки**Def. (Апостериорные оценки)**

- Апостериорное среднее: $\hat{\theta}_{PM} = \mathbb{E}[\theta|X]$
- Апостериорная медиана: $\text{Med}[\theta|X]$
- Апостериорная мода (MAP): $\hat{\theta}_{MAP} = \arg \max_{\theta} \pi(\theta|X)$

Th. (Оптимальность)

- Апостериорное среднее минимизирует квадратичный риск
- Апостериорная медиана минимизирует абсолютный риск
- MAP максимизирует апостериорную плотность

46.5 Credible Intervals (доверительные интервалы Байеса)**Def. (Credible Interval)**

($1 - \alpha$)-байесовский доверительный интервал (credible interval) для θ — это интервал $[L, U]$ такой, что:

$$P(\theta \in [L, U]|X) = 1 - \alpha$$

Интерпретация: Вероятность того, что θ лежит в интервале, равна $1 - \alpha$ при условии наблюдённых данных.

NB.

В отличие от частотного доверительного интервала, байесовский интервал имеет прямую вероятностную интерпретацию относительно параметра.

46.5.1 Типы credible intervals

Def. (Equal-tailed interval)**Равнохвостый интервал:**

$$P(\theta < L|X) = P(\theta > U|X) = \frac{\alpha}{2}$$

Def. (HPD interval)**Highest Posterior Density (HPD) интервал:** кратчайший интервал с заданной апостериорной вероятностью. C — HPD интервал, если:

1. $P(\theta \in C|X) = 1 - \alpha$
2. Для любого $\theta_1 \in C$ и $\theta_2 \notin C$: $\pi(\theta_1|X) \geq \pi(\theta_2|X)$

Ex. (Нормальное распределение) $X_1, \dots, X_n | \mu \sim \mathcal{N}(\mu, \sigma^2)$, σ^2 известна.Априорное: $\mu \sim \mathcal{N}(\mu_0, \tau^2)$.Апостериорное: $\mu|X \sim \mathcal{N}(\mu_n, \sigma_n^2)$, где:

$$\mu_n = \frac{\frac{n}{\sigma^2} \bar{X} + \frac{1}{\tau^2} \mu_0}{\frac{n}{\sigma^2} + \frac{1}{\tau^2}}, \quad \sigma_n^2 = \frac{1}{\frac{n}{\sigma^2} + \frac{1}{\tau^2}}$$

95% credible interval: $\mu_n \pm 1.96\sigma_n$.**46.6 Байесовская проверка гипотез****46.6.1 Апостериорные вероятности гипотез****Def. (Апостериорные вероятности)**Для гипотез H_0 и H_1 с априорными вероятностями $P(H_0)$ и $P(H_1) = 1 - P(H_0)$:

$$P(H_0|X) = \frac{P(X|H_0)P(H_0)}{P(X|H_0)P(H_0) + P(X|H_1)P(H_1)}$$

46.6.2 Байес-фактор**Def. (Байес-фактор)**

$$BF_{01} = \frac{P(X|H_0)}{P(X|H_1)} = \frac{\int f(X|\theta)\pi_0(\theta) d\theta}{\int f(X|\theta)\pi_1(\theta) d\theta}$$

— отношение маргинальных правдоподобий.

Связь с апостериорными шансами:

$$\frac{P(H_0|X)}{P(H_1|X)} = BF_{01} \cdot \frac{P(H_0)}{P(H_1)}$$

Апостериорные шансы = Байес-фактор \times Априорные шансы

46.6.3 Интерпретация Байес-фактора

BF_{01}	Сила доказательства в пользу H_0
> 100	Решающее
$30 - 100$	Очень сильное
$10 - 30$	Сильное
$3 - 10$	Существенное
$1 - 3$	Слабое
$1/3 - 1$	Слабое в пользу H_1
$< 1/3$	Существенное и более в пользу H_1

46.6.4 Точечные нулевые гипотезы

Def. (Точечная гипотеза)

$H_0: \theta = \theta_0$ vs $H_1: \theta \neq \theta_0$.

Требуется присвоить H_0 ненулевую априорную вероятность $\pi_0 = P(\theta = \theta_0)$.

Априорное распределение:

$$\pi(\theta) = \pi_0 \delta_{\theta_0}(\theta) + (1 - \pi_0)g(\theta)$$

где $g(\theta)$ — непрерывная плотность при H_1 .

Апостериорная вероятность:

$$P(H_0|X) = \frac{\pi_0 f(X|\theta_0)}{\pi_0 f(X|\theta_0) + (1 - \pi_0)m_1(X)}$$

где $m_1(X) = \int f(X|\theta)g(\theta) d\theta$ — маргинальное правдоподобие при H_1 .

46.7 Сравнение байесовского и частотного подходов к проверке гипотез

	Частотный	Байесовский
Результат	p-value	$P(H_0 X)$, Байес-фактор
Интерпретация	$P(\text{данные} H_0)$	$P(H_0 \text{данные})$
Априорное	Не нужно	Необходимо
H_0 vs H_1	Асимметрия	Симметрия

NB.

Малое p-value не обязательно означает высокую апостериорную вероятность H_1 . Это называется **парадоксом Линдли-Джеффриса**: при больших n p-value может быть малым, а Байес-фактор — в пользу H_0 .